


ANÁLISE ESPECTRAL DE SINAIS E SISTEMAS MECÂNICOS LINEARES



José Roberto de França Arruda
Belisário Nina Hualpa

**UNIVERSIDADE ESTADUAL DE CAMPINAS
FACULDADE DE ENGENHARIA MECÂNICA**

Campinas, 2008

Copyright© (2005,2006,2008) José Roberto de França Arruda e Belisário Nina Huallpa. Todos os direitos reservados. É vedada a distribuição deste trabalho ou qualquer parte dele em qualquer formato sem a prévia autorização dos proprietários do direito autoral.

Prefácio

Este livro tem por objetivo fazer uma introdução às técnicas de análise de sinais baseadas no uso da Transformada de Fourier Discreta (TFD), cuja implementação na forma de algoritmos eficientes (Transformada de Fourier Rápida) constitui-se numa verdadeira revolução no processamento de sinais dinâmicos. Ele é fruto de mais de vinte anos de experiência ministrando disciplina da área de análise de sinais em cursos de graduação e pós-graduação da Faculdade de Engenharia Mecânica da Universidade Estadual de Campinas.

Com a disseminação de sistemas de aquisição de dados baseados em microcomputadores, estas ferramentas passaram a estar ao alcance de uma diversificada e vasta gama de profissionais. Por outro lado, enquanto nos sistemas dedicados quase todo o processamento de sinais era feito por *software* ou *hardware* dedicado, sem necessidade de muita intervenção e conhecimento do usuário, nos sistemas de aquisição de dados genéricos é o usuário quem deve implementar as rotinas computacionais que calculam os espectros e outros parâmetros dos sinais adquiridos. O objetivo desta obra é expor os conhecimentos básicos necessários a uma utilização consciente de sistemas comerciais dedicados ou à implementação de rotinas simples de análise de sinais digitalizados em um microcomputador.

O texto está mais voltado para as aplicações em análise espectral de sinais experimentais, mas as técnicas expostas podem ser utilizadas igualmente na solução numérica de equações diferenciais e na análise de sinais simulados numericamente. A variável independente é geralmente assumida como sendo o tempo, mas nada impede que seja uma variável espacial ou outra variável qualquer.

Os conhecimentos básicos necessários à compreensão deste texto são o cálculo integral e diferencial e o uso de variáveis complexas. O texto pode ser usado tanto em cursos dos últimos anos de uma formação em engenharia como em cursos introdutórios sobre o assunto na pós graduação, ou ainda como curso de extensão para atualização de profissionais. As áreas de aplicação são, principalmente, a análise de vibração e ruído e a análise de dados experimentais em geral.

Os exercícios são desenvolvidos utilizando o ambiente MATLAB[®] (The Mathworks, Inc.), mas podem ser facilmente implementados em qualquer linguagem de computador.

O capítulo 1 introduz as definições da série e da transformada de Fourier. Apesar de muito conhecidas, é importante apresentá-las para definir a notação utilizada e interpretar a representação gráfica para espectros de sinais dinâmicos. Importantes relações envolvendo a série e a transformada de Fourier, tais como o teorema da convolução, o teorema da energia e a fórmula de Poisson, são demonstradas e interpretadas. Fenômenos de modulação e janelas de observação são brevemente discutidos.

O capítulo 2 apresenta as relações entre os sinais de entrada e saída em sistemas lineares. A noção de Função de Resposta em Frequência (FRF) é introduzida de forma absolutamente geral, partindo-se apenas das propriedades de causalidade e linearidade de um sistema genérico de parâmetros invariantes no tempo.

No capítulo 3, a discretização de sinais é abordada, o teorema da amostragem deduzido e a Transformada de Fourier Discreta definida.

No capítulo 4 alguns dos algoritmos mais usados da Transformada de Fourier Rápida são descritos e o aumento de resolução espectral por re-amostragem é tratado.

No capítulo 5 é exposta a teoria de sinais aleatórios e definida a Densidade Espectral de Potência (DEP) de três formas diferentes, sendo demonstrada a equivalência entre as três. Além disso, nele é apresentada a estimação da DEP através da TFD e é abordado o problema da circularidade no cálculo das funções de correlação através da TFD.

No capítulo 6 é vista a teoria de sistemas lineares com entrada aleatória e definida a função de coerência ordinária e os estimadores da FRF para o caso de uma entrada e uma saída e no caso geral de sistemas de múltiplas entradas.

O capítulo 7 faz uma introdução à análise paramétrica de sinais, apresentando a obtenção da DEP via modelo auto-regressivo e comparando-a com a obtenção via TFD usando uma abordagem que deixa clara a diferença entre ambas as estimativas.

O capítulo 8 apresenta uma síntese da teoria apresentada nos capítulos anteriores, comentando os três tipos de representação espectral e deixando clara a importância de se usar a representação adequada para cada tipo básico de sinal: transitório, periódico e aleatório.

Nos capítulos de 9 a 11 são abordados outros métodos de análise espectral. O capítulo 9 trata da Transformada de Hilbert e do conceito de sinal analítico. O capítulo 10 apresenta uma abordagem generalizada da Transformada de Fourier Discreta que passa a ser utilizada como aproximação, ao invés da tradicional interpolação. A abordagem regressiva pode ser utilizada em aplicações onde se desejam aproximar sinais unidimensionais ou multidimensionais, tratar sinais não uniformemente amostrados ou sinais com dados incompletos e realizar suavizações de curvas para o cálculo numérico de derivadas. O capítulo 11 apresenta alguns métodos de identificação de modelos paramétricos diferentes da série e integral de Fourier. Estes métodos podem ser usados para identificar parâmetros de sistemas lineares a partir dos sinais de entrada e saída.

Ainda que se trate aqui, com a exceção dos capítulos 10 e 11, de material clássico, que pode ser encontrado em vários livros texto, acreditamos que esta obra traz uma contribuição na forma original com que apresenta o material. Centrada na análise de Fourier de sinais periódicos, transitórios e aleatórios discretizados, resumida nas fórmulas de Shannon e Poisson e nos teoremas de Wiener-Kinchine, o texto procura criar uma base sólida para que o leitor possa utilizar de forma adequada a ferramenta da TFD para

analisar os diferentes tipos de sinal. A apresentação não se esquivava da álgebra elaborada que está por trás das técnicas de processamento de sinais, mas privilegia a compreensão e capacidade de manipulação pelo leitor das ferramentas, em detrimento muitas vezes de um maior rigor nas demonstrações apresentadas. Demonstrações mais rigorosas podem ser encontradas nas referências citadas ao longo do texto. Finalmente, uma transformada que pode ser usada para obter espectros com largura de banda proporcional à frequência (Q constante) é apresentada.

Esperamos que esta obra possa ajudar engenheiros e pesquisadores, que precisam analisar sinais experimentais e simulados numericamente, a melhor utilizar as ferramentas que encontrará a sua disposição, bem como a desenvolver ferramentas próprias usando da versatilidade dos sistemas de aquisição de dados baseados em microcomputador. Agradecemos ao aluno Túlio Campos pela formatação final do livro ao Conselho Nacional de Desenvolvimento Científico e Tecnológico, a Fundação de Amparo à Pesquisa do Estado de São Paulo e a Fundação CAPES, por terem financiado nossa atividade de pesquisa e pós-graduação ao longo de todos estes anos.

Campinas, maio de 2005

José Roberto de França Arruda
Professor Titular

1 - Análise de Fourier

O resultado quantitativo da observação de um fenômeno físico são os valores assumidos por uma grandeza que podemos designar por x , que é função de uma variável independente que denotaremos t . Na maioria das aplicações, a função $x(t)$ será uma função do tempo. Exemplos de grandezas físicas representada por tais funções são a aceleração, a pressão sonora, a força e a temperatura. A variável independente pode também ser um outro parâmetro físico como, por exemplo, a posição no espaço ao longo de um eixo coordenado.

A esta função do tempo chamaremos de **sinal**. Um sinal básico, que corresponde à solução de uma equação diferencial ordinária de segunda ordem, que governa a dinâmica dos osciladores lineares simples (sistema massa-mola-amortecedor, ressonador de Helmholtz, etc.), é a senóide. A forma gráfica desta função é mostrada na figura 1.1.




figura 1.1. Traçado de um sinal senoidal; — $x(t) = X \sin(\Omega t)$. ----
 $x(t) = X \sin(\Omega t + \beta)$

O sinal senoidal é o tipo mais elementar que se pode obter em fenômenos físicos. Caracterizado por uma amplitude X , uma fase β e uma frequência Ω , a senóide é a base da análise espectral e da análise de sistemas lineares, como veremos nos próximos capítulos.

A frequência Ω é denominada frequência angular pois pode ser associada a um movimento de rotação circular uniforme, que gera, na sua projeção, uma senóide (veja figura 1.1). Por isso ela é expressa em radianos por segundo. Na análise de sinais é mais comum expressar frequências em ciclos por segundo, ou Hertz. No texto denotaremos f a frequência em Hertz, sendo que valem as relações:

$$f = \frac{\Omega}{2\pi} \quad (1.1)$$

$$T = \frac{1}{f}$$

O inverso da frequência f é o período T , ou intervalo de tempo que a função leva para assumir novamente um mesmo valor numérico:

$$x(t) = x(t \pm nT), \quad n = 1, 2, \dots \quad (1.2)$$

Existem diversas formas de expressar a amplitude do sinal. Ao fator multiplicativo que se aplica à forma básica da função harmônica chamamos de "zero a pico". A gama total de variação do sinal, de $-X$ a X , ou seja $2X$, é chamada amplitude de "pico a pico". A raiz do valor médio quadrático do sinal também é usada para caracterizar a amplitude com a abreviatura do termo equivalente em inglês, RMS ("Root Mean Square"). Para sinais periódicos temos:

$$RMS = \left(\lim_{\tau \rightarrow \infty} \frac{1}{\tau} \int_{-\tau/2}^{\tau/2} x^2(t) dt \right)^{1/2} = \left(\frac{1}{T} \int_{-T/2}^{T/2} x^2(t) dt \right)^{1/2} = \frac{X}{\sqrt{2}} \quad (1.3)$$

A fase da senóide é uma característica de importância menor, uma vez que depende unicamente da maneira como é tomado o início dos tempos. O conceito importante é a defasagem ou diferença entre as fases de dois sinais da mesma frequência. Na figura 1.1 a defasagem entre os sinais independe da origem da escala do tempo e vale β graus.

Os sinais físicos que se podem medir não são, via de regra, tão simples. Algumas vezes eles são uma combinação de senóides, mas sem perder o caráter periódico, como é o caso do sinal mostrado na figura 1.2.a. Podemos ainda ter sinais que não perduram no tempo, fruto de fenômenos transitórios, tais como impactos e descontinuidades de operação, como o sinal mostrado na figura 1.2.b. Chamaremos de transitório este tipo de sinal, que tem existência apenas num período limitado de tempo, ou que concentra sua energia num tempo finito (ver condições de existência da integral de Fourier), podendo ser truncado sem perda significativa de informação.




figura 1.2. (a) Sinal periódico. (b) Sinal transitório.

Os dois tipos de sinal comentados acima, periódicos e transitórios, geralmente podem ser razoavelmente representados por expressões matemáticas e são por isso chamados determinísticos. Ao contrário, existem sinais para os quais é impossível ou muito grosseiro representá-los por funções matemáticas. Estes sinais são chamados aleatórios e só podem ser estudados por suas propriedades médias ou estatísticas.

Neste capítulo, trataremos dos sinais determinísticos para os quais o Barão Jean-Baptiste-Joseph Fourier (matemático Francês que viveu no período de 1768 a 1830) nos deu as ferramentas básicas, que são a Série e a Transformada de Fourier.

Exporemos, ainda, alguns teoremas, fórmulas e propriedades básicas da análise de sinais determinísticos, que são: o teorema da Convolução ou de Borel, o teorema de Parseval ou da energia, a fórmula de Poisson, a distribuição de Dirac e as "janelas" no tempo.

1.1 Série de Fourier

Todo sinal periódico $x(t)$ que obedeça as condições de Diritchlet, ou seja:

$$x(t) = x(t \pm nT), \quad n = 0, 1, 2, \dots$$

a.
$$\int_{-T/2}^{T/2} |x(t)| dt < \infty \quad (1.4)$$

b. número finito de descontinuidades num período T

c. número finito de máximos e mínimos locais num período T

pode ser expandido numa série trigonométrica infinita (série de Fourier) da forma:

$$x(t) = \frac{a_0}{2} + \sum_{n=1}^{\infty} (a_n \cos(n\omega_o t) + b_n \sin(n\omega_o t)) \quad (1.5)$$

onde $\omega_o = 2\pi/T$, os termos a_n e b_n podem ser obtidos utilizando-se as seguintes propriedades das funções trigonométricas:

a.
$$\int_{-T/2}^{T/2} \cos(n\omega_o t) \cos(m\omega_o t) dt = \begin{cases} 0, & m \neq n \\ \pi / \omega_o, & m = n \end{cases}$$

b.
$$\int_{-T/2}^{T/2} \sin(n\omega_o t) \sin(m\omega_o t) dt = \begin{cases} 0, & m \neq n \\ \pi / \omega_o, & m = n \end{cases}$$

c.
$$\int_{-T/2}^{T/2} \cos(n\omega_o t) \sin(m\omega_o t) dt = 0$$

Multiplicando (1.5) por $\cos(m\omega_o t)$, integrando num período e utilizando as propriedades acima, temos:

$$\int_{-T/2}^{T/2} x(t) \cos(m\omega_o t) dt = a_m \int_{-T/2}^{T/2} \cos(m\omega_o t) \cos(m\omega_o t) dt = a_m \frac{\pi}{\omega_o}$$

Donde, procedendo analogamente com $\sin(n\omega_o t)$, pode-se escrever as fórmulas de Euler-Fourier:

$$\begin{aligned} a_n &= \frac{2}{T} \int_{-T/2}^{T/2} x(t) \cos(n\omega_o t) dt, \quad n = 0, 1, 2, \dots \\ b_n &= \frac{2}{T} \int_{-T/2}^{T/2} x(t) \sin(n\omega_o t) dt, \quad n = 1, 2, \dots \end{aligned} \quad (1.6)$$

Para a análise de sinais, é mais conveniente formular a série de Fourier na chamada forma exponencial. Da representação no plano complexo na forma exponencial (figura 1.3) temos:

$$e^{\pm in\omega_o t} = \cos(n\omega_o t) \pm i \sin(n\omega_o t) \quad (1.7)$$

onde $i = \sqrt{-1}$; daí podemos escrever:

$$a_n \cos(n\omega_o t) + b_n \sin(n\omega_o t) = \frac{a_n - ib_n}{2} e^{in\omega_o t} + \frac{a_n + ib_n}{2} e^{-in\omega_o t}$$




figura 1.3. Plano complexo e forma exponencial.

Chamando:

$$\alpha_n = \frac{a_n - ib_n}{2}, \quad \alpha_{-n} = \frac{a_n + ib_n}{2}, \quad \alpha_o = \frac{a_o}{2} \quad (1.8)$$

podemos chegar à forma exponencial:

$$x(t) = \sum_{n=-\infty}^{\infty} \alpha_n e^{in\omega_o t} \quad (1.9)$$

e as fórmulas de Euler-Fourier se condensam em:

$$\alpha_n = \frac{1}{T} \int_{-T/2}^{T/2} x(t) e^{-in\omega_o t} dt \quad (1.10)$$

A série de Fourier pode ter como forma de representação gráfica o que chamaremos espectro de frequências de raios. Para construir o espectro associamos a cada coeficiente complexo α_n a frequência correspondente do termo da série: $n\omega_o$ (rad/seg) ou $f_n = n\omega_o/2\pi$. Porém, na forma exponencial, aparecem frequências negativas que não têm significado físico, mas apenas utilidade matemática. Associando-se o conceito do vetor girante, temos que os pares de termos:

$$\alpha_n e^{i2\pi nt/T} + \alpha_{-n} e^{-i2\pi nt/T}$$

representam dois vetores da mesma amplitude $|\alpha_n| = |\alpha_{-n}|$ e fases opostas $\angle \alpha_n = -\angle \alpha_{-n}$ (vide equação (1.8)) girando em direções opostas com a mesma frequência angular. Deste modo, as componentes imaginárias se anulam (figura 1.4).




figura 1.4. Interpretação das frequências negativas.

Como forma final da série de Fourier adotaremos a notação:

$$X(f_k) = \alpha_k = |X(f_k)| e^{i\angle X(f_k)}, k \text{ inteiro} \quad (1.11)$$

onde

$$X(f_k) = \frac{1}{T} \int_{-T/2}^{T/2} x(t) e^{-i2\pi kt/T} dt \quad (1.12)$$

com

$$x(t) = \sum_{k=-\infty}^{\infty} X(f_k) e^{i2\pi kt/T}, \text{ onde } f_k = k/T \quad (1.13)$$

Podemos interpretar a equação (1.12) como a forma de transformar o sinal periódico $x(t)$ do domínio do tempo para o domínio da frequência, e a equação (1.13) o inverso. Esta forma é útil na comparação com a transformada de Fourier que veremos a seguir.

Exemplo 1

Tomemos, por exemplo uma onda quadrada como mostrada na figura 1.5 (a). Aplicando a equação (1.12) temos:

$$\begin{aligned}
 X(f_k) &= \frac{1}{T} \int_{-T/2}^0 (-A) e^{-i2\pi kt/T} dt + \frac{1}{T} \int_0^{T/2} A e^{-i2\pi kt/T} dt \\
 &= -\frac{A}{T} \frac{T}{2\pi k} [\sin(2\pi kt/T) + i \cos(2\pi kt/T)]_{-T/2}^0 + \\
 &\quad \frac{A}{T} \frac{T}{2\pi k} [\sin(2\pi kt/T) + i \cos(2\pi kt/T)]_0^{T/2} \\
 &= \begin{cases} 0, & k \text{ par} \\ -\frac{i2A}{\pi k}, & k \text{ impar} \end{cases}
 \end{aligned}$$

$$\text{ou seja, } |X(f_k)| = \begin{cases} 0, & k \text{ par} \\ \frac{2A}{\pi k}, & k \text{ impar} \end{cases} \quad \text{e} \quad \angle X(f_k) = \begin{cases} \text{indefinida}, & k \text{ par} \\ -\text{sinal}(k) \frac{\pi}{2}, & k \text{ impar} \end{cases}$$

$$\text{onde } \text{sinal}(k) = \begin{cases} +1, & k \geq 0 \\ -1, & k < 0 \end{cases}$$




figura 1.5. (a) Onda quadrada. (b) Espectro de amplitudes. (c) Espectro de fase.

1.2 Teorema de energia (ou de Parseval)

Chama-se de energia do sinal a integral de seu valor absoluto ao quadrado, isto é,

$$E = \int_{-\infty}^{+\infty} |x(t)|^2 dt$$

No caso de sinais periódicos, este valor é infinito. Neste caso, pode-se definir a potência do sinal, ou taxa de variação da energia no tempo:

$$P = \frac{1}{T} \int_{-T/2}^{T/2} |x(t)|^2 dt$$

O teorema da energia para sinais periódicos pode, então, ser expresso em termos da potência do sinal.

Se

$$x(t) = \sum_{k=-\infty}^{\infty} X(f_k) e^{i2\pi kt/T},$$

então

$$\frac{1}{T} \int_{-T/2}^{T/2} |x(t)|^2 dt = \sum_{k=-\infty}^{\infty} |X(f_k)|^2 \quad (1.14)$$

ou seja, a potência contida no sinal independe da sua representação (no tempo ou em frequência).

Demonstração: Temos que

$$\frac{1}{T} \int_{-T/2}^{T/2} |x(t)|^2 dt = \frac{1}{T} \int_{-T/2}^{T/2} x(t) x^*(t) dt \quad (1.15)$$

onde * denota o conjugado de um complexo¹.

Substituindo a equação (1.13) na equação (1.15) e desenvolvendo pode-se chegar a:

$$\frac{1}{T} \int_{-T/2}^{T/2} |x(t)|^2 dt = \sum_{n=-\infty}^{\infty} \sum_{m=-\infty}^{\infty} X(f_n) X^*(f_m) \left[\frac{1}{T} \int_{-T/2}^{T/2} e^{i2\pi(n-m)t/T} dt \right]$$

e, devido à ortogonalidade das funções trigonométricas:

¹ Na análise de sinais aplicada ao estudo experimental de fenômenos físicos os sinais são sempre reais. Porém, como muitos dos resultados neste texto valem para o caso geral de sinais complexos, procuraremos manter a generalidade sempre que isto não prejudicar a compreensão.

$$\frac{1}{T} \int_{-T/2}^{T/2} e^{i2\pi(n-m)t/T} dt = \begin{cases} 0, & n \neq m \\ 1, & n = m \end{cases}$$

donde:

$$\frac{1}{T} \int_{-T/2}^{T/2} x(t) dt = \sum_{n=-\infty}^{\infty} X(f_n) X^*(f_n) = \sum_{n=-\infty}^{\infty} |X(f_n)|^2$$

1.3 Transformada de Fourier

Todo sinal $x(t)$ transitório que satisfaz as condições de Diritchlet em todo intervalo finito, e tal que $\int_{-\infty}^{\infty} x(t) dt$ existe, pode ser expresso da forma:

$$x(t) = \int_{-\infty}^{\infty} X(f) e^{i2\pi ft} df \quad (1.16)$$

onde:

$$X(f) = \int_{-\infty}^{\infty} x(t) e^{-i2\pi ft} dt \quad (1.17)$$

Este par de transformações lineares, transformada de Fourier direta $x(t) \xrightarrow{\tilde{f}} X(f)$, equação (1.17), e inversa $X(f) \xrightarrow{\tilde{f}^{-1}} x(t)$, equação (1.16), permitem a representação de um sinal no domínio das frequências ou no domínio do tempo.

Dada a semelhança destas equações com as equações (1.12) e (1.13), pode-se interpretar a transformada ou integral de Fourier como um limite da série com T , período de $x(t)$, tendendo a infinito.

Chamando a distância entre duas raiais do espectro discreto $\Delta f = 1/T$, podemos escrever de (1.12):

$$X(k\Delta f) = \Delta f \int_{-T/2}^{T/2} x(t) e^{-i2\pi k\Delta f t} dt \quad (1.18)$$

e, substituindo em (1.13):

$$x(t) = \sum_{k=-\infty}^{\infty} \left[\Delta f \int_{-T/2}^{T/2} x(t) e^{-i2\pi k\Delta f t} dt \right] e^{i2\pi k\Delta f t} \quad (1.19)$$

Fazendo $T \rightarrow \infty$; $\Delta f \rightarrow df$; $k\Delta f \rightarrow f$, temos:

$$x(t) = \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} x(t) e^{-i2\pi f t} dt \right] e^{i2\pi f t} df \quad (1.20)$$

De (1.20) pode-se tirar o par de transformações das equações (1.16) e (1.17). Este processo é ilustrado na figura 1.6.




figura 1.6. Transformada de Fourier como limite da série.

Exemplo 2

Tomemos, por exemplo, a função porta como mostrada na figura 1.7 (a). Aplicando (1.17) temos:

$$\begin{aligned} X(f) &= \int_0^{\tau} A e^{-i2\pi f t} dt = \frac{A}{-i2\pi f} \left[e^{-i2\pi f t} \right]_0^{\tau} \\ &= \frac{iA}{2\pi f} e^{-i\pi f \tau} \left[e^{-i\pi f \tau} - e^{i\pi f \tau} \right] \\ &= A\tau \frac{\sin(\pi f \tau)}{\pi f \tau} e^{-i\pi f \tau} = A\tau \operatorname{sinc}(\pi f \tau) e^{-i\pi f \tau} \end{aligned}$$

donde

$$|X(f)| = A\tau |\operatorname{sinc}(\pi f \tau)| \text{ e } \angle X(f) = \tan^{-1}(\tan(-\pi f \tau))$$

Note que a expressão obtida para a fase não é trivial. Pela expressão obtida para $X(f)$ temos que a fase é dada pela soma da fase correspondente ao sinal da função *sinc* (0 se

positivo e π se negativo) com a fase da exponencial de módulo unitário, $e^{-i\pi f\tau}$; ou seja, soma-se π à expressão $-\pi f\tau$ sempre que o sinal da função *sinc* é negativo. A expressão acima é uma forma elegante de expressar este resultado.




figura 1.7. (a) Função porta. (b) Espectro de amplitudes. (c) Espectro de fase

A denominação espectro será empregada neste texto para qualquer representação no domínio da frequência de um sinal, quer ele seja periódico, transitório ou, como veremos em capítulos posteriores, aleatório.

É interessante notar que, como na série de Fourier, para sinais $x(t)$ reais a transformada de Fourier é, em amplitude, uma função par e, em fase, uma função ímpar, o que se pode deduzir de:

$$X(-f) = \int_{-\infty}^{\infty} x(t) e^{i2\pi ft} dt = X^*(f) \quad (1.21)$$

1.4 Distribuição de Dirac e pseudo-transformada

Chamada também delta de Dirac ou função delta, $\delta(t)$, é uma função generalizada, ou distribuição. Como só utilizaremos neste texto a distribuição delta de Dirac e a função degrau unitário ou de Heaviside, não cabem maiores comentários sobre a teoria de distribuições e as funções de singularidade. $\delta(t)$ é definida tal que:

$$\delta(t) = \begin{cases} 0, & t \neq 0 \\ +\infty, & t = 0 \end{cases}$$

$$\int_a^b \delta(t) dt = 1, \quad a < t < b \quad (1.22)$$

$$\int_a^b x(t) \delta(t - \tau) dt = x(\tau), \quad a < \tau < b$$

Então, temos que:

$$\delta(f - f_o) \xrightarrow{\tilde{f}^{-1}} e^{i2\pi f_o t} \quad (1.23)$$

pois, de (1.16):

$$\int_{-\infty}^{\infty} \delta(f - f_o) e^{i2\pi f t} df = e^{i2\pi f_o t}$$

A distribuição $\delta(t)$ pode ser melhor compreendida como o limite de uma função porta $\Pi_{\tau}^{1/\tau}(t)$ de amplitude $1/\tau$ e duração τ , ou seja, de área unitária (vide figura 1.8).

$$\Pi_{\tau}^{1/\tau}(t) = \begin{cases} 0, & t < 0 \\ 1/\tau, & 0 \leq t \leq \tau \\ 0, & t > \tau \end{cases} \quad (1.24)$$

$$\delta(t) = \lim_{\tau \rightarrow 0} \Pi_{\tau}^{1/\tau}(t)$$




figura 1.8. Distribuição de Dirac e sua representação gráfica. (a) Função porta.

(b) Distribuição.

Note que no exemplo 2 o sinal $x(t) = \Pi_T(t)$, ou seja, é uma função porta de amplitude unitária. A partir da propriedade (1.23) podemos obter uma pseudo-transformada de Fourier de sinais periódicos pois, se $x(t)$ é periódica:

$$x(t) = \sum_{k=-\infty}^{\infty} X(f_k) e^{i2\pi k t / T} \quad (1.25)$$

aplicando (1.23) e (1.17), temos para um sinal periódico:

$$X(f) = \sum_{k=-\infty}^{\infty} X(f_k) \delta(f - f_k) \quad (1.26)$$

Exemplo 3

Pseudo-transformada da senóide.

Seja

$$x(t) = \sin(2\pi f_0 t) = \frac{e^{i2\pi f_0 t} - e^{-i2\pi f_0 t}}{2i}$$

Aplicando (1.23) e (1.17), podemos chegar a:

$$X(f) = \frac{i}{2} [\delta(f + f_0) - \delta(f - f_0)]$$

Analogamente, para

$$x(t) = \cos(2\pi f_0 t)$$

teríamos

$$X(f) = \frac{1}{2} [\delta(f + f_0) + \delta(f - f_0)]$$

1.5 Teorema da convolução

Definimos a integral, ou produto de convolução de duas funções (ou sinais) $x(t)$ e $h(t)$:

$$x(t) * h(t) = \int_{-\infty}^{\infty} x(\tau) h(t - \tau) d\tau \quad (1.27)$$

Assim definida, a integral de convolução tem as seguintes propriedades quando associada à transformada de Fourier (teorema):

$$\begin{aligned} x(t) * h(t) &\xrightarrow{\tilde{f}} X(f) H(f) \\ x(t)h(t) &\xrightarrow{\tilde{f}} X(f) * H(f) \end{aligned} \quad (1.28)$$

onde, $X(f)$ e $H(f)$ são as transformadas de $x(t)$ e $h(t)$, respectivamente.

Demonstração:

Substituindo (1.27) em (1.17):

$$\begin{aligned} \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} x(\tau) h(t - \tau) d\tau \right] e^{-i2\pi f t} dt = \\ \int_{-\infty}^{\infty} x(\tau) \left[\int_{-\infty}^{\infty} h(t - \tau) e^{-i2\pi f t} dt \right] d\tau \end{aligned}$$

mas temos que, para um deslocamento ao longo do eixo do tempo de uma função (“shift”):

$$\int_{-\infty}^{\infty} x(t - \tau) e^{-i2\pi f t} dt = X(f) e^{-i2\pi f \tau} \quad (1.29)$$

o que é facilmente obtido por substituição de variáveis, por exemplo $t - \tau = \alpha$.

Substituindo (1.29) na equação anterior temos:

$$= \int_{-\infty}^{\infty} x(\tau) e^{-i2\pi f \tau} d\tau H(f) = X(f) H(f)$$

A demonstração de (1.28) é deixada ao leitor como exercício.

Exemplo 4

Seja a função “porta” definida como

$$x(t) = \Pi_{\tau}(t) = \begin{cases} 0, & t < 0 \\ 1, & 0 \leq t \leq \tau \\ 0, & t > \tau \end{cases}$$

então, a sua representação no domínio da frequência será

$$X(f) = \Pi_{\tau}(f) = \frac{\sin(2\pi f \tau)}{\pi f} e^{-i\pi f \tau}$$

E seja a função senoidal definida como

$$h(t) = \sin(2\pi f_0 t) = \frac{e^{i2\pi f_0 t} - e^{-i2\pi f_0 t}}{2i}$$

então, a sua representação no domínio da frequência será

$$H(f) = \frac{i}{2} [\delta(f + f_0) - \delta(f - f_0)]$$

Logo, utilizando a segunda relação da equação (1.28), isto é, o produto no domínio do tempo corresponde à convolução no domínio da frequência, podemos calcular a transformada do produto da função “porta” pela senóide.

A figura 1.9 ilustra o exemplo de convolução no domínio da frequência. Observa-se que na figura superior tem-se a função “porta” no domínio do tempo e o seu espectro no domínio da frequência; na figura do meio é apresentada uma função senóide de frequência f_0 e de duração infinita, e à direita o seu espectro; e na figura inferior é apresentada a função resultado do produto entre a função “porta” e a função senóide, o qual corresponde à convolução no domínio da frequência.

$$X(f) * H(f) = \frac{1}{2} i \Pi_{\tau}(f + f_0) - \frac{1}{2} i \Pi_{\tau}(f - f_0)$$




figura 1.9. Exemplo de convolução no domínio da frequência .

Exemplo 5

Este segundo exemplo mostra a convolução no domínio do tempo. Seja a função “porta” definida como

$$x(t) = \Pi_{\tau}(t) = \begin{cases} 0, & t < -\tau/2 \\ 1, & -\tau/2 \leq t \leq \tau/2 \\ 0, & t > \tau/2 \end{cases}$$

então, a sua representação no domínio da frequência será

$$X(f) = \Pi_{\tau}(f) = \frac{\sin(2\pi f \tau)}{\pi f} e^{-i\pi f \tau}$$

E seja a função composta de uma série de impulsos de período T

$$h(t) = \sum_{n=-\infty}^{\infty} \delta(t + nT)$$

A representação de $h(t)$ como uma série de impulsos é também uma função periódica de período $T = 1/f_o$ e, assim, pode ser escrita, de (1.26), como:

$$H(f) = \frac{1}{T} \sum_{n=-\infty}^{\infty} \delta(f - nf_o)$$

Já que os termos da série de Fourier de $h(t)$ são todos iguais a $1/T$.

A convolução no domínio do tempo $x(t)*h(t)$ pode ser obtida através da transformada inversa de Fourier do produto das transformadas de Fourier das funções $x(t)$ e $h(t)$.

A figura 1.10 ilustra graficamente o exemplo da convolução no domínio do tempo. Na parte superior esquerda está a função “porta” de comprimento τ e à direita está o espectro da função “porta”. A seguir está a série de impulsos de período T e à direita está o espectro da série que também é outra série de impulsos de período $1/T$. Na parte inferior está a convolução da função “porta” e a série de impulsos. Pode-se observar que o resultado da convolução é uma série de “portas” de período igual à da série de impulsos. O espectro da convolução da função “porta” e da série de impulsos resulta ser o produto dos espectros da função “porta” e da série de impulsos.




figura 1.10. Exemplo de convolução no domínio do tempo .

1.6 Teorema da energia

Também para a transformada de Fourier podemos formular um teorema de energia:

$$\int_{-\infty}^{\infty} |x(t)|^2 dt = \int_{-\infty}^{\infty} |X(f)|^2 df \quad (1.30)$$

Demonstração:

De (1.27) e (1.28) temos que, aplicando (1.16) no segundo membro:

$$\int_{-\infty}^{\infty} x(\tau) g(t - \tau) d\tau = \int_{-\infty}^{\infty} X(f) G(f) e^{i2\pi ft} df \quad (1.31)$$

com $t = 0$ temos:

$$\int_{-\infty}^{\infty} x(\tau) g(-\tau) d\tau = \int_{-\infty}^{\infty} X(f) G(f) df \quad (1.32)$$

Fazendo, $g(-t) = h^*(t)$, temos que:

$$H^*(f) = \int_{-\infty}^{\infty} h^*(t) e^{i2\pi ft} dt = \int_{-\infty}^{\infty} g(-t) e^{i2\pi ft} dt \quad (1.33)$$

com $\tau = -t$, podemos chegar a:

$$H^*(f) = \int_{-\infty}^{\infty} g(\tau) e^{-i2\pi f\tau} d\tau = G(f) \quad (1.34)$$

de maneira que a equação (1.32) fica:

$$\int_{-\infty}^{\infty} x(t)h^*(t) dt = \int_{-\infty}^{\infty} X(f)H^*(f) df \quad (1.35)$$

então:

$$\int_{-\infty}^{\infty} x(t)x^*(t) dt = \int_{-\infty}^{\infty} X(f)X^*(f) df$$

1.7 Outra demonstração da transformada de Fourier

Agora podemos mostrar que $x(t) \xleftrightarrow{\tilde{f}} X(f)$, ou seja, que se:

$$X(f) = \int_{-\infty}^{\infty} x(t)e^{-i2\pi ft} dt$$

então:

$$x(t) = \int_{-\infty}^{\infty} X(f)e^{i2\pi ft} df$$

Demonstração: Substituindo (1.17) em (1.16):

$$x(t) = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x(\tau)e^{-i2\pi f\tau} d\tau \right) e^{i2\pi ft} df$$

mas:

$$\begin{aligned} \int_{-\infty}^{\infty} e^{i2\pi ft} df &= \lim_{a \rightarrow \infty} \int_{-a}^a e^{i2\pi ft} df = \lim_{a \rightarrow \infty} \left[\frac{e^{i2\pi ft}}{i2\pi t} \right]_{-a}^a = \lim_{a \rightarrow \infty} \frac{1}{\pi t} \left[\frac{e^{i2\pi at} - e^{-i2\pi at}}{2i} \right] \\ &= \lim_{a \rightarrow \infty} \frac{\sin(2\pi at)}{\pi t} = \lim_{b \rightarrow \infty} \frac{\sin(bt)}{\pi t} \end{aligned} \quad (1.36)$$

onde $b = 2\pi a$.




figura 1.11. Representação gráfica da expressão (1.37).

Ora, mas é bem conhecido que:

$$\int_{-\infty}^{\infty} \frac{\sin(bt)}{\pi t} dt = 1, \text{ e} \quad (1.37)$$

$$\lim_{b \rightarrow \infty} \int_{-\infty}^{\infty} \frac{\sin(bt)}{\pi t} y(t) dt = y(0) \lim_{b \rightarrow \infty} \int_{-\infty}^{\infty} \frac{\sin(bt)}{\pi t} dt = y(0) \quad (1.38)$$

então:

$$\lim_{b \rightarrow \infty} \frac{\sin(bt)}{\pi t} = \delta(t) \quad (1.39)$$

A figura 1.11 mostra graficamente a expressão (1.40). Deste resultado resulta que:

$$\int_{-\infty}^{\infty} e^{i2\pi f(t-\tau)} df = \delta(t-\tau)$$

e, finalmente,

$$\int_{-\infty}^{\infty} x(\tau) \delta(t-\tau) d\tau = x(t)$$

1.8 Fórmula de Poisson

Chamada também de função “pente”, a soma infinita de distribuições de Dirac $\delta(t)$ espaçadas de T , ou seja:

$$\sum_{n=-\infty}^{\infty} \delta(t+nT)$$

é uma função periódica e como tal pode ser expandida em série de Fourier de coeficientes (equação (1.12)) :

$$X(kf_o) = \frac{1}{T} \int_{-T/2}^{T/2} \delta(t) e^{-i2\pi k f_o t} dt = \frac{1}{T}$$

onde $f_o = 1/T$. Note que $\delta(t)$ é igual à soma infinita $\sum_{n=-\infty}^{\infty} \delta(t+nT)$ no intervalo $(-T/2, T/2)$.

Temos então que:

$$\sum_{n=-\infty}^{\infty} \delta(t+nT) = \frac{1}{T} \sum_{k=-\infty}^{\infty} e^{i2\pi k t / T} \quad (1.41)$$

Mas, das equações (1.23) e (1.41) temos que:

$$\sum_{n=-\infty}^{\infty} \delta(t + nT) \xleftrightarrow{\tilde{f}} \frac{1}{T} \sum_{n=-\infty}^{\infty} \delta(f - nf_o)$$

Do teorema da convolução, multiplicar por $X(f)$ em frequência equivale a fazer a convolução com $x(t)$ no tempo, com $x(t) \xleftrightarrow{\tilde{f}} X(f)$.

$$\int_{-\infty}^{\infty} \sum_{n=-\infty}^{\infty} \delta(\tau + nT) x(t - \tau) d\tau \xleftrightarrow{\tilde{f}} X(f) \frac{1}{T} \sum_{n=-\infty}^{\infty} \delta(f - nf_o)$$

Usando as propriedades da distribuição δ e fazendo a transformação inversa (1.16):

$$\begin{aligned} \int_{-\infty}^{\infty} X(f) \frac{1}{T} \sum_{n=-\infty}^{\infty} \delta(f - nf_o) e^{i2\pi ft} df &= \\ \frac{1}{T} \sum_{n=-\infty}^{\infty} \int_{-\infty}^{\infty} X(f) e^{i2\pi ft} \delta(f - nf_o) df &= \\ \frac{1}{T} \sum_{n=-\infty}^{\infty} X(nf_o) e^{i2\pi nf_o t} & \end{aligned}$$

de onde temos finalmente a fórmula de Poisson:

$$T \sum_{n=-\infty}^{\infty} x(t + nT) = \sum_{n=-\infty}^{\infty} X(nf_o) e^{i2\pi nf_o t} \quad (1.42)$$

De (1.42) podemos interpretar que os valores discretos $X(nf_o)$ amostrados da função contínua $X(f)$ são os coeficientes da série de Fourier da função periódica $T \sum_{n=-\infty}^{\infty} x(t + nT)$.

1.9 Janelas de observação

A definição da transformada de Fourier pela expressão (1.17) implica numa dificuldade de obtenção prática devido aos limites de integração. Como os sinais tratados provêm da observação de fenômenos físicos, eles terão um início e um término dentro de limites finitos no tempo. Isto implica, matematicamente, no truncamento do sinal.

Consideremos, por exemplo, uma senóide com duração τ . Matematicamente, é o mesmo que multiplicar a senóide $\sin(2\pi f_o t)$ por uma função “porta” de amplitude unitária e duração τ .

$$x'(t) = x(t) \Pi_\tau(t), \quad \Pi_\tau(t) = \begin{cases} 0, & t < 0 \\ 1, & 0 \leq t \leq \tau \\ 0, & t > \tau \end{cases}$$

É como se estivéssemos observando a senóide através de uma janela “retangular”.




figura 1.12. (a) Senóide observada com janela retangular. (b) Sua transformada de Fourier

Pelo teorema da convolução, esta multiplicação no tempo corresponde a fazer na frequência a convolução da transformada da senóide com a transformada da função “porta” (vide exemplo 2).

$$X'(f) = \tau \frac{\sin(\pi f \tau)}{\pi f \tau} e^{-i\pi f \tau} * \left\{ \frac{1}{2} i [\delta(f + f_o) - \delta(f - f_o)] \right\}$$

Aplicando as propriedades da distribuição δ :

$$\begin{aligned} X'(f) &= \int_{-\infty}^{\infty} \Pi_\tau(f - \zeta) \left\{ \frac{1}{2} i [\delta(\zeta + f_o) - \delta(\zeta - f_o)] \right\} d\zeta = \\ &= \frac{1}{2} i \Pi_\tau(f + f_o) - \frac{1}{2} i \Pi_\tau(f - f_o) \end{aligned}$$

onde $\Pi_\tau(f)$ é a transformada de $\Pi_\tau(t)$. O valor absoluto de $X'(f)$ é mostrado na figura (1.11).

De forma geral, dada a janela $p(t)$ de transformada $P(f)$ e um sinal $x(t)$ observado através dela, temos:

$$x'(t) = x(t)p(t) \xrightarrow{\tilde{f}} X'(f) = X(f) * P(f) \quad (1.43)$$

Para a janela retangular, ou seja, o sinal truncado com duração τ ,

$$X'(f) = \int_{-\infty}^{\infty} X(f - \zeta) \tau \frac{\sin(\pi \zeta \tau)}{\pi \zeta \tau} e^{-i\pi \zeta \tau} d\zeta \quad (1.44)$$

É fácil imaginar que, se o sinal truncado tem componentes de frequências vizinhas, os lóbulos laterais introduzirão erros nas amplitudes. Na figura 1.13, são mostradas: em linha tracejada as transformadas de Fourier de duas senóides truncadas, de frequências f_1 e f_2 (f_1 é vizinha de f_2); e em linha cheia a transformada de Fourier formada pela soma das duas senóides. Como se pode observar, a transformada do sinal composto apresenta um erro de amplitude causado pela interferência dos lóbulos laterais dos espectros das senóides.




figura 1.13. Efeito dos lóbulos laterais devidos ao truncamento no valor das amplitudes para um sinal composto de duas senóides de frequências vizinhas.

Para atenuar este problema, podem-se utilizar outras formas de janela (figura 1.14), onde uma diminuição das amplitudes das ondulações laterais é conseguida ao preço de uma menor precisão na medida da frequência, pois o lóbulo principal fica mais largo.




figura 1.14. Formas de janela e ondulações produzidas. (a) Retangular. (b) Hanning. (c) Hamming.

As janelas são geralmente normalizadas, de modo que:

$$p(0) = \int_{-\infty}^{\infty} P(f) df = 1 \quad (1.45)$$

Nos analisadores modernos, a janela mais utilizada é a de Hanning, que tem a expressão:

$$p(t) = \begin{cases} 0, & t < -\frac{\tau}{2} \\ \cos^2\left(\frac{\pi t}{\tau}\right), & -\frac{\tau}{2} \leq t \leq \frac{\tau}{2} \\ 0, & t > \frac{\tau}{2} \end{cases} \quad (1.46)$$

para chegar à sua transformada $P(f)$ podemos fazer:

$$\cos^2\left(\frac{\pi t}{\tau}\right) = \frac{1}{2} + \frac{1}{2} \cos\left(\frac{2\pi t}{\tau}\right) = \frac{1}{2} + \frac{1}{4} e^{i2\pi t/\tau} + \frac{1}{4} e^{-i2\pi t/\tau}$$

e aplicando (1.17) com:

$$p(t) = \cos^2\left(\frac{\pi t}{\tau}\right) \Pi_{\tau}(t)$$

temos:

$$P(f) = \int_{-\infty}^{\infty} \left(\frac{1}{2} + \frac{1}{4} e^{i2\pi t/\tau} + \frac{1}{4} e^{-i2\pi t/\tau} \right) \Pi_{\tau}(t) e^{-i2\pi f t} dt$$

e sendo $\Pi_\tau(f) \xleftrightarrow{\tilde{f}} \Pi_\tau(t)$ temos finalmente:

$$P(f) = \frac{1}{4} \Pi_\tau\left(f - \frac{1}{\tau}\right) + \frac{1}{2} \Pi_\tau(f) + \frac{1}{4} \Pi_\tau\left(f + \frac{1}{\tau}\right) \quad (1.47)$$

A figura 1.15, mostra uma comparação de $\Pi_\tau(f)$ e $P(f)$ de Hanning. Pode-se observar que o lóbulo central da janela de Hanning é mais largo que o da janela retangular. Entretanto, os lóbulos laterais da janela Hanning são consideravelmente atenuados, se comparados com os da janela retangular.




figura 1.15. Comparação de $|\Pi_\tau(f)|$ e $|P(f)|$.

1.10 Modulação em amplitude

Consideremos um sinal transitório $x(t)$. Podemos usar este sinal para modular uma senóide de frequência f_o , ou seja, fazer o produto:

$$m(t) = x(t) \cos(2\pi f_o t) = x(t) \left(\frac{e^{i2\pi f_o t} + e^{-i2\pi f_o t}}{2} \right)$$

A transformada de Fourier deste produto será:

$$M(f) = \int_{-\infty}^{\infty} x(t) \left(\frac{e^{i2\pi f_o t} + e^{-i2\pi f_o t}}{2} \right) e^{-i2\pi f t} dt$$

que pode ser desdobrado em:

$$M(f) = \frac{1}{2} \int_{-\infty}^{\infty} x(t) e^{-i2\pi(f+f_o)t} dt + \frac{1}{2} \int_{-\infty}^{\infty} x(t) e^{-i2\pi(f-f_o)t} dt$$

que em termos de $X(f)$, transformada de $x(t)$, fica:

$$M(f) = \frac{1}{2} [X(f + f_o) + X(f - f_o)] \quad (1.48)$$

ou seja, a modulação provoca um desdobramento e um deslocamento do espectro de $+f_o$ e $-f_o$ (figura 1.16).




figura 1.16. Efeito de deslocamento devido à modulação.

Para evitar o desdobramento do espectro podemos multiplicar um sinal real pela exponencial complexa $e^{i2\pi f_o t}$, o que significa criar um sinal complexo $x_{desl}(t)$:

$$x_{desl}(t) = x(t) \cos(2\pi f_o t) + i x(t) \sin(2\pi f_o t) \quad (1.49)$$

Sendo assim sua transformada fica:

$$X_{desl}(f) = \int_{-\infty}^{\infty} x(t) e^{i2\pi f_o t} e^{-i2\pi f t} dt = X(f - f_o) \quad (1.50)$$

ou seja, o efeito é apenas um deslocamento do eixo das frequências ("shift").


1.11 Exercícios

1.1 Obter a série de Fourier da função $f(t) = t - \pi$ no intervalo $(0, 2\pi)$ e $f(t+2n\pi) = f(t)$, n inteiro.


1.2 Calcular a série de Fourier da função $f(t) = \exp(t)$ no intervalo $(0, 2\pi)$ e $f(t+2n\pi) = f(t)$, n inteiro.

1.3 Demonstrar que a função $f(t) = e^{2\cos(t)} \cos(2\sin(t))$ pode ser expandida em uma série de Fourier dada por $1 + \sum_{n=1}^{\infty} \frac{2^n}{n!} \cos(nt)$


1.4 Calcular os coeficientes da série de Fourier complexa para uma onda quadrada de período T e amplitude pico-a-pico A mostrada na figura abaixo:



1.5 Calcular os coeficientes da série de Fourier complexa para a onda de período T e amplitude pico-a-pico A mostrada na figura abaixo:



1.6 Calcular a transformada (integral) de Fourier do pulso retangular abaixo. Se possível, traçar os resultados dos itens anteriores usando o programa MATLAB (traçar somente os valores absolutos).



1.7 Provar o teorema da convolução na forma:


$$x(t)h(t) \Leftrightarrow X(f) * H(f)$$

1.8 Mostrar que os coeficientes da Série de Fourier podem ser aproximados pela expressão:


$$X_k = \frac{1}{N} \sum_{n=0}^{N-1} x_n e^{-i2\pi kn/N}$$

1.9 Calcular a série de Fourier de um sinal do tipo dente de serra usando a aproximação acima e comparar com a Série de Fourier analítica. Comparar os espectros graficamente.

Usar $A = 3$ e $T = 7$



1.10 Calcular a Transformada de Fourier de um pulso triangular (um período do sinal do item anterior) usando a aproximação da SF e a fórmula de Poisson.



1.11 Demonstre que a transformada de Fourier de: $a + b\delta(t - t_0) + c\delta'(t - t_1)$ é $2\pi a\delta(\omega) + be^{-i\omega t_0} + ic\omega_1 e^{-i\omega t_1}$

1.12 Usando as propriedades da transformada de Fourier, demonstrar que a solução particular de: $\ddot{x}(t) + 5\dot{x}(t) + 6x(t) = \delta(t)$ é $x(t) = (e^{-2t} + e^{-3t})u(t)$

2 - Relações entrada/saída de sistemas lineares

Matematicamente falando, um sistema (análogo) é uma regra para atribuir a uma função $x(t)$ uma outra função $y(t)$. Chamemos a $x(t)$ entrada e a $y(t)$ saída e o sistema que faz a transformação $L[x(t)]$:

$$y(t) = L[x(t)] \quad (2.1)$$

Fisicamente falando, um sistema produz um objetivo, uma resposta, quando estimulado por uma excitação. Resposta e excitação são os termos correspondentes a saída e entrada, respectivamente. Exemplos de sistemas físicos são circuitos elétricos, estruturas mecânicas, etc.

Restringiremos nosso estudo aos sistemas lineares, fisicamente realizáveis e invariantes no tempo, que podem ser representados por uma equação diferencial linear a parâmetros constantes.

2.1 Sistema linear

Por definição, um sistema é linear se:

$$L[a_1 x_1(t) + a_2 x_2(t)] = a_1 L[x_1(t)] + a_2 L[x_2(t)] \quad (2.2)$$

para quaisquer $a_1, a_2, x_1(t), x_2(t)$, ou seja, o conhecido princípio de superposição (figura 2.1).




figura 2.1. Sistema linear e o princípio de superposição

Um sistema é dito causal ou fisicamente realizável se a resposta ou saída não depende de valores futuros da entrada. Isto pode ser matematicamente representado por:

$$\text{Se } x(t) = 0 \text{ para } t \leq \tau; \text{ então } y(t) = 0 \text{ para } t \leq \tau \quad (2.3)$$

Um sistema é dito invariante no tempo se:

$$L[x(t - \tau)] = y(t - \tau) \quad (2.4)$$

para qualquer τ real.

Um sistema linear invariante no tempo pode geralmente ser representado por uma equação diferencial linear da forma:

$$\begin{aligned} a_n \frac{d^n y(t)}{dt^n} + a_{n-1} \frac{d^{n-1} y(t)}{dt^{n-1}} + \dots + a_1 \frac{dy(t)}{dt} + a_0 y(t) = \\ b_m \frac{d^m x(t)}{dt^m} + b_{m-1} \frac{d^{m-1} x(t)}{dt^{m-1}} + \dots + b_1 \frac{dx(t)}{dt} + b_0 x(t) \end{aligned} \quad (2.5)$$

É interessante notar que um sistema linear com N entradas e M saídas pode ser dividido em NM problemas de uma entrada e uma saída utilizando o princípio de superposição. Assim, por exemplo, uma sistema linear de 2 entradas e 3 saídas pode ser subdividido em 6 sistemas lineares de uma entrada e uma saída.

2.2 Integral de Duhamel (convolução)

Se a resposta de um sistema linear à distribuição $\delta(t)$ é uma função $h(t)$, podemos obter a resposta a uma entrada qualquer $x(t)$ em função de $h(t)$. Para tanto, a entrada $x(t)$ pode ser escrita como a soma de entradas elementares (figura 2.1).




figura 2.1. Sinal de entrada indicando, indicando uma das entradas elementares e a resposta a esta entrada

Com $\Delta\tau$ suficientemente pequeno podemos escrever:

$$x(t) = \sum_{i=1}^N x_i(t) = \sum_{i=1}^N x(\tau_i) \Delta\tau \delta(t - \tau_i) \quad (2.6)$$

Como o sistema é linear, pelo princípio da superposição, temos que a resposta será:

$$y(t) = \sum_{i=1}^N y_i(t) = \sum_{i=1}^N x(\tau_i) h(t - \tau_i) \Delta\tau \quad (2.7)$$

fazendo $\Delta\tau \rightarrow d\tau$:

$$y(t) = \int_0^t x(\tau) h(t - \tau) d\tau \quad (2.8)$$

Geralmente, tomamos, por conveniência, a entrada $x(t)$ só para tempos positivos (função causal) ou seja:

$$x(t) = 0 \quad \text{para } t < 0 \quad (2.9)$$

Como o sistema é causal, a saída $y(t)$ não pode depender de entradas futuras $x(\tau > t)$, ou seja:

$$h(t) = 0 \quad \text{para } t < 0 \quad (2.10)$$

Donde a integral (2.8) fica:

$$y(t) = \int_{-\infty}^{\infty} x(\tau) h(t - \tau) d\tau \quad (2.11)$$

A equação (2.8), que expressa a resposta de um sistema linear causal a uma entrada qualquer, é conhecida por integral de Duhamel. Devido às equações (2.9) e (2.10), as expressões (2.8) e (2.11) expressam o mesmo resultado.

Da definição (1.32), temos que a expressão (2.11) expressa a convolução de $x(t)$ com $h(t)$, ou seja:

A resposta de um sistema linear a uma excitação qualquer é a convolução do sinal de entrada com a função resposta ao impulso unitário.

Do teorema da convolução (1.33) temos que, fazendo a transformada de Fourier da expressão (2.11):

$$Y(f) = X(f)H(f)$$

onde

$$X(f) \xleftrightarrow{\tilde{f}} x(t); \quad (2.12)$$

$$Y(f) \xleftrightarrow{\tilde{f}} y(t);$$

$$H(f) \xleftrightarrow{\tilde{f}} h(t).$$

Mas este resultado pode ser obtido por um outro caminho mais rigoroso.

A resposta de um sistema linear à entrada $e^{i2\pi ft}$ é uma função de f e t .

$$y(t, f) = L[e^{i2\pi ft}] \quad (2.13)$$

pela invariância com o tempo (2.4):

$$y(t + \tau, f) = L[e^{i2\pi f(t+\tau)}]$$

para qualquer τ . Devido à linearidade (2.2):

$$L[e^{i2\pi ft} e^{i2\pi f\tau}] = e^{i2\pi f\tau} L[e^{i2\pi ft}] = e^{i2\pi f\tau} y(t, f) \quad (2.14)$$

donde:

$$y(t + \tau, f) = e^{i2\pi f\tau} y(t, f)$$

fazendo $t = 0$:

$$y(\tau, f) = e^{i2\pi f\tau} y(0, f) \quad (2.15)$$

Como (2.15) é válida para qualquer τ e $y(0, f)$ é uma função apenas de f e chamaremos $H(f) = y(0, f)$:

$$y(t, f) = H(f) e^{i2\pi ft}$$

ou seja, a resposta a uma exponencial complexa é também uma exponencial complexa. Da expressão da transformada de Fourier inversa podemos escrever:

$$x(t) = \int_{-\infty}^{\infty} X(f) e^{i2\pi ft} df$$

e como resposta a $e^{i2\pi ft}$ é $H(f) e^{i2\pi ft}$ temos, pelo princípio da superposição:

$$y(t) = \int_{-\infty}^{\infty} X(f) H(f) e^{i2\pi ft} df \quad (2.16)$$

Fazendo a transformada de (2.16) temos:

$$Y(f) = \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} X(\xi) H(\xi) e^{i2\pi\xi t} d\xi \right] e^{-i2\pi ft} dt$$

ou seja:

$$Y(f) = \int_{-\infty}^{\infty} X(\xi) H(\xi) \left[\int_{-\infty}^{\infty} e^{i2\pi\xi t} e^{-i2\pi ft} dt \right] d\xi \quad (2.17)$$

Mas de (1.28) temos que o termo no colchete vale $\delta(f-\xi)$ donde:

$$Y(f) = \int_{-\infty}^{\infty} X(\xi) H(\xi) \delta(f - \xi) d\xi \quad (2.18)$$

$$Y(f) = X(f) H(f)$$

ou seja, o mesmo resultado de (2.12). Pelo teorema da convolução (1.33), chegamos a (2.11) e, para mostrar que $h(t)$ é a resposta ao impulso $\delta(t)$ basta substituir $x(t) = \delta(t)$ em (2.11).

2.3 Função de resposta em frequência

A função $H(f)$, que é a transformada de Fourier da resposta ao delta de Dirac, é chamada de Função de Resposta em Frequência (FRF). A figura 2.2 mostra um esquema das relações entrada/saída de sistemas lineares.

$$H(f) = \int_{-\infty}^{\infty} h(t) e^{-i2\pi ft} dt \quad (2.19)$$




figura 2.2 Relações entrada/saída de um sistema linear

Dado que:

$$\frac{dx(t)}{dt} \xleftrightarrow{\tilde{f}} i2\pi f X(f) \quad (2.20)$$

pois:

$$\begin{aligned} \frac{dx(t)}{dt} &= \frac{d}{dt} \left(\int_{-\infty}^{\infty} X(f) e^{i2\pi f t} df \right) \\ &= \int_{-\infty}^{\infty} X(f) \frac{d}{dt} (e^{i2\pi f t}) df \\ &= \int_{-\infty}^{\infty} (i2\pi f X(f)) e^{i2\pi f t} df \end{aligned}$$

podemos fazer a transformada de Fourier dos dois lados da equação (2.5) e usando (2.20):

$$\begin{aligned} Y(f) [a_n (i2\pi f)^n + a_{n-1} (i2\pi f)^{n-1} + \dots + a_1 (i2\pi f) + a_o] = \\ X(f) [b_m (i2\pi f)^m + b_{m-1} (i2\pi f)^{m-1} + \dots + b_1 (i2\pi f) + b_o] \end{aligned}$$

ou seja:

$$H(f) = \frac{Y(f)}{X(f)} = \frac{b_m (i2\pi f)^m + b_{m-1} (i2\pi f)^{m-1} + \dots + b_1 (i2\pi f) + b_o}{a_n (i2\pi f)^n + a_{n-1} (i2\pi f)^{n-1} + \dots + a_1 (i2\pi f) + a_o} \quad (2.21)$$

que é a expressão geral da função resposta em frequência para sistemas lineares invariantes no tempo que podem ser representados por uma equação diferencial.

É interessante interpretar $H(f)$ considerando a resposta de um sistema linear a uma entrada senoidal.

Todo sistema linear é real, ou seja, a resposta a uma entrada real é uma saída real:

$$L[x_1(t) + ix_2(t)] = y_1(t) + iy_2(t)$$

então:

$$L[x_1(t)] = y_1(t); \quad L[x_2(t)] = y_2(t) \quad (2.22)$$

Tomemos a entrada :

$$x(t) = X e^{i2\pi f t} = X \cos(2\pi f t) + iX \sin(2\pi f t)$$

A resposta a esta entrada, em parte real, será a resposta a $X \cos(2\pi f t)$ e, em parte imaginária, a $X \sin(2\pi f t)$.

Mas, já vimos que a resposta a $x(t)$ será:

$$y(t) = H(f) X e^{i2\pi ft}$$

Como $H(f)$ é uma função complexa podemos escrever:

$$H(f) = |H(f)| e^{i\angle H(f)}$$

ou seja:

$$y(t) = Y e^{i(2\pi ft + \angle H(f))} \quad (2.23)$$

onde:

$$Y = |H(f)| X \quad (2.24)$$

ou seja, a relação entre as amplitudes das senóides de entrada e saída é $|H(f)|$ e a defasagem é $\angle H(f)$.

Exemplo

Consideremos o sistema mecânico elementar massa-mola-amortecedor (figura 2.3.a). A excitação é a força externa $F(t)$ atuando sobre a massa (devido, por exemplo, a um rotor desbalanceado) e a resposta é o movimento da massa, que pode ser dado em termos de deslocamento $x(t)$. Aplicando as leis de Newton:

$$m \frac{d^2 x(t)}{dt^2} + c \frac{dx(t)}{dt} + k x(t) = F(t) \quad (2.25)$$

Aplicando (2.18) temos:

$$H(f) = \frac{1}{m(i2\pi f)^2 + c(i2\pi f) + k} \quad (2.26)$$

É mais conveniente escrever a expressão (2.26) usando definições:

$$\xi = \frac{c}{2\sqrt{km}}; \quad f_n = \frac{1}{2\pi} \sqrt{\frac{k}{m}} \quad (2.27)$$

onde ξ é o fator de amortecimento e f_n a frequência natural não amortecida. Substituindo (2.27) em (2.26):

$$H(f) = \frac{1/k}{1 - (f/f_n)^2 + 2i\xi(f/f_n)} \quad (2.28)$$

ou, em termos de amplitude e fase, chamando $\gamma = f/f_n$ temos:

$$|H(f)| = \frac{1/k}{\sqrt{(1 - \gamma^2)^2 + (2\xi\gamma)^2}} \quad (2.29)$$

$$\angle H(f) = \arctan\left(\frac{2\xi\gamma}{1-\gamma^2}\right) \quad (2.30)$$

as curvas $|H(f)|$ e $\angle H(f)$ são mostradas nas figura 2.3.(b) e (c) respectivamente, para diferentes valores do coeficiente de amortecimento ξ .

É importante notar a diferença entre função de resposta em frequência e função de transferência. A função de transferência é, por definição, o quociente da transformada de Laplace da saída pela transformada de Laplace da entrada. A função de transferência é utilizada no estudo analítico das relações entrada/saída de sistemas lineares.

A transformada de Laplace é dada por :

$$X(s) = \int_0^{\infty} x(t) e^{-st} dt; \quad s = \sigma + i\omega \quad (2.31)$$

e a transformada inversa de Laplace :

$$x(t) = \int_{-\infty}^{\infty} X(s) e^{st} ds; \quad (2.32)$$




figura 2.3. (a) Sistema massa-mola-amortecedor e sua função de resposta em frequência. (b) Amplitude; (c) fase.

A transformada de Fourier pode ser obtida de (2.31) fazendo $s = i2\pi f$.

$$H(s) = \frac{Y(s)}{X(s)} \quad (2.33)$$

e a função de resposta em frequência pode ser obtida de (2.33) fazendo $s = i2\pi f$.

Um exemplo análogo pode ser obtido a partir de um circuito elétrico RLC. A excitação é o sinal de tensão $v(t)$ e a resposta é a corrente $i(t)$ no circuito RLC (Figura 2.5).




figura 2.4. Sistema elétrico RLC

Usando a lei de Kirchoff, obtém-se a equação diferencial:

$$L \frac{d^2 i(t)}{dt^2} + R \frac{di(t)}{dt} + \frac{1}{C} i(t) = \frac{dv(t)}{dt} \quad (2.34)$$

Aplicando (2.18) temos:

$$H(f) = \frac{i2\pi f}{L(i2\pi f)^2 + R(i2\pi f) + \frac{1}{C}} = \frac{1}{R + L(i2\pi f) + \frac{1}{C(i2\pi f)}} \quad (2.35)$$

Definindo

$$\xi = \frac{R}{2} \sqrt{\frac{C}{L}}; \quad f_n = \frac{1}{2\pi\sqrt{LC}} \quad (2.36)$$

onde ξ é o fator de atenuação e f_n a frequência natural não amortecida,

$$H(f) = \frac{(1/R)2i\xi(f/f_n)}{1 - (f/f_n)^2 + 2i\xi(f/f_n)} \quad (2.37)$$

ou, em termos de amplitude e fase, chamando $\gamma = f/f_n$ temos:

$$|H(f)| = \frac{(1/R)(2\xi\gamma)}{\sqrt{(1-\gamma^2)^2 + (2\xi\gamma)^2}} \quad (2.38)$$

$$\angle H(f) = \arctan\left(\frac{1-\gamma^2}{2\xi\gamma}\right) \quad (2.39)$$

as curvas $|H(f)|$ e $\angle H(f)$ representam o módulo e fase do sistema em f .

2.4 Filtros

Qualquer sistema linear é considerado um filtro. Um filtro analógico é fisicamente realizável se $h(t) = 0$ para $t < 0$. Os filtros são geralmente utilizados para eliminar ou ao menos atenuar o sinal em determinadas faixas de frequência.

Podemos definir dois tipos básicos de filtros: passa-baixas e passa altas (figura 2.5.a e figura 2.5.b). Idealmente estes filtros eliminariam componentes de frequência superior ou inferior, respectivamente, a uma determinada frequência f_c , dita frequência de corte. Colocados sequencialmente, estes dois tipos básicos de filtros geram outros dois de larga aplicação: passa-banda e rejeita-banda (figura 2.6.a e figura 2.6.b).




figura 2.5. Filtros ideais básicos: (a) Passa-baixas; (b) passa-altas.

Os filtros ideais assim definidos não são fisicamente realizáveis. Isto porque:

- (a) Para não haver defasagem do sinal, a parte imaginária de $H(f)$ deveria ser nula, mas isto implicaria em $h(t)$ ser real par, o que é impossível pois $h(t) = 0$ para $t < 0$. Daí conclui-se que todo tipo de filtro fisicamente realizável defasa.
- (b) A condição de $h(t)$ ser causal implica num truncamento que, no domínio das frequências, significa uma convolução com a transformada de uma janela. Daí conclui-se que é impossível ter os cantos “cantos vivos” em $H(f)$.

Para demonstrar de forma rigorosa as afirmações acima seria necessário fazer apelo à condição de Paley-Wiener³⁶, ou seja: “Se $h(t) = 0$ para $t < 0$, então $H(f)$ não pode ser zero para todo f de um intervalo”. Esta demonstração estaria fora do escopo deste texto.




figura 2.6. Filtros ideais: (a) Passa-banda; (b) rejeita-banda.

A figura 2.7, mostra a forma assintótica de $|H(f)|$ para um filtro real passa-baixas. O que caracteriza basicamente um filtro real é a frequência de corte f_c , definida como a frequência correspondente a uma atenuação de 3 decibéis (dB), e a inclinação da curva de atenuação em escala logarítmica expressa em dB/década ou dB/oitava. Uma década é o intervalo entre f a $10f$ e uma oitava o intervalo de f a $2f$ no eixo das frequências. Uma razão entre dois valores reais v_1 e v_2 em decibéis é calculada como $20 \log_{10}(v_1/v_2)$.




figura 2.7. Características básicas de um filtro real.

Outro conceito importante que caracteriza um filtro real é a largura de banda. A largura de banda tem a propriedade de fazer passar somente parte da potência total cujas frequências estão dentro de uma determinada faixa finita.

Exemplo

Um filtro ideal passa-baixas (figura 2.8a) é definido como sendo

$$Y(f) = \begin{cases} e^{-i2\pi f t_0}, & |f| \leq f_c \\ 0, & |f| > f_c \end{cases} \quad (2.40)$$

Calcular a resposta do filtro ao impulso unitário.

Res. A resposta do filtro ideal passa-baixas ao impulso unitário é dada por:

$$y(t) = \int_{-\infty}^{\infty} Y(f) e^{i2\pi f t} df$$

substituindo

$$y(t) = \int_{-\infty}^{\infty} e^{-i2\pi f t_0} e^{i2\pi f t} df = \int_{-f_c}^{f_c} e^{i2\pi f (t-t_0)} df$$

$$y(t) = \frac{e^{i2\pi f (t-t_0)}}{i2\pi (t-t_0)} \Big|_{-f_c}^{f_c} = 2f_c \frac{\sin(2\pi f_c (t-t_0))}{2\pi f_c (t-t_0)}$$

Logo,

$$y(t) = 2f_c \text{sinc}(2\pi f_c (t-t_0)) \text{ como mostra a figura 2.8b}$$






Fig. 2.8. Resposta do filtro passa-baixas ao impulso unitário

2.5 Exercícios

2.1 Se a excitação de um sistema linear cuja função de transferência é $H(f)$ é dada por $\cos(t) + \cos(3t)$, encontrar a resposta do sistema.


2.2 A um sistema mecânico massa-mola (figura abaixo) é aplicada uma excitação do tipo $F(t) = 5e^{-t}u(t)$. Pede-se encontrar a resposta $x(t)$.




2.3 Dado um sistema dinâmico cuja FRF é conhecida analiticamente, pede-se descrever todo o procedimento para calcular a resposta do sistema aos dois sinais de entrada definidos abaixo.

$$H(f) = \left(\frac{1}{k} \right) \left(\frac{1}{1 - \alpha^2 + i2\xi\alpha} \right), \quad k=1, \xi=0.2, 0 \leq \alpha \leq 4, \alpha = \frac{\omega}{\omega_n}, \omega_n = \sqrt{\frac{k}{m}}$$

a) Excitação transitória: $x(t) = \begin{cases} A \sin(2\pi f_0 t), & 0 \leq t < 80ms \\ 0, & t \geq 80ms \end{cases} \quad f_0 = 8Hz \text{ e } A = 1$



b) Excitação periódica: $x(t) = |A \sin(2\pi f_0 t)|, 0 \leq t < 40s, \quad f_0 = 5Hz \text{ e } A = 1$



3 3 - Discretização e transformada de Fourier discreta

Para poder fazer uso dos modernos processadores digitais extremamente rápidos na análise de sinais, é necessário trabalhar com valores discretos, ou seja, é necessário discretizar (ou digitalizar) os sinais analógicos. Torna-se, então, necessário estabelecer relações entre os sinais discretos e os sinais analógicos dos quais foram obtidos bem como, na análise espectral, as relações entre suas transformadas.

3.1 Discretização e teorema da amostragem

Seja um sinal $x(t)$ contínuo. A partir dele, tomando valores a intervalos de tempo Δt , podemos obter um sinal discreto $x(n)$ (figura 3.1).

$$x(n) = x(t = n\Delta t); \text{ } n \text{ inteiro} \quad (3.1)$$

Para o sinal discreto $x(n)$ podemos definir uma transformada de Fourier contínua do sinal discreto $\bar{X}(f)$:

$$\bar{X}(f) = \sum_{n=-\infty}^{\infty} x(n) e^{-i2\pi f n \Delta t} \quad (3.2)$$




figura 3.1. Discretização do sinal

Podemos mostrar que esta transformada de Fourier do sinal discreto é periódica. A frequência com que o sinal é amostrado, ou frequência de amostragem, é:

$$f_a = \frac{1}{\Delta t} \quad (3.3)$$

Então:

$$\bar{X}(f + kf_a) = \sum_{n=-\infty}^{\infty} x(n) e^{-i2\pi f n \Delta t} e^{-i2\pi k f_a n \Delta t}, k \text{ inteiro}$$

mas, usando (3.3) e lembrando que:

$$e^{-i2\pi k} = \cos(2\pi k) - i \sin(2\pi k) = 1, k \text{ inteiro}$$

temos:

$$\bar{X}(f + kf_a) = \bar{X}(f), k \text{ inteiro} \quad (3.4)$$

então $\bar{X}(f)$ definida em (3.2) é periódica de período f_a . Multiplicando os dois lados de (3.2) por $e^{i2\pi f n \Delta t}$, integrando de $-f_a/2$ a $f_a/2$ e multiplicando a integral por $1/f_a$, obtemos:

$$\frac{1}{f_a} \int_{-f_a/2}^{f_a/2} \bar{X}(f) e^{i2\pi n \Delta t} df = \sum_{k=-\infty}^{\infty} x(k) \frac{1}{f_a} \int_{-f_a/2}^{f_a/2} e^{i2\pi f(k-n)\Delta t} df \quad (3.5)$$

mas

$$\frac{1}{f_a} \int_{-f_a/2}^{f_a/2} e^{i2\pi f(k-n)\Delta t} df = \delta_{kn} = \begin{cases} 1, k = n \\ 0, k \neq n \end{cases} \quad (3.6)$$

substituindo em (3.5) obtemos:

$$x(n) = \frac{1}{f_a} \int_{-f_a/2}^{f_a/2} \bar{X}(f) e^{i2\pi n f \Delta t} df \quad (3.7)$$

Podemos interpretar (3.2) como uma expansão em série de Fourier da função periódica $\bar{X}(f)$ de coeficientes de Euler-Fourier $x(n)$ dados por (3.7), apenas com os sinais das exponenciais da série alterados.

Como $x(t)$ é a transformada de $X(f)$ e dada a equação (3.1) temos:

$$x(n) = \int_{-\infty}^{\infty} X(f) e^{i2\pi n \Delta t} df \quad (3.8)$$

que pode ser rearranjado:

$$x(n) = \sum_{r=-\infty}^{\infty} \int_{(2r-1)f_a/2}^{(2r+1)f_a/2} X(f) e^{i2\pi n \Delta t} df \quad (3.9)$$

ou:

$$x(n) = \sum_{r=-\infty}^{\infty} \int_{-f_a/2}^{f_a/2} X(f + rf_a) e^{i2\pi n \Delta t} e^{i2\pi rf_a n \Delta t} df \quad (3.10)$$

o que pode ser facilmente obtido por substituição de variáveis, com $\xi = f - rf_a$. Mas:

$$e^{i2\pi rf_a n \Delta t} = e^{i2\pi n} = 1, r \text{ e } n \text{ inteiros}$$

donde:

$$x(n) = \int_{-f_a/2}^{f_a/2} \left(\sum_{r=-\infty}^{\infty} X(f + rf_a) \right) e^{i2\pi n \Delta t} df \quad (3.11)$$

Comparando (3.11) e (3.7) temos:

$$\bar{X}(f) = f_a \sum_{r=-\infty}^{\infty} X(f + rf_a) = \sum_{n=-\infty}^{\infty} x(n) e^{-i2\pi n \Delta t} \quad (3.12)$$

A figura 3.2. mostra graficamente a expressão (3.12), que traduz o teorema da amostragem, para uma dada transformada de Fourier $X(f)$. É interessante observar a semelhança entre as equações (3.12) e (1.44). **Em outras palavras, o teorema da amostragem é o equivalente da fórmula de Poisson no domínio das frequências.**




figura 3.2. Efeito de rebatimento devido à discretização. (a) Transformada do sinal original; (b) transformada do sinal discretizado com distorção (em inglês, “aliasing”); (c) sem distorção.

É fácil ver que se:

$$X(f) = 0, \text{ para } f > f_{max} \quad (3.13)$$

temos:

$$\bar{X}(f) = f_a X(f); \quad -\frac{f_a}{2} \leq f \leq \frac{f_a}{2} \quad \text{se} \quad f_{max} \leq \frac{f_a}{2} \quad (3.14)$$

$$\bar{X}(f) \neq f_a X(f); \quad \text{se} \quad f_{max} > \frac{f_a}{2} \quad (3.15)$$

Na condição de que a maior frequência contida no sinal seja inferior à metade da frequência de amostragem, a transformada do sinal discretizado é igual à transformada do sinal contínuo na faixa $-f_a/2 \leq f \leq f_a/2$ a menos de uma constante f_a . Caso $f_{max} > f_a/2$ então

existirá distorção pelo efeito de rebatimento devido à discretização. A frequência $f_a/2$ é também chamada de frequência de Nyquist, f_N .

No caso em que não há distorção (em inglês, “*aliasing*”), ou seja, $f_{\max} \leq f_a/2$, podemos escrever:

$$x(t) = \int_{-\infty}^{\infty} X(f) e^{i2\pi ft} df = \int_{-f_a/2}^{f_a/2} \frac{1}{f_a} \bar{X}(f) e^{i2\pi ft} df \quad (3.16)$$

e substituindo (3.2) em (3.16):

$$x(t) = \frac{1}{f_a} \int_{-f_a/2}^{f_a/2} \left(\sum_{k=-\infty}^{\infty} x(k) e^{-i2\pi k \Delta t} \right) e^{i2\pi ft} df \quad (3.17)$$

ou ainda, rearranjando:

$$x(t) = \sum_{k=-\infty}^{\infty} x(k) \left(\frac{1}{f_a} \int_{-f_a/2}^{f_a/2} e^{i2\pi f(t-k\Delta t)} df \right)$$

mas a expressão entre colchetes é facilmente integrável, obtendo-se, finalmente,

$$x(t) = \sum_{k=-\infty}^{\infty} x(k) \frac{\sin(\pi f_a(t-k\Delta t))}{\pi f_a(t-k\Delta t)} \quad (3.18)$$

A expressão (3.18) é conhecida por interpolação de Shannon e pode ser interpretada como prova da possibilidade de recuperar um sinal analógico a partir do mesmo sinal discretizado desde que a frequência de amostragem tenha sido pelo menos o dobro da maior frequência contida no sinal.

3.2 Transformada de Fourier discreta

A transformada definida pela equação (3.2) ainda não é conveniente para obtenção de um espectro, pois para seu cálculo seriam necessários infinitos valores amostrados do sinal $x(t)$. Neste item obteremos uma expressão de transformada por soma, análoga a (3.2), porém finita e, portanto, passível de ser calculada para um sinal físico observado durante um intervalo de tempo finito.

A partir do sinal $x(t)$ podemos obter um sinal discreto $x(n)$ em intervalos de tempo Δt , conforme a equação (3.1).

Da fórmula de Poisson (equação 1.44) temos que os termos da série de Fourier do sinal $x(t)$ periodizado, ou seja $\bar{x}(t)$ são os valores amostrados da transformada de $x(t)$:

$$\bar{x}(t) = \sum_{k=-\infty}^{\infty} \frac{X(kf_o)}{T} e^{i2\pi kf_o t} \quad (3.19)$$

onde:

$$f_o = 1/T$$

$$\bar{x}(t) = \sum_{k=-\infty}^{\infty} x(t + nT) \quad (3.20)$$

Valores discretos de $\bar{x}(t)$ espaçados de Δt com $T = N\Delta t$ podem ser obtidos da seguinte forma:

$$\bar{x}(n) = \sum_{k=-\infty}^{\infty} \frac{X(kf_o)}{T} e^{i2\pi kn/N} \quad (3.21)$$

Introduzindo a notação:

$$e^{i2\pi/N} = w_N$$

ou seja, w_N sendo a N -ésima raiz da unidade $\left(\sqrt[N]{e^{i2\pi}}\right)$, temos:

$$\bar{x}(n) = \sum_{k=-\infty}^{\infty} \frac{X(kf_o)}{T} w_N^{kn} \quad (3.22)$$

onde:

$$\bar{x}(n) = \sum_{r=-\infty}^{\infty} x(n + rN) \quad (3.23)$$

Mas $\bar{x}(t)$ é uma função periódica de período T , o que implica que $\bar{x}(n)$ é periódica de período N .

Do teorema de discretização (equação (3.12)) temos:

$$\bar{X}(f) = N \sum_{r=-\infty}^{\infty} \frac{X(f + rf_a)}{T} \quad (3.24)$$

onde $\bar{X}(f)$, dada pela equação (3.2), é periódica de período $f_a = 1/\Delta t$. Fazendo $f = mf_o$ em (3.24) podemos chegar facilmente a:

$$\bar{X}(mf_o) = N \sum_{r=-\infty}^{\infty} \frac{X[(m + rN)f_o]}{T} = \bar{X}(m) \quad (3.25)$$

Trabalhando a equação (3.22) onde fazemos:

$$k = m + rN; \quad m = 0, 1, \dots, N-1; \quad r = \dots, -1, 0, 1, 2, \dots \quad (3.26)$$

chegamos a:

$$\bar{x}(n) = \sum_{m=0}^{N-1} \sum_{r=-\infty}^{\infty} \frac{X[(m+rN)f_o]}{T} w_N^{(m+rN)n} \quad (3.27)$$

mas como:

$$w_N^N = 1, \quad \text{donde} \quad w_N^{(m+rN)n} = w_N^{mn}$$

temos:

$$\bar{x}(n) = \sum_{m=0}^{N-1} w_N^{mn} \sum_{r=-\infty}^{\infty} \frac{X[(m+rN)f_o]}{T} \quad (3.28)$$

Substituindo a expressão (3.25) em (3.28) temos:

$$\bar{x}(n) = \frac{1}{N} \sum_{m=0}^{N-1} \bar{X}(m) w_N^{mn} \quad (3.29)$$

Multiplicando os dois lados da equação (3.29) por w_N^{-nr} e somando sobre n :

$$\sum_{n=0}^{N-1} w_N^{-nr} \bar{x}(n) = \frac{1}{N} \sum_{n=0}^{N-1} \sum_{m=0}^{N-1} \bar{X}(m) w_N^{(m-r)n}$$

que pode ser rearranjado:

$$\sum_{n=0}^{N-1} w_N^{-nr} \bar{x}(n) = \sum_{m=0}^{N-1} \bar{X}(m) \frac{1}{N} \sum_{n=0}^{N-1} w_N^{(m-r)n}$$

mas é bem conhecido que:

$$\sum_{n=0}^{N-1} w_N^{n(m-r)} = N \delta_{mr} = \begin{cases} 0, & m \neq r \\ N, & m = r \end{cases} \quad (3.30)$$

Então:

$$\sum_{m=0}^{N-1} \bar{X}(m) \frac{1}{N} N \delta_{mr} = \bar{X}(r)$$

e, finalmente:

$$\bar{X}(r) = \sum_{n=0}^{N-1} \bar{x}(n) w_N^{-nr} \quad (3.31)$$

A figura 3.3 ilustra graficamente o significado das expressões (3.29) e (3.31).

É evidente que a constante multiplicativa $1/N$ que aparece na equação (3.29) poderia igualmente aparecer na equação (3.31) e as duas equações continuariam a constituir um par de transformações igualmente válido.

Na verdade preferiremos definir a transformada de Fourier discreta (TFD) pelas expressões:

$$X_r = \frac{1}{N} \sum_{n=0}^{N-1} x_n w_N^{-nr} ; r = 0, \dots, N-1 \quad (3.32)$$

$$x_n = \sum_{r=0}^{N-1} X_r w_N^{nr} ; n = 0, \dots, N-1 \quad (3.33)$$

A interpretação da TFD definida acima deduz-se imediatamente de (3.29), (3.31) e da figura 3.3.

Das equações obtidas e da figura 3.3 fica claro que, para obter valores amostrados da transformada de Fourier de um sinal transitório através da transformada de Fourier discreta, é necessário que a periodização não introduza distorções no sinal (a estas distorções dá-se o nome de “leakage”, isto é, vazamento em inglês), ou seja:

$$x(t) = 0, \begin{cases} t > T/2 \\ t < -T/2 \end{cases}$$

e ainda que a discretização seja tal que, sendo $f_{\max}$ a maior frequência contida no sinal $x(t)$, $f_a \geq 2 f_{\max}$ para que não haja distorção por rebatimento (em inglês, “aliasing”).

Para obter os valores dos coeficientes de Euler-Fourier para sinais periódicos a partir da transformada de Fourier discreta, é necessário truncar o sinal e isto, como vimos no capítulo 1, equivale a fazer uma convolução com a transformada da janela utilizada.

Uma maneira de relacionar a transformada de Fourier discreta com os coeficientes de Euler-Fourier é obter a resposta em frequência da TFD.

Fazendo:

$$x_n = e^{i2\pi f_n \Delta t} \quad (3.34)$$

e substituindo em (3.32), obtemos:

$$F(k) = \frac{1}{N} \sum_{n=0}^{N-1} e^{i2\pi n(fT-k)/N} \quad (3.35)$$

mas é bem conhecido que:

$$\sum_{n=0}^{N-1} e^{ina} = \frac{\sin\left(\frac{N}{2}a\right)}{\sin\left(\frac{a}{2}\right)} e^{ia(N-1)/2} \quad (3.36)$$

Substituindo $a = \frac{2\pi}{N}(fT - k)$ pode-se chegar a:

$$F(k) = \frac{1}{N} \frac{\sin(\pi fT)}{\sin\left(\frac{\pi}{N}(fT - k)\right)} e^{i\pi\left(\frac{N-1}{N}\right)(fT - k)} \quad (3.37)$$

que é a “pseudo resposta em frequência” da TFD.

É importante notar que se tomarmos uma senóide de frequência f_0 e escolhermos N e Δt de modo que:

$$T = N\Delta t = M \frac{1}{f_0} = MT_0 \quad (3.38)$$

ou seja, de modo a que o tempo total sobre o qual é calculada a TFD contenha um número inteiro de períodos, teremos que $F(k) = 1$. Isto significa que pela TFD serão obtidos exatamente valores da série de Fourier (figura. 4). Para sinais periódicos quaisquer isto também é verdade pois o produto fT será um número inteiro para cada frequência contida no sinal.




figura 3.3. Interpretação da transformada de Fourier discreta: (a) Sinal e sua transformada de Fourier; (b) sinal discretizado e sua transformada; (c) sinal periodizado e sua transformada de Fourier; (d) sinal periodizado discretizado e sua transformada





figura 3.4. Obtenção dos coeficientes de Euler-Fourier a partir da TDF (a) com f_0 múltipla de Δf e (b) com f_0 não múltipla de Δf (fenômeno de “leakage”).


3.3 Exercícios

3.1. Um sinal harmônico é digitalizado para análise espectral usando a TFD. Pede-se calcular a TFD e comentar o resultado para os casos mostrados nas figuras abaixo. Os círculos denotam os pontos amostrados.


Caso 1:




Caso 2:



Caso 3:



Caso 4:



3.2. Um sinal periódico é amostrado com frequência de amostragem $f_s = 1$ kHz resultando no vetor $x = \{1 \ 0 \ -1 \ 0\}$. Pede-se:

- Calcular a TFD do sinal
- Determinar, a partir da TFD, a frequência do sinal
- Traçar o resultado indicando a frequência de Nyquist no gráfico
- É possível dizer se houve ou não "aliasing" nesta análise ?
- Se o sinal original é uma senóide, houve "leakage" nesta análise ?


3.3. Para calcular o espectro de um pulso retangular de duração 1 ms e amplitude 1 V pede-se especificar:

- Uma frequência de amostragem adequada
- Um número de pontos adequado
- Esboçar a curva do espectro que seria obtida

3.4 Calcular, usando a TFD, o espectro de um sinal periódico descrito pela equação $x(t) = \sin(200\pi t) + 2\sin(300\pi t + \pi/4) + 0.5 \sin(500\pi t + \pi/2)$. Especificar a frequência de amostragem e o número de pontos, e mostrar o efeito de "leakage" usando um número não inteiro de períodos.

3.5. Seja o sinal periódico mostrado na figura abaixo, cujo período é de 1 s. Determinar a TFD do sinal amostrado a intervalos de:

- a) 0,2 s
- b) 0,1 s
- c) 0,05 s
- d) Comparar os espectros obtidos nos itens (a, b e c)



3.6. Seja a função periódica com período de 1s descrita pela equação $x(t) = e^{-t}$, $0 \leq t < 1s$. Obter a TFD onde o número de pontos é de: a) $N = 8$, b) $N = 16$, c) $N = 32$, d) comparar os resultados com a solução analítica da série de Fourier deste sinal periódico.

3.7. Seja $x(n)$ uma sequência de valores reais de N pontos e seja $X(k)$ sua TFD com partes real e imaginária dada por $X(k) = X_R(k) + iX_I(k)$. Demonstrar que $X_R(k)$ e $X_I(k)$ são funções par e ímpar, respectivamente.

4 - Algoritmos da transformada de Fourier rápida

Para o cálculo da transformada de Fourier discreta (TFD), i.e.,

$$X_k = \frac{1}{N} \sum_{n=0}^{N-1} x_n w_N^{-kn}, \quad k = 0, \dots, N-1$$

são necessárias N multiplicações complexas para cada valor de X_k , ou seja, N^2 multiplicações complexas no total. Para $N = 1024$, que é o número usual para o cálculo da TFD, são necessárias 1.048.576 multiplicações complexas. Esta quantidade de operações implica num tempo de processamento em computador muito elevado.

Uma possibilidade para diminuir o número de operações necessárias ao cálculo de X_k foi inicialmente formulada por Cooley e Tukey em 1965². Com o algoritmo por eles proposto e denominado transformada rápida de Fourier ou mais conhecido como “fast Fourier transform” (FFT), é possível, como veremos a seguir, calcular a TFD com $N \log_2 N$ multiplicações complexas, ou seja, para os mesmos $N = 1024$ pontos, serão necessárias 10.240 multiplicações complexas.

Trataremos aqui apenas o algoritmo original Cooley-Tukey onde N deve ser potência de 2, ou seja, $N = 2^p$ com p inteiro. Na teoria generalizada dos algoritmos da FFT, este algoritmo é chamado de base 2.

4.1 Decimação no tempo

Seja uma série temporal:

$$\{x_r\}; \quad r = 0, \dots, N-1 \quad (4.1)$$

composta pelos valores amostrados $x(t = r\Delta t)$ de um sinal do qual se deseja obter a FFT. Podemos partir esta série em duas outras (base 2) com metade do número de valores, desde que N seja par:

² Cooley, J.W. and Tukey, J.W., Na Algorithm for the Machine Calculation of Complex Fourier Series, *Mathematics of Computation*, vol.19, p. 297-301, 1965

$$\left. \begin{array}{l} \{y_r\} \quad ; y_r = x_{2r} \\ \{z_r\} \quad ; z_r = x_{2r+1} \end{array} \right\}; \quad r = 0, \dots, \frac{N}{2} - 1 \quad (4.2)$$

Substituindo no cálculo da TFD:

$$X_k = \frac{1}{N} \left\{ \sum_{r=0}^{N/2-1} x_{2r} w_N^{-2rk} + \sum_{r=0}^{N/2-1} x_{2r+1} w_N^{-(2r+1)k} \right\}, \quad k = 0, \dots, N-1 \quad (4.3)$$

rearranjando:

$$X_k = \frac{1}{2} \left\{ \frac{2}{N} \sum_{r=0}^{N/2-1} y_r w_{N/2}^{-rk} + \frac{2}{N} w_N^{-k} \sum_{r=0}^{N/2-1} z_r w_{N/2}^{-rk} \right\}$$

denotando Y_k e Z_k as FFT das séries y_r e z_r de $N/2$ valores, temos:

$$X_k = \frac{1}{2} \{Y_k + w_N^{-k} Z_k\}, \quad k = 0, \dots, N/2 - 1 \quad (4.4)$$

Para obter os $N/2$ pontos restantes, basta substituir $k = k + N/2$ na equação (4.3):

$$X_{k+N/2} = \frac{1}{N} \left\{ w_N^{-rN} \sum_{r=0}^{N/2-1} y_r w_{N/2}^{-rk} + w_N^{-k} w_N^{-\left(\frac{2r+1}{2}\right)N} \sum_{r=0}^{N/2-1} z_r w_{N/2}^{-rk} \right\} \quad (4.5)$$

mas já vimos que $w_N^N = 1$ e, portanto:

$$w_N^{-rN} = 1; \quad w_N^{-(2r+1)N/2} = w_N^{-rN} w_N^{-N/2} = -1$$

Substituindo em (4.5):

$$X_{k+N/2} = \frac{1}{2} \{Y_k - w_N^{-k} Z_k\}, \quad k = 0, \dots, N/2 - 1 \quad (4.6)$$

As expressões (4.4) e (4.6) constituem a base de algoritmo da FFT, pois permitem obter as TFDs de duas séries de $N/2$ pontos cada, formadas a partir da série inicial, conforme a expressão (4.2). A figura 4.1 ilustra o algoritmo que, por sua forma gráfica, é geralmente conhecido como “borboleta”.




figura 4.1. Algoritmo básico da FFT (“borboleta”)

Partindo uma série de $N = 2^p$ pontos p vezes, chegamos a séries constituídas de apenas um elemento. Mas, para uma série de apenas um elemento:

$$\{x_r\} = x_o, r = 0 \quad (4.7)$$

Temos que a sua TFD é uma série de apenas um elemento igual a x_o :

$$X_k = \sum_{r=0}^0 x_r w_N^{-kr}, k = 0 \quad (4.8)$$

ou seja, $X_o = x_o$. Remonta-se à TFD da série original usando (4.4) e (4.6). A figura 4.2 ilustra o procedimento para uma série com $N = 4$.

O processo de partição da série temporal conforme a expressão (4.2) é chamada decimação no tempo. A

figura 4.3 ilustra de outra forma o procedimento para obter a TFD da mesma série de $N = 4$ termos. Esta representação é útil na comparação com outros algoritmos, como o que veremos a seguir.





figura 4.2. FFT sobre uma série de $N = 4$ termos.figura 4.3. FFT sobre uma série de $N = 4$ termos com decimação no tempo.

4.2 Decimação na frequência

Podemos partir a TFD de outra maneira:

$$X_k = \frac{1}{N} \left\{ \sum_{r=0}^{N/2-1} x_r w_N^{-rk} + \sum_{r=N/2}^{N-1} x_r w_N^{-rk} \right\}$$

que é o mesmo que:

$$X_k = \frac{1}{N} \left\{ \sum_{r=0}^{N/2-1} x_r w_N^{-rk} + w_N^{-kN/2} \sum_{r=0}^{N/2-1} x_{r+N/2} w_N^{-rk} \right\}$$

mas já vimos que $w_N^{-N/2} = -1$ e portanto:

$$X_k = \frac{1}{N} \sum_{r=0}^{N/2-1} (x_r + (-1)^k x_{r+N/2}) w_N^{-rk}, \quad k = 0, \dots, N-1$$

Fazendo $k = 2n$ (par):

$$X_{2n} = \frac{2}{N} \sum_{r=0}^{N/2-1} \frac{1}{2} (x_r + x_{r+N/2}) w_{N/2}^{-nr}, \quad n = 0, \dots, N/2-1$$

e para $k = 2n + 1$ (ímpar):

$$X_{2n+1} = \frac{2}{N} \sum_{r=0}^{N/2-1} \frac{1}{2} (x_r - x_{r+N/2}) w_{N/2}^{-nr} w_N^{-r}, n = 0, \dots, N/2-1$$

Chamando:

$$\left. \begin{aligned} y_r &= \frac{1}{2} \{x_r + x_{r+N/2}\} \\ z_r &= \frac{1}{2} \{(x_r - x_{r+N/2}) w_N^{-r}\} \end{aligned} \right\}; \quad r = 0, \dots, \frac{N}{2} - 1 \quad (4.9)$$

temos:

$$\left. \begin{aligned} X_{2n} &= Y_n \\ X_{2n+1} &= Z_n \end{aligned} \right\}; \quad n = 0, \dots, \frac{N}{2} - 1 \quad (4.10)$$

As expressões (4.9) e (4.10) constituem a base do algoritmo da FFT com decimação em frequência. A figura 4.4 ilustra o procedimento.




figura 4.4. FFT sobre uma série de $N = 4$ termos com decimação em frequência.

4.3 Economia de memória

Os algoritmos tratados apresentam ainda ineficiência em relação ao espaço de memória ocupado. Como os sinais analisados são reais, metade da memória de N valores complexos contém zeros. Vimos ainda que, para sinais reais, a transformada de Fourier

tem parte real par e parte imaginária ímpar. Dada a periodicidade do espectro obtido via FFT temos que:

$$\bar{X}_{k+nN} = X_k; \quad k = 0, \dots, N-1 \quad (4.11)$$

e:

$$\bar{X}_{N-k} = \bar{X}_k^*; \quad (4.12)$$

Sendo assim, os valores de X_k com k variando de $N/2$ a $N-1$ são redundantes, uma vez que sabemos que (figura 4.5):

$$\begin{aligned} \operatorname{Re}\{X_{k+N/2}\} &= \operatorname{Re}\{X_{N/2-k}\} \\ \operatorname{Im}\{X_{k+N/2}\} &= -\operatorname{Im}\{X_{N/2-k}\} \end{aligned} \quad (4.13)$$

Basta então calcular os $N/2$ primeiros pontos de X_k .




figura 4.5. Redundância dos valores de X_k para $k > N/2$.

Investiguemos as possibilidades de sanar estas ineficiências. Podemos construir a partir da série real $\{x_r\}$ uma série complexa $\{\alpha_r\}$ tal que:

$$\begin{cases} y_r = x_{2r} \\ z_r = x_{2r+1} \\ \alpha_r = y_r + iz_r \end{cases}, \quad r = 0, \dots, N/2-1 \quad (4.14)$$

Chamando A_k a TFD de $\{\alpha_r\}$, temos:

$$A_k = \frac{2}{N} \sum_{r=0}^{N/2-1} (y_r - iz_r) w_{N/2}^{-kr}$$

ou seja:

$$A_k = Y_k + iZ_k, \quad k = 0, \dots, N/2 - 1 \quad (4.15)$$

Então, processando a TFD da série $\{\alpha_r\}$ obtemos A_k . Porém, de (4.15) não é imediato obter Y_k e Z_k de que precisamos para o cálculo de X_k . Isto porque Y_k e Z_k são valores complexos. Usando a simetria da FFT (equação (4.13)):

$$X_k = X_{N-k}^*, \quad k = 0, \dots, N - 1 \quad (4.16)$$

o que pode ser expresso para Y_k , Z_k e A_k de $N/2$ termos:

$$\begin{aligned} Y_k &= Y_{N/2-k}^* \\ Z_k &= Z_{N/2-k}^* \end{aligned}, \quad k = 0, \dots, N/2 - 1 \quad (4.17)$$

Podemos então escrever:

$$A_k = Y_{N/2-k}^* + iZ_{N/2-k}^*, \quad k = 0, \dots, N/2 - 1 \quad (4.18)$$

mas também podemos escrever (4.15):

$$A_{N/2-k}^* = Y_{N/2-k}^* - iZ_{N/2-k}^*, \quad k = 0, \dots, N/2 - 1 \quad (4.19)$$

Somando ou subtraindo (4.18) e (4.19) pode-se chegar facilmente a:

$$\left. \begin{aligned} Y_k &= \frac{1}{2} (A_k + A_{N/2-k}^*) \\ Z_k &= -\frac{i}{2} (A_k - A_{N/2-k}^*) \end{aligned} \right\}, \quad k = 0, \dots, N/2 - 1 \quad (4.20)$$

Aplicando (4.4) temos finalmente:

$$X_k = \frac{1}{2} \left\{ \frac{1}{2} (A_k + A_{N/2-k}^*) - \frac{i}{2} (A_k - A_{N/2-k}^*) w_N^{-k} \right\}, \quad k = 0, \dots, N/2 - 1 \quad (4.21)$$

Resta calcular os valores da componente de corrente contínua $k = 0$ e de Nyquist $k = N/2$. A expressão (4.21) não vale para $k = 0$ pois o valor $A_{N/2}$ não é conhecido.

Substituindo $k = 0$ e $k = N/2$ em (4.4) temos:

$$\begin{aligned} X_0 &= \frac{1}{2}(Y_0 + Z_0) \\ X_{N/2} &= \frac{1}{2}(Y_0 - Z_0) \end{aligned} \quad (4.22)$$

Mas como Y_k e Z_k têm parte imaginária ímpar, Y_0 e Z_0 são necessariamente reais e, neste caso, podemos obter Y_0 e Z_0 diretamente de A_0 pela expressão (4.15):

$$\begin{aligned} Y_0 &= \text{Re}(A_0) \\ Z_0 &= \text{Im}(A_0) \end{aligned} \quad (4.23)$$

Com as equações (4.22) e (4.23) podemos obter X_0 e $X_{N/2}$.

4.4 Resolução em frequência e “zoom”

Aumentar a resolução em frequência, ou seja, diminuir:

$$\Delta f = \frac{1}{T} = \frac{1}{N\Delta t} \quad (4.24)$$

mantendo N (que é o tamanho da memória necessária) constante, implica em ter Δt maior, ou seja, ter a faixa de frequências de análise $(0, f_a/2)$ menor.

Portanto, a única maneira de aumentar a resolução em torno de uma dada frequência f_o seria aumentar N , pelo cálculo direto da TFD. Como veremos a seguir, é possível, pré-processando o sinal, aumentar a resolução sem aumentar N . Esta técnica é conhecida por análise em banda estreita com memória restrita ou “zoom – TFD”.

Esta técnica se baseia no deslocamento em frequência (“shift”) por modulação. Isto é, diminuindo a frequência de amostragem aumenta-se a resolução em torno de $f = 0$ mantendo N constante.

Se quisermos aumentar a resolução em torno da frequência f_o , podemos multiplicar o sinal por uma exponencial complexa $e^{-i2\pi f_o t}$, o que tem por efeito deslocar a parte do espectro que se deseja analisar para a origem. Depois disto, basta diminuir f_a .

A figura 4.6 mostra esquematicamente este procedimento.




figura 4.6. “Zoom – TFD”.

Reamostrando o sinal com $f'_a = f_a / Z$ temos que:

$$\Delta f' = \frac{\Delta f}{Z} \quad (4.25)$$

$$T' = N \Delta t' = Z N \Delta t \quad (4.26)$$

ou seja, a resolução aumenta de Z que é chamado fator “ZOOM”. É importante notar que o tempo de aquisição aumenta com o mesmo fator Z .

4.5 Analisadores de Fourier

Analisadores em tempo real ou analisadores de Fourier são instrumentos eletrônicos digitais operando com microprocessadores que calculam a FFT.

Para isto são basicamente constituídos (figura 4.8) de um filtro “*anti-aliasing*” e de um conversor analógico-digital (CAD) que realiza a conversão do sinal analógico no sinal digital; este sinal digitalizado é então armazenado numa memória. A frequência de

amostragem f_a deve ser ajustável para cobrir a faixa de 0 a 20 kHz para aplicações em vibrações e acústica.

Um analisador pode ser tanto um instrumento dedicado como um módulo de conversão A/D acoplado a um microcomputador ou estação de trabalho. Os módulos de aquisição de sinais, que incluem frequentemente microprocessadores vetoriais para cálculo da FFT, são denominados, em inglês, de “*front-end*”. Os sistemas dedicados são geralmente mais robustos e, por isso, adequados a aplicações *in situ*, enquanto os sistemas com “*front end*” são mais versáteis e mais adequados para ambientes controlados de laboratório.

Filtro anti-rebatimento (“*anti-aliasing*”)

Filtro passa-baixas com frequência de corte ajustável de maneira a garantir a condição $f_{max} < f_a/2$ (“*anti-aliasing*”). Este filtro tem que ser analógico antes da primeira digitalização. Pode-se optar por filtros analógicos de frequência de corte fixa ou variável em função da gama de frequências de análise. No caso de um filtro de frequência de corte fixa, geralmente é necessário realizar uma re-amostragem, e para isto, é utilizado um filtro digital “*anti-aliasing*” permitindo um aumento na resolução.

Conversor Analógico – Digital (CAD)

Realizam a discretização do sinal analógico com uma dada frequência de amostragem e a quantização da amplitude em 2^b faixas, onde b é o número de bits do conversor. Na figura 4.7 mostra-se o mapeamento analógico-digital, onde o sinal analógico varia entre V_{min} e V_{max} . O sinal analógico é mapeado neste exemplo com quatro bits variando de 0000 a 1111. Se o conversor permite mapear 0v (0000) a 15v (1111), e se tem na entrada 10,75v, então o CAD mapeará em 1011 que na verdade representa 10,5v existindo um erro de 0,25v.




figura 4.7. Mapeamento analógico-digital

Processador da TFD

São circuitos digitais com microprocessadores para cálculo da TFD através dos algoritmos otimizados de FFT. O primeiro processador foi patenteado por Richard A. Smith em 1968 através da *Bell Telephone Laboratories Inc.* Este processador utiliza o algoritmo de Cooley (1965). Hoje em dia existem processadores velozes usando a tecnologia MOS ou CMOS.

Monitores

Monitores ou tubo de raios catódicos para visualização do conteúdo da memória sinal no tempo e transformada. Na atualidade existem monitores de alta resolução e que conseguem mostrar tanto o sinal no tempo ou o espectro do sinal em tempo real. O MATLAB oferece este tipo de aplicações adicionando placas de processamento digital de sinais (DSP).




figura 4.8. Configuração típica de um analisador de Fourier

4.6 Exercícios

4.1. Gerar um sinal periódico cujas componentes de frequência são de 2000 Hz e 4000 Hz, amplitude unitária, e cuja frequência de amostragem é de 10000 Hz. A seguir, realizar um “zoom” na faixa de 1500 Hz a 2500 Hz.

4.2. Seja o sinal contínuo $x(t)$ cuja frequência máxima é f_{max} Hz amostrado a intervalos de T gerando o sinal discretizado $x(n)$. Este sinal é submetido a uma re-amostragem de $T' = 2T$. Mostrar graficamente os espectros resultantes do sinal contínuo, sinal discretizado e sinal re-amostrado.

Determinar o T de amostragem mínimo que permita a reconstrução de $x(t)$.

4.3. Seja
$$X_k = \frac{1}{N} \sum_{n=0}^{N-1} x_n w_N^{-kn}, \quad k = 0, \dots, N-1$$

Onde $N = M^2$. Mostrar que X_k pode ser expresso como:

$$X_k = y_k^* \frac{1}{N} \sum_{n=0}^{N-1} (x_n y_k^*)(y_{k-n}), \quad k = 0, \dots, N-1 \quad \text{onde } y_n = e^{i\frac{\pi}{N}n^2}, \quad -\infty < n < \infty$$

5 - Sinais aleatórios

Um sinal é considerado aleatório quando seu comportamento futuro no tempo não pode ser previsto. Trata-se de sinais de caráter estacionário (não transitório), porém não periódicos. Por não serem periódicos, estes sinais não podem ser representados pela série de Fourier e, por não serem transitórios, não podem ser representados pela transformada de Fourier. Para estes sinais é preciso desenvolver, portanto, outra forma de representação espectral.

O estudo destes sinais e da relação entre entrada e saída de sistemas lineares quando sujeitos a excitações deste tipo é então feito através da aplicação de conceitos estatísticos para analisar as características médias do sinal e dos estimadores das grandezas de interesse. Vamos nos servir da teoria de processos estocásticos sem, entretanto, nos aprofundarmos no assunto, o que fugiria ao escopo deste texto. Para uma abordagem mais aprofundada recomendam-se as referências ^[1] a ^[2].

Considere um processo estocástico no qual cada amostra é um sinal aleatório $x_k(t)$, $k = 1, 2, 3, \dots$. A figura 5.1 mostra esquematicamente a representação gráfica de um tal processo.




figura 5.1. Representação gráfica esquemática de um processo estocástico

Devido ao seu caráter aleatório, só é possível investigar as características médias no tempo do processo, tais como valor médio e o valor médio quadrático, representadas pelas equações (5.1) e (5.2), respectivamente,

$$\mu_x(k) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T x_k(t) dt \quad (5.1)$$

$$\varphi_x^2(k) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T x_k^2(t) dt \quad (5.2)$$

ou através de médias de conjunto tomadas entre as realizações de um processo para um dado instante de tempo, dadas pelas equações:

$$\mu_x(t) = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N x_k(t) \quad (5.3)$$

$$\varphi_x^2(t) = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N x_k^2(t) \quad (5.4)$$

Assim com a média e o valor médio quadrático, outros momentos estatísticos^[1] podem ser definidos através da média no tempo e da média de conjunto. Dentre as funções médias, ou momentos estatísticos, que podem ser calculados para um processo estocástico, destacam-se as **funções de correlação**. A *função de autocorrelação* é definida como a média dos produtos dos valores do sinal nos tempos t e $t + \tau$ em função de τ

$$R_{xx}(k, \tau) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T x_k(t) x_k(t + \tau) dt \quad (5.5)$$

$$R_{xx}(t, \tau) = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N x_k(t) x_k(t + \tau) \quad (5.6)$$

Denominam-se *estacionários* os processos cujas propriedades médias no tempo se mantêm constantes. Quando as propriedades médias computadas no tempo para qualquer sinal (realização) individual são iguais às propriedades computadas a partir de médias de conjunto, o processo é denominado *ergódico*. Desta maneira, para um processo estacionário ergódico

$$\mu_x(t) = \mu_x(k) = \mu_x \quad (5.7)$$

$$\varphi_x^2(t) = \varphi_x^2(k) = \varphi_x^2 \quad (5.8)$$

$$R_{xx}(k, \tau) = R_{xx}(t, \tau) = R_{xx}(\tau) \quad (5.9)$$

ou seja, para um processo ergódico, as propriedades médias obtidas a partir de uma única realização são suficientes para caracterizar o processo. Ou ainda, de outra maneira, um sinal considerado ergódico pode ser medido continuamente durante um tempo qT sendo então desmembrado em q amostras de duração T de forma a caracterizar o processo.

A maneira usual de representar um sinal aleatório no domínio do tempo é através da sua função de autocorrelação, calculada através da média temporal. Vamos mostrar que a transformada de Fourier desta função, que é transitória para um sinal aleatório, fornece uma representação espectral conveniente. Cabe, portanto, investigar algumas das propriedades das funções de correlação.

Para um sinal $x(t)$ aleatório estacionário de média $\mu(x)$, pode-se definir a *função de autocovariância*

$$C_{xx}(\tau) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T (x(t) - \mu_x)(x(t + \tau) - \mu_x) dt \quad (5.10)$$

A relação entre a função de autocorrelação e a função de autocovariância é facilmente obtida a partir de suas definições como

$$C_{xx}(\tau) = R_{xx}(\tau) - \mu_x^2 \quad (5.11)$$

de onde fica claro que as funções são idênticas para sinais de média nula. É usual eliminar a componente média de um sinal e tratá-la separadamente na análise. Por esta razão pode-se trabalhar indiferentemente com as funções da autocorrelação e autocovariância, sendo mais comum utilizar a primeira.

Assim com foi definida a função de autocorrelação, pode-se também definir a função de intercorrelação entre dois sinais aleatórios x_k e y_k .

$$R_{xy}(k) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T x_k(t) y_k(t + \tau) dt \quad (5.12)$$

Dado que as integrais das equações (5.5) e (5.10) podem ser feitas tanto no intervalo de tempo $[0, T]$ como no intervalo $[-T/2, T/2]$, fazendo uma simples substituição de variáveis, é fácil mostrar que

$$R_{xx}(\tau) = R_{xx}(-\tau) \quad (5.13)$$

$$R_{xy}(\tau) = R_{yx}(-\tau) \quad (5.14)$$

Considerando sinais de média nula, é interessante investigar o problema da regressão linear dos pontos dados pelas coordenadas $(x(t), y(t))$. Trata-se do problema de

passar uma reta entre estes pontos. A reta passa pela origem (sinais de média nula) e tem coeficiente angular β . Para isso constitui-se a função erro quadrático

$$e(\tau, \beta) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T [x(t) - \beta y(t + \tau)]^2 dt \quad (5.15)$$

A reta que minimiza o erro pode ser obtida de

$$\frac{\partial e}{\partial \beta} = 0 \quad (5.16)$$

o que dá a expressão de β

$$\beta = \frac{\lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T x(t)y(t + \tau)dt}{\lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T y^2(t + \tau)dt} = \frac{R_{xy}(\tau)}{\phi_y^2} \quad (5.17)$$

Substituindo esta expressão de β na equação (5.15) obtém-se o erro mínimo

$$e_{\min}(\tau) = \phi_x^2 \left(1 - \frac{R_{xy}^2(\tau)}{\phi_x^2 \phi_y^2} \right) = \phi_x^2 (1 - \rho_{xy}^2(\tau)) \quad (5.18)$$

onde $\rho_{xy}^2(\tau)$ é o coeficiente que mede o grau de relação linear, chamado de *coeficiente de correlação*. Como o erro é quadrático e, portanto, sempre maior ou igual a zero, temos que, para sinais de média nula

$$\rho_{xy}^2 = \frac{R_{xy}^2}{\phi_x^2 \phi_y^2} \leq 1 \quad (5.19)$$

o que implica

$$R_{xy}^2(\tau) \leq \phi_x^2 \phi_y^2 = R_{xx}(0)R_{yy}(0) \quad (5.20)$$

ou, no caso de $y(t) \equiv x(t)$

$$R_{xx}^2(\tau) \leq R_{xx}^2(0) \quad (5.21)$$

e, finalmente

$$|R_{xx}(\tau)| \leq R_{xx}(0) \quad (5.22)$$

É interessante notar que, para sinais de média não nula μ_x e desvio padrão σ_x , este resultado é expresso por

$$\mu_x^2 - \sigma_x^2 \leq R_{xx}(\tau) \leq \mu_x^2 + \sigma_x^2 \quad (5.23)$$

onde

$$\sigma_x^2 = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T (x(t) - \mu_x)^2 dt = \phi_x^2 - \mu_x^2 \quad (5.24)$$

A análise das funções de correlação tem inúmeras aplicações em engenharia. A grande maioria delas, porém, também pode ser tratada com a análise espectral, na qual nos concentraremos aqui. Mesmo porque o cálculo eficiente das funções de correlação pode ser feito a partir dos espectros para aproveitar a eficiência dos algoritmos da transformada de Fourier rápida. Vamos, portanto, seguir na busca de uma representação espectral para os sinais aleatórios.

5.1 Densidade Espectral de Potência

Nossa abordagem consistirá em, primeiramente, definir um espectro para sinais aleatórios de diferentes maneiras para, depois, demonstrar que estas definições se equivalem.

Definição 1: Espectro via Filtragem Analógica

A definição mais intuitiva de espectro de sinais aleatórios pode ser feita utilizando o conceito do filtro passa-banda ideal. Se o sinal aleatório for filtrado por um filtro passa-banda ideal centrado na frequência f e com largura de banda Δf e se o valor médio quadrático do sinal na saída do filtro for $\phi_x^2(f, \Delta f)$, pode-se definir a *Densidade Espectral de Potência* (DEP) como

$$G_{xx}^{(1)}(f) = \lim_{\Delta f \rightarrow 0} \frac{\phi_x^2(f, \Delta f)}{\Delta f}; \quad f \geq 0 \quad (5.25)$$

onde $\phi_x^2(f, \Delta f) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T x^2(t, f, \Delta f) dt$.

A figura 5.2 ilustra o procedimento de filtragem.




figura 5.2: Sinal aleatório filtrado por um filtro passa-banda ideal

Da definição acima é evidente que o valor médio quadrático do sinal para uma dada banda de frequências $[f_1, f_2]$ pode ser obtido a partir da DEP

$$\phi_x^2(f_1, f_2) = \int_{f_1}^{f_2} G_{xx}^{(1)}(f) df \quad (5.26)$$

Definição 2: Espectro via Transformada de Fourier Finita

Dividindo um sinal aleatório em q amostras $x_k(t, T)$ da forma:

$$x_k(t, T) = \begin{cases} x(t); & t_k \leq t \leq t_k + T \\ 0 & \text{fora do intervalo} \end{cases}$$

pode-se definir a Transformada de Fourier Finita (TFF) de um sinal num intervalo T como:

$$X_k(f, T) = \int_{-\infty}^{+\infty} x_k(t, T) e^{-i2\pi ft} dt = \int_{t_k}^{t_k+T} x(t) e^{-i2\pi ft} dt \quad (5.27)$$

A densidade espectral de potência definida a partir da Transformada de Fourier Finita é então dada por

$$S_{xx}^{(2)}(f) = \lim_{T \rightarrow \infty} \lim_{q \rightarrow \infty} \frac{1}{qT} \sum_{k=1}^q |X_k(f, T)|^2 \quad (5.28)$$

De forma análoga, define-se a *Densidade Espectral de Potência Cruzada* entre dois sinais:

$$S_{xy}^{(2)}(f) = \lim_{T \rightarrow \infty} \lim_{q \rightarrow \infty} \frac{1}{qT} \sum_{k=1}^q X_k^*(f, T) Y_k(f, T) \quad (5.29)$$

Definição 3: Espectro via funções de correlação

Dado que é usual representar um sinal aleatório no domínio do tempo como uma função de autocorrelação calculada através de média temporal, é natural que a representação desse sinal no domínio da frequência seja dada pela sua transformada de Fourier

$$S_{xx}^{(3)}(f) = \int_{-\infty}^{+\infty} R_{xx}(\tau) e^{-i2\pi f\tau} d\tau \quad (5.30)$$

e analogamente

$$S_{xy}(f) = \int_{-\infty}^{+\infty} R_{xy}(\tau) e^{-i2\pi f\tau} d\tau \quad (5.31)$$

A partir desta definição é fácil mostrar algumas propriedades importantes da DEP. Primeiramente, como a função de autocorrelação é uma função real par (equação (5.13)), a sua transformada também o é, i. e.,

$$S_{xx}(f) = S_{xx}(-f)$$

Como a intercorrelação é uma função real, fazendo o conjugado da equação (5.31) pode-se obter

$$S_{xy}(-f) = S_{xy}^*(f) = S_{yx}(f)$$

Nas definições da DEP feitas até aqui apareceram duas notações, $G_{xx}(f)$ e $S_{xx}(f)$. A primeira é definida para frequências positivas (*one sided* em inglês) enquanto que a segunda, obtida através da transformada de Fourier, é definida para frequências tanto positivas quanto negativas (*double sided* em inglês). A conservação da energia do sinal exige que:

$$G_{xx}(f) = 2S_{xx}(f), \quad f \geq 0$$

$$G_{xx}(f) = 0, \quad f \leq 0$$

A figura 5.3 ilustra a representação *one-sided* e *double-sided* da DEP. Observe que a definição anterior pode também ser aplicada à DEP cruzada.




figura 5.3. Densidade Espectral de Potência "one-sided", $G_{xx}(f)$, e "double-sided", $S_{xx}(f)$.

Em função das definições anteriores, temos que

$$R_{xx}(\tau) = \int_{-\infty}^{+\infty} S_{xx}(f) e^{i2\pi f\tau} df = \int_0^{\infty} G_{xx}(f) e^{i2\pi f\tau} df$$

$$R_{xx}(0) = \varphi_x^2 = \int_0^{\infty} G_{xx}(f) df$$

$$\varphi_x^2(f_1, f_2) = \int_{f_1}^{f_2} G_{xx}(f) df$$

5.2 Equivalência entre as definições

Se pudermos mostrar que as três definições apresentadas são equivalentes, teremos definido sem ambigüidade uma representação espectral para sinais aleatórios. A prova de equivalência entre as definições 1 e 2 é conhecida como teorema de Wiener-Khintchine^[3] e será brevemente exposta aqui.

Pela definição do valor médio quadrático temos que

$$\varphi_x^2(k) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T x_k^2(t) dt = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\infty}^{+\infty} x_k^2(t, T) dt$$

Pelo teorema da energia, dado pela equação (1.35), temos que:

$$\int_{-\infty}^{+\infty} x_k^2(t, T) dt = \int_{-\infty}^{+\infty} |X_k(f, T)|^2 df \quad (5.32)$$

donde

$$\varphi_x^2(k) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\infty}^{+\infty} |X_k(f, T)|^2 df \quad (5.33)$$

Como o sinal $x_k(t, T)$ é suposto real, o valor absoluto de sua transformada de Fourier é uma função par,

$$\varphi_x^2(k) = 2 \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^{+\infty} |X_k(f, T)|^2 df \quad (5.34)$$

Se o sinal $x_k(t)$ for filtrado em torno da frequência f_0 arbitrária por um filtro passa-banda ideal de largura Δf , temos que seu valor médio quadrático será

$$\varphi_x^2(k, f_0, \Delta f) = 2 \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^{+\infty} |H(f)|^2 |X_k(f, T)|^2 df \quad (5.35)$$

onde $H(f)$ é a função de resposta em frequência do filtro ideal

$$|H(f)| = \begin{cases} 1, & \text{se } f_0 - \frac{\Delta f}{2} \leq f \leq f_0 + \frac{\Delta f}{2} \\ 0, & \text{caso contrário} \end{cases} \quad (5.36)$$

Substituindo (5.36) em (5.35) temos

$$\varphi_x^2(k, f_0, \Delta f) = \int_{f_0 - \Delta f/2}^{f_0 + \Delta f/2} \left[2 \lim_{T \rightarrow \infty} \frac{1}{T} |X_k(f, T)|^2 \right] df \quad (5.37)$$

Fazendo, agora, a média de conjunto de (5.37) de modo a eliminar os índices k das amostras

$$\varphi_x^2(f_0, \Delta f) = \int_{f_0 - \Delta f/2}^{f_0 + \Delta f/2} \left[2 \lim_{T \rightarrow \infty} \lim_{q \rightarrow \infty} \frac{1}{qT} \sum_{k=1}^q |X_k(f, T)|^2 \right] df \quad (5.38)$$

Mas, pela definição 1 da DEP, temos,

$$\varphi_x^2(f_0, \Delta f) = \int_{f_0 - \Delta f/2}^{f_0 + \Delta f/2} G_{xx}^{(1)}(f) df \quad (5.39)$$

de onde conclui-se que

$$G_{xx}^{(1)}(f) = 2 \lim_{T \rightarrow \infty} \lim_{q \rightarrow \infty} \frac{1}{qT} \sum_{k=1}^q |X_k(f, T)|^2 \equiv 2S_{xx}^{(2)}(f) \quad (5.40)$$

o que prova a equivalência das definições 1 e 2 da DEP. Resta ainda provar a equivalência entre as duas primeiras definições e a definição 3. Para isso vamos partir da definição 2, porém em sua forma generalizada para dois sinais distintos, $x(t)$ e $y(t)$. A demonstração desejada é um caso particular desta, onde $y(t) = x(t)$.

Definimos inicialmente, partindo da definição 2,

$$\tilde{S}_{xy}(k, f, T) = \frac{1}{T} X_k^*(f, T) Y_k(f, T) \quad (5.41)$$

de modo que

$$S_{xx}^{(2)}(f) = \lim_{T \rightarrow \infty} \lim_{q \rightarrow \infty} \frac{1}{q} \sum_{k=1}^q \tilde{S}_{xx}(k, f, T) \quad (5.42)$$

Usando α e β no lugar de t nas expressões das transformadas de Fourier finitas de $x_k(t, T)$ e $y_k(t, T)$, tem-se

$$\begin{aligned} \tilde{S}_{xy}(k, f, T) &= \frac{1}{T} \int_0^T x_k(\alpha) e^{i2\pi f\alpha} d\alpha \int_0^T y_k(\beta) e^{-i2\pi f\beta} d\beta \\ &= \frac{1}{T} \int_0^T \int_0^T x_k(\alpha) e^{i2\pi f\alpha} y_k(\beta) e^{-i2\pi f\beta} d\alpha d\beta \end{aligned} \quad (5.43)$$

Fazendo uma substituição de variáveis $\tau = \beta - \alpha$ e fazendo a dupla integração em τ e α ao invés de α e β , pode-se dividir o domínio de integração de forma que

$$\int_0^T \int_0^T d\alpha d\beta = \int_{-\alpha}^{T-\alpha} \int_0^T d\alpha d\tau = \int_{-T-\tau}^0 \int_0^T d\alpha d\tau + \int_0^{T-\tau} \int_0^T d\alpha d\tau \quad (5.44)$$

A figura 5.20 ilustra os domínios de integração antes e depois da substituição de variáveis.




figura 5.4: Domínio de integração antes e depois da substituição de variáveis

Aplicando a divisão de domínio da equação (5.44) na equação (5.43) tem-se

$$\begin{aligned} \tilde{S}_{xy}(k, f, T) = & \int_{-T}^0 \frac{1}{T} \int_{-\tau}^T x_k(\alpha) y_k(\alpha + \tau) d\alpha e^{-i2\pi f \tau} d\tau + \\ & \int_0^T \frac{1}{T} \int_0^{T-\tau} x_k(\alpha) y_k(\alpha + \tau) d\alpha e^{-i2\pi f \tau} d\tau \end{aligned} \quad (5.45)$$

Fazendo a média de conjunto de (5.45) tem-se

$$\begin{aligned} \tilde{S}_{xy}(f, T) = & \int_{-T}^0 \frac{1}{T} \int_{-\tau}^T \left[\lim_{q \rightarrow \infty} \frac{1}{q} \sum_{k=1}^q x_k(\alpha) y_k(\alpha + \tau) \right] d\alpha e^{-i2\pi f \tau} d\tau + \\ & \int_0^T \frac{1}{T} \int_0^{T-\tau} \left[\lim_{q \rightarrow \infty} \frac{1}{q} \sum_{k=1}^q x_k(\alpha) y_k(\alpha + \tau) \right] d\alpha e^{-i2\pi f \tau} d\tau \end{aligned} \quad (5.46)$$

Mas, por uma definição de intercorrelação análoga à definição da equação (5.6), tem-se

$$R_{xy}(\tau) = \lim_{q \rightarrow \infty} \frac{1}{q} \sum_{k=1}^q x_k(\alpha) y_k(\alpha + \tau) \quad (5.47)$$

Substituindo (5.47) em (5.46), pode-se escrever

$$\tilde{S}_{xy}(f, T) = \int_{-T}^0 R_{xy}(\tau) \left[\frac{1}{T} \int_{-\tau}^T d\alpha \right] e^{-i2\pi f \tau} d\tau + \int_0^T R_{xy}(\tau) \left[\frac{1}{T} \int_0^{T-\tau} d\alpha \right] e^{-i2\pi f \tau} d\tau \quad (5.48)$$

É possível chegar a uma expressão única para os termos entre colchetes na equação (5.48) já que

$$\left[\frac{1}{T} \int_{-\tau}^T d\alpha \right] = \frac{T + \tau}{T} = \frac{T - |\tau|}{T} ; \quad \tau \leq 0 \quad (5.49)$$

$$\left[\frac{1}{T} \int_0^{T-\tau} d\alpha \right] = \frac{T - \tau}{T} = \frac{T - |\tau|}{T} ; \quad \tau \geq 0 \quad (5.50)$$

de onde (5.48) pode ser reescrita como

$$\tilde{S}_{xy}(f, T) = \int_{-T}^T \frac{T - |\tau|}{T} R_{xy}(\tau) e^{-i2\pi f \tau} d\tau \quad (5.51)$$

que no limite quando $T \rightarrow \infty$ corresponde à definição 2

$$S_{xy}^{(2)}(f) = \lim_{T \rightarrow \infty} \tilde{S}_{xy}(f, T) = \int_{-\infty}^{+\infty} R_{xy}(\tau) e^{-i2\pi f\tau} d\tau \quad (5.52)$$

donde, como queríamos demonstrar,

$$S_{xy}^{(2)}(f) = S_{xy}^{(3)}(f) \quad (5.53)$$

A igualdade

$$S_{xx}^{(2)}(f) = S_{xx}^{(3)}(f) \quad (5.54)$$

é um caso particular de (5.53)

Como, na prática, só é possível um T finito, o cálculo do DEP por esta definição está sujeito a um efeito de janelamento da função de correlação envolvida por uma janela triangular, como mostra a equação (5.51).

As três definições anteriores são equivalentes, ou seja, pode-se, a partir de qualquer uma delas chegar às demais apenas com manipulação algébrica. Entretanto, as três definições são úteis, pois, dependendo da técnica utilizada na obtenção da DEP, é mais interessante recorrer a uma ou outra para a interpretação dos resultados e respectivas estimativas de erros envolvidos, já que cada uma das definições anteriores envolve limites que, de alguma maneira, do ponto de vista prático, são apenas idealizações. A definição 1 é útil quando se utiliza um filtro passa banda analógico na análise dos sinais. O uso da definição 2 é interessante na aplicação de equipamentos e técnicas digitais na análise dos sinais de medição, que utilizam algoritmos discretos. A definição 3 é talvez a mais apropriada para investigações analíticas, que envolvam manipulações simbólicas.

5.3 Densidade espectral de potência via TFD

Feitas as definições da DEP e demonstrada a sua equivalência, cabe investigar as formas de obtê-la numericamente. A Definição 2, via transformada de Fourier finita, é o caminho mais imediato. Podemos aproximar esta transformada pela TFD; como já foi visto anteriormente:

$$X_k(f = r/T, T) = TX_r^{(k)} ; \quad r = 0, N-1. \quad (5.55)$$

onde $X_r^{(k)}$ é a TFD definida pela equação

$$X_r^{(k)} = \frac{1}{N} \sum_{n=0}^{N-1} x_n^{(k)} w_N^{-nr} \quad ; \quad r = 0, \dots, N-1$$

da série:

$$x_n^{(k)} = x_k \left(t = nT/N \right) ; \quad n = 0, N-1. \quad (5.56)$$

Desta forma, pode-se obter a expressão da DEP via TFD (ver Eq. (5.28)):

$$S_{xx} \left(f = r/T \right) \cong \frac{1}{qT} \sum_{k=1}^q \left| TX_r^{(k)} \right|^2 \quad ; \quad r=0, N-1. \quad (5.57)$$

ou, finalmente,

$$S_{xx} \left(f = r/T \right) \cong \frac{1}{\Delta f} \frac{1}{q} \sum_{k=1}^q \left| X_r^{(k)} \right|^2 \quad ; \quad r=0, N-1. \quad (5.58)$$

onde $\Delta f = 1/T$. Para $x_k(t, T)$ em unidades [U], a DEP é dada em $[U^2/\text{Hz}]$.

De forma análoga, o interespectro entre dois sinais $x(t)$ e $y(t)$ pode ser aproximado por:

$$S_{xy} \left(f = r/T \right) \cong \frac{1}{\Delta f} \frac{1}{q} \sum_{k=1}^q X_r^{(k)*} Y_r^{(k)} \quad ; \quad r=0, N-1. \quad (5.59)$$

onde $Y_r^{(k)}$ é a TFD de $y_k(t, T)$.

A equação (5.51), dada por:

$$\tilde{S}_{xy}(f, T) = \int_{-T}^T \frac{T - |\tau|}{T} R_{xy}(\tau) e^{-i2\pi f \tau} d\tau$$

expressa a aproximação da DEP via TFF. Esta aproximação convergirá para o valor exato da DEP (que é uma abstração matemática para sinais obtidos experimentalmente) na medida em que $T \rightarrow \infty$ e $q \rightarrow \infty$. Cabe, portanto, investigar a precisão com que a expressão aproxima a DEP para T e q finitos. Uma discussão mais aprofundada deste tema está fora do escopo deste texto, porém algumas diretrizes conceituais e considerações de ordem prática serão feitas a seguir.

A equação (5.51) deixa claro que a DEP obtida a partir da transformada de Fourier finita corresponde à transformada da função de autocorrelação (caso em que $x \equiv y$ em $\tilde{S}_{xy}(f, T)$) observada através de uma janela triangular dada pela expressão

$$w(t) = \begin{cases} \frac{T-|t|}{T}; & -T \leq t \leq T \\ 0; & \text{caso contrário} \end{cases}.$$

Dado que a expressão (5.58) pode ser entendida como uma implementação da equação

$$S_{xy}^{(2)}(f) = \lim_{T \rightarrow \infty} \lim_{q \rightarrow \infty} \frac{1}{qT} \sum_{k=1}^q X_k^*(f, T) Y_k(f, T),$$

onde a TFF é calculada a partir da TFD, pode-se concluir que a DEP estimada via TFD é distorcida de duas formas:

- * pelo efeito da janela triangular,

$$\tilde{S}_{xx}(f) = \int_{-\infty}^{+\infty} W(\xi - f) S_{xx}(\xi) d\xi \quad (5.60)$$

- * pelo efeito de *leakage* da TFD na estimação da TFF

A expressão da transformada da janela triangular, que pode ser interpretada como um *filtro equivalente* ao processo de obtenção da DEP via TFD, pode ser facilmente obtida:

$$W(f) = \int_{-T}^T \frac{T-|\tau|}{T} e^{-i2\pi f\tau} d\tau \quad (5.61)$$

Pela simetria da janela, tem-se:

$$W(f) = 2 \int_0^T \frac{T-\tau}{T} \cos(2\pi f\tau) d\tau = T [\text{sinc}(\pi fT)]^2 \quad (5.62)$$

Além do efeito do janelamento e do *leakage*, existe erro na estimação da DEP devido ao número de médias ser necessariamente finito. Este erro estatístico pode ser estimado [3] e ele cai com a raiz do número de médias. Dado um certo intervalo de tempo de aquisição dos sinais aleatórios, existe, portanto, um compromisso entre aumentar o número de médias (e diminuir o erro estatístico) e aumentar a duração de cada amostra (e diminuir o erro de janelamento).

5.4 Janela de Hanning

Para diminuir o erro do *leakage* utiliza-se geralmente a janela de Hanning, vista no Capítulo 1 (janelas de observação).

Aplicando a janela de Hanning, definida pela equação (1.46), numa amostra do sinal aleatório discretizado $x_n^{(k)}$, $n = 0, \dots, N-1$, temos o sinal *janelado*, que é dado por $x_n^{(k)} = x_n^{(k)} h_n$, onde h_n é a janela discretizada, dada por:

$$h_n = \frac{1}{2} - \frac{1}{4} e^{in2\pi/N} - \frac{1}{4} e^{-in2\pi/N} = \frac{1}{2} - \frac{1}{4} w_N^n - \frac{1}{4} w_N^{-n}$$

A TFD do sinal *janelado* é dada por:

$$\bar{X}_r^{(k)} = \sum_{n=0}^{N-1} x_n^{(k)} h_n w_N^{-nr} ; \quad r = 0, \dots, N-1 \quad (5.63)$$

$$\bar{X}_r^{(k)} = \frac{1}{2} \sum_{n=0}^{N-1} x_n^{(k)} w_N^{-nr} - \frac{1}{4} \sum_{n=0}^{N-1} x_n^{(k)} w_N^{-n(r-1)} - \frac{1}{4} \sum_{n=0}^{N-1} x_n^{(k)} w_N^{-n(r+1)}$$

de onde tem-se

$$\bar{X}_r^{(k)} = \frac{1}{2} X_r - \frac{1}{4} X_{r-1} - \frac{1}{4} X_{r+1} \quad (5.64)$$

Estimando a DEP *one-sided* pela TFD temos, para o sinal *janelado*:

$$\bar{G}_r = \frac{2}{\Delta f} \frac{1}{q} \sum_{r=1}^q |\bar{X}_r^{(k)}|^2 \quad (5.65)$$

Substituindo na equação (5.65) a expressão (5.64) tem-se:

$$\bar{G}_r \cong \frac{2}{\Delta f} \frac{1}{q} \sum_{k=1}^q \left(\frac{1}{4} |\bar{X}_r^{(k)}|^2 + \frac{1}{16} |\bar{X}_{r-1}^{(k)}|^2 + \frac{1}{16} |\bar{X}_{r+1}^{(k)}|^2 + \text{termos cruzados} \right) \quad (5.66)$$

Considerando que as médias dos termos cruzados se anulam num sinal aleatório, tem-se:

$$\bar{G}_r \cong \frac{2}{\Delta f} \frac{1}{q} \sum_{k=1}^q \left(\frac{1}{4} |\bar{X}_r^{(k)}|^2 + \frac{1}{16} |\bar{X}_{r-1}^{(k)}|^2 + \frac{1}{16} |\bar{X}_{r+1}^{(k)}|^2 \right)$$

de onde,

$$\bar{G}_r \cong \left(\frac{1}{4} G_r + \frac{1}{16} G_{r-1} + \frac{1}{16} G_{r+1} \right) \quad (5.67)$$

Levando em consideração que a DEP é suave na região de frequência $f = r\Delta f$, ou seja $G_r \approx G_{r-1} \approx G_{r+1}$, então a equação (5.67) pode-se escrever como:

$$\overline{G}_r \cong \frac{3}{8} G_r \quad (5.68)$$

Ou seja, aplicar a janela de Hanning tem o efeito de um alisamento (*smoothing*) da DEP com ponderação de valor de $1/4$ para as linhas de frequência vizinhas. Para corrigir a atenuação da potência causada pela aplicação da janela de Hanning, deve-se multiplicar o resultado pelo coeficiente de valor $8/3$.

5.5 Circularidade e adição de zeros

Vamos demonstrar que a função de correlação cruzada (e também a de autocorrelação) computada pela TFD inversa da DEP é *circular*. O erro de *circularidade* consiste em periodizar artificialmente as amostras de sinal aleatório observadas, isto é, a função de correlação *circular* é definida por:

$$R_r = \frac{1}{N} \sum_{s=0}^{N-1} x_s y_{s+r} \quad (5.69)$$

com $y_{s+r} = y_{s+r-N}$ se $s+r \geq N$. Na verdade, R_r é uma estimativa da função de correlação cruzada entre $x(t)$ e $y(t)$ com $\tau = r\Delta t$, já que N é finito. Para provar que esta é uma estimativa obtida pela TFD inversa da DEP, por sua vez estimada pela TFD, chamemos de $\tilde{S}_k$ a TFD de R_r

$$\tilde{S}_k = \frac{1}{N} \sum_{r=0}^{N-1} R_r w_N^{-kr} \quad (5.70)$$

Substituindo (5.69) em (5.70) vem:

$$\begin{aligned} \tilde{S}_k &= \frac{1}{N} \sum_{r=0}^{N-1} \left(\frac{1}{N} \sum_{s=0}^{N-1} x_s y_{s+r} \right) w_N^{-kr} \\ &= \frac{1}{N} \sum_{s=0}^{N-1} x_s w_N^{ks} \frac{1}{N} \sum_{r=0}^{N-1} y_{s+r} w_N^{-k(s+r)} \end{aligned} \quad (5.71)$$

como y_s é periódica de período N , é fácil ver que:

$$\tilde{S}_k = X_k^* Y_k \quad (5.72)$$

o que implica:

$$R_r = \sum_{k=0}^{N-1} X_k^* Y_k W_N^{kr} = \sum_{k=0}^{N-1} \tilde{S}_k W_N^{kr} \quad (5.73)$$

Existem maneiras de evitar a circularidade da função de correlação (auto ou cruzada) que consistem em *zerar* parte dos sinais adquiridos ou acrescentar zeros a eles.

Por exemplo, considere que $x(t)$ e $y(t)$ foram adquiridos com $f_a = 1/\Delta t$ e número de pontos $2N$. Zerando N pontos do sinal $x(t)$ (figura 5.9) tem-se:

$$R_r = \frac{1}{2N} \sum_{s=0}^{2N-1} x_s y_{s+r} = \frac{1}{2N} \left(\sum_{s=0}^{N-1} x_s y_{s+r} + \sum_{s=N}^{2N-1} x_s y_{s+r} \right) \quad (5.74)$$

onde a segunda somatória é nula para $r = 0, N-1$ pois $x_s = 0$; $s \geq N$. Daí pode-se escrever:

$$R_r = \frac{1}{2} \hat{R}_r; \quad r = 0, N-1 \quad (5.75)$$

onde

$$\hat{R}_r = \frac{1}{N} \sum_{s=0}^{N-1} x_s y_{s+r} \quad (5.76)$$

que é, neste caso, um estimador *não circular* de $R_{xy}(\tau)$.




figura 5.9. Zerando metade dos pontos $x(t)$ para evitar a circularidade

Quando não se deseja perder metade dos pontos adquiridos, como é feito neste caso (ainda que os N pontos restantes possam ser utilizados para estimar valores da função de correlação cruzada para τ negativo, *zerando* então os N primeiros pontos de x), pode-se apenas acrescentar N zeros a cada sinal, adquiridos com N pontos desta vez:

$$x_s = 0; \quad s \geq N$$

$$y_s = 0; \quad s \geq N$$

A somatória que computa a correlação cruzada pode ser escrita:

$$R_r = \frac{1}{2N} \sum_{s=0}^{N-r-1} x_s y_{s+r} + \frac{1}{2N} \sum_{s=N-r}^{2N-1} x_s y_{s+r-2N}; \quad r = 0, N-1 \quad (5.77)$$

onde o segundo somatório se anula. Portanto

$$R_r = \frac{N-r}{2N} \hat{R}_r \quad (5.78)$$

ou seja, um estimador não circular é obtido da TFD inversa dos sinais com N zeros adicionados fazendo $\frac{2N}{N-r} R_r; r = 0, N-1$.

É interessante comentar, neste ponto, que a convolução calculada pela TFD inversa também sofre do problema de circularidade. É fácil mostrar, por analogia à correlação, que a convolução calculada pela TFD inversa.

$$\Gamma_r = \sum_{k=0}^{N-1} X_k Y_k W_N^{kr} \quad (5.79)$$

também é circular;

$$\Gamma_r = \frac{1}{N} \sum_{s=0}^{N-1} x_s y_{r-s} \quad (5.80)$$

com $y_{r-s} = y_{r-s+N}$, se $r-s < 0$. Para evitar o erro de circularidade da convolução discreta computada pela TFD, os mesmos procedimentos utilizados para a correlação podem ser aplicados. Por exemplo, basta zerar N pontos do sinal x :

$$\Gamma_r = \frac{1}{2N} \sum_{s=0}^{N-1} x_s y_{r-s} + \sum_{s=N}^{2N-1} x_s y_{r-s} \quad (5.81)$$

A segunda somatória será nula já que $x_s = 0; s > N$. Daí pode-se escrever:

$$\Gamma_r = \frac{1}{2N} \hat{\Gamma}_r; \quad r = 0, N-1 \quad (5.82)$$

onde $\hat{\Gamma}_r$ é o estimador não circular da correlação entre $x(t)$ e $y(t)$. Cabe notar que:

$$(x * y)_\tau = \int_{-\infty}^{\infty} x(t)y(\tau - t)dt \quad (5.83)$$

donde

$$(x * y)_{\tau=r\Delta t} \cong \left(\sum_{s=0}^{N-1} x_s y_{r-s} \right) \Delta t = \hat{\Gamma}_r N \Delta t \quad (5.84)$$

Portanto, sumarizando, as estimativas da correlação e da convolução a partir da TFD e ITDF podem ser obtidas da seguinte forma:

1. Adquirir x_s e y_s , $s = 0, 2N-1$ de $x(t)$ e $y(t)$.
2. Zerar metade dos pontos de x ; $x_s = 0$, $s \geq N$.
3. Computar as TFD's de $\{x\}$ e $\{y\}$.
4. Correlação:

$$R_{xy}(\tau = r\Delta t) \cong 2 \text{ITFD}[< X^* Y >] \quad (5.85)$$

onde $< >$ denota a média sobre várias amostras.

5. Convolução:


$$x * y(\tau = r\Delta t) \cong 2N\Delta t \text{ITFD}[XY] \quad (5.86)$$

5.6 Exercícios

5.1 Considerando que o circuito elétrico RC da figura abaixo é excitado com ruído branco cuja função de autocorrelação é $R_{xx}(\tau) = A\delta(\tau)$.


a) Demonstrar que a função de autocorrelação da resposta é $R_{yy}(\tau) = \frac{A}{2RC} e^{-\tau/RC}$ para $\tau > 0$.

b) Demonstrar que densidade espectral de potência da resposta é $S_{yy}(f) = \frac{A}{2RC}$



5.2. Considerando o sistema mecânico da figura abaixo cuja excitação é ruído branco com densidade espectral $S_{xx}(f) = Q$.

- a) Demonstrar que densidade espectral de potência da resposta é
- $$S_{yy}(f) = \frac{Q}{(k - 4\pi^2 m f^2)^2 + 4\pi^2 c^2 f^2}$$
- b) Determinar a função de autocorrelação da resposta.



5.3. Pede-se descrever as etapas necessárias para a análise espectral de um sinal aleatório estacionário na faixa de 0 a 10 kHz com a TFD, incluindo:

- filtragem analógica
- discretização
- número de blocos e de pontos por bloco
- janelamento
- médias
- comentar o problema da circularidade

g) comentar ainda o que deveria ser feito caso se desejasse fazer a análise espectral por modelo autoregressivo

5.4 Demonstrar a igualdade da expressão (5.62):

$$W(f) = 2 \int_0^T \frac{T-\tau}{T} \cos(2\pi f\tau) d\tau = T [\text{sinc}(\pi fT)]^2$$

6 - Relações entrada/saída de sistemas lineares

A partir das relações entrada/saída de sistemas lineares vistas no capítulo 2, pode-se facilmente estabelecer estas relações em termos de auto-espectros e espectros cruzados para sinais aleatórios.

Partindo da integral da convolução para sistemas causais ($h(t) = 0, t < 0$), pode-se escrever:

$$y(t) = \int_{-\infty}^{\infty} h(\xi) x(t - \xi) d\xi \quad (6.1)$$

Substituindo t por $t + \tau$ na equação (6.1) e substituindo o resultado na expressão da autocorrelação, tem-se:

$$\begin{aligned} R_{yy}(\tau) &= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} y(t) y(t + \tau) dt \\ &= \int_0^{\infty} \int_0^{\infty} h(\xi) h(\eta) \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} x(t - \xi) x(t + \tau - \eta) dt d\xi d\eta \\ &= \int_0^{\infty} \int_0^{\infty} h(\xi) h(\eta) R_{xx}(\tau - \eta + \xi) d\xi d\eta \end{aligned} \quad (6.2)$$

já que:

$$\lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} x(t - \xi) x(t + \tau - \eta) dt = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2 - \xi}^{T/2 - \xi} x(\theta) x(\theta + \tau - \eta + \xi) d\theta = R_{xx}(\tau - \eta + \xi)$$

, com $t - \xi = \theta$.

Mas, aplicando a transformada de Fourier em (6.2), vem,

$$\begin{aligned}
S_{yy}(f) &= \int_{-\infty}^{\infty} R_{yy}(\tau) e^{-i2\pi f\tau} d\tau \\
&= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(\xi)h(\eta) \int_{-\infty}^{\infty} R_{xx}(\tau-\eta+\xi) e^{-i2\pi f\tau} d\tau d\eta d\xi
\end{aligned} \tag{6.3}$$

Fazendo a substituição $\gamma = \tau + \xi - \eta$; $d\gamma = d\tau$ em (6.3):

$$S_{yy}(f) = \int_{-\infty}^{\infty} h(\xi) \int_{-\infty}^{\infty} h(\eta) \left\{ \int_{-\infty}^{\infty} R_{xx}(\gamma) e^{-i2\pi f\gamma} d\gamma \right\} e^{i2\pi f\eta} d\eta e^{-i2\pi f\xi} d\xi \tag{6.4}$$

Reconhecendo a expressão de $S_{xx}(f)$ em (6.4), tem-se:

$$S_{yy}(f) = S_{xx}(f) \int_{-\infty}^{\infty} h(\xi) e^{-i2\pi f\xi} d\xi \int_{-\infty}^{\infty} h(\eta) e^{i2\pi f\eta} d\eta \tag{6.5}$$

e reconhecendo a transformada de Fourier de $h(t)$ e seu conjugado em (6.5) tem-se finalmente:

$$S_{yy}(f) = H(f)H^*(f)S_{xx}(f) \tag{6.6}$$

ou seja

$$S_{yy}(f) = |H(f)|^2 S_{xx}(f) \tag{6.7}$$

A equação (6.7) expressa a relação entre o auto-espectro da saída e o auto-espectro da entrada com sinais aleatórios. A partir desta relação, em deduções análogas, pode-se chegar a outros resultados.

Por exemplo, fazendo $x(t) y(t + \tau)$ em (6.2), é fácil chegar a:

$$S_{xy}(f) = H(f)S_{xx}(f) \tag{6.8}$$

e fazendo $y(t) y(t + \tau)$, porém sem substituir $y(t)$ de (6.1), é imediato chegar a:

$$S_{yy}(f) = H(f)S_{yx}(f) \tag{6.9}$$

Relações intermediárias das demonstrações anteriores expressam a relação entrada/saída no domínio do tempo para sinais aleatórios:

$$R_{xy} = \int_{-\infty}^{\infty} h(\xi)R_{xx}(\tau-\xi) d\xi = h(t) * R_{xx}(t) \tag{6.10}$$

$$R_{yy} = \int_{-\infty}^{\infty} h(\xi)R_{yx}(\tau-\xi) d\xi = h(t) * R_{yx}(t) \tag{6.11}$$

As mesmas relações entre espectros de entrada e saída podem ser obtidas partindo-se da transformada de Fourier finita dos sinais de entrada e saída.

Sabemos que para sistemas lineares,

$$Y(f) = H(f)X(f) \quad (6.12)$$

Assumindo que esta relação é válida para a transformada de Fourier finita:

$$Y(f, T) = H(f, T)X(f, T) \quad (6.13)$$

Omitindo a dependência de f e T para facilitar a notação tem-se:

$$Y = H X \quad (6.14)$$

E, multiplicando por X^*

$$X^* Y = H X^* X \quad (6.15)$$

Fazendo o valor esperado da equação anterior, tem-se:

$$S_{xy} = H(f) S_{xx} \quad (6.16)$$

onde $S_{xx} = T E[X^*X]$ e $S_{xy} = T E[X^*Y]$, onde $E[\]$ denota a média de conjunto.

Alternativamente, multiplicando a expressão (6.12) por Y^* tem-se

$$Y^* Y = H Y^* X \quad (6.17)$$

Aplicando a média:

$$S_{yy} = H(f) S_{yx} \quad (6.18)$$

Cabe notar que, quando resolvendo o problema inverso, onde procura-se determinar a FRF a partir dos sinais $x(t)$ e $y(t)$ aleatórios medidos, denominam-se de $\hat{H}_1$ e $\hat{H}_2$ os estimadores obtidos das equações (6.8) e (6.9):

$$\hat{H}_1(f) = \frac{S_{xy}(f)}{S_{xx}(f)} \quad (6.19)$$

$$\hat{H}_2(f) = \frac{S_{yy}(f)}{S_{yx}(f)} \quad (6.20)$$

6.1 Função de coerência ordinária

Dados dois sinais aleatórios, $x(t)$ e $y(t)$, já foi mostrado que:

$$\left| R_{xy}(\tau) \right|^2 \leq R_{xx}(0) R_{yy}(0)$$

Esta equação vale para qualquer τ , inclusive para $\tau = 0$.

$$\left| R_{xy}(0) \right|^2 \leq R_{xx}(0) R_{yy}(0) \quad (6.21)$$

Filtrando os sinais em torno de uma frequência f_0 com filtro passa-banda ideal de largura Δf , tem-se :

$$R_{xx}(0) = \int_0^{\infty} G_{xx}(f) df = \int_{f_0 - \Delta f / 2}^{f_0 + \Delta f / 2} G_{xx}(f) df \cong G_{xx}(f_0) \Delta f \quad (6.22)$$

já que Δf pode ser feito tão pequeno quanto se queira. Da mesma forma:

$$R_{yy}(0) \cong G_{yy}(f_0) \Delta f \quad (6.23)$$

$$R_{xy}(0) \cong G_{xy}(f_0) \Delta f \quad (6.24)$$

A última expressão merece um comentário:

$$R_{xy}(0) = \int_{-\infty}^{\infty} G_{xy}(f) df \cong G_{xy}(f_0) \Delta f$$

Substituindo (6.22) – (6.24) em (6.21) vem:

$$|G_{xy}(f_0)|^2 \leq G_{xx}(f_0) G_{yy}(f_0) \quad (6.25)$$

que é válida para qualquer f_0 . A desigualdade é obviamente válida também para as DEP's “double sided”, i.e.;

$$|S_{xy}(f)|^2 \leq S_{xx}(f) S_{yy}(f) \quad (6.26)$$

A partir da relação (6.26) podemos definir uma função da frequência que chamaremos *função de coerência ordinária*:

$$\gamma_{xy}^2(f) = \frac{|S_{xy}(f)|^2}{S_{xx}(f) S_{yy}(f)} \quad (6.27)$$

e, devido a (6.26), tem-se:

$$0 \leq \gamma_{xy}^2 \leq 1 \quad (6.28)$$

No caso de $y(t)$ e $x(t)$ serem ligados por uma relação linear, que pode ser representada por uma FRF, $H(f)$, tem-se:

$$S_{xy}(f) = H(f) S_{xx}(f)$$

donde,

$$\gamma_{xy}^2(f) = \frac{|H(f)|^2 S_{xx}^2(f)}{S_{xx}(f) S_{yy}(f)}$$

e substituindo (6.7):

$$\gamma_{xy}^2(f) = \frac{|H(f)|^2 S_{xx}(f)}{S_{xx}(f) |H(f)|^2 S_{xx}(f)} = 1 \quad (6.29)$$

ou seja, se $x(t)$ e $y(t)$ têm uma relação linear, a coerência é unitária. Portanto, pode-se interpretar a coerência como um coeficiente de correlação no domínio da frequência.

Seguindo a modelagem de ruído proposta por Bendat e Piersol [3,4], imagine-se que ruídos de medição Gaussianos aditivos independentes contaminem a entrada e a saída de um sistema linear, como mostrado na figura 6.1.




figura 6.1. Modelo de ruído de medição em um sistema linear

Na figura 6.1, tem-se:

$$\begin{aligned} x(t) &= u(t) + w(t) \\ y(t) &= v(t) + z(t) \end{aligned} \quad (6.30)$$

ou, aplicando a transformada de Fourier finita:

$$\begin{aligned} X(f, T) &= U(f, T) + W(f, T) \\ Y(f, T) &= V(f, T) + Z(f, T) \end{aligned} \quad (6.31)$$

Os espectros são dados por:

$$G_{xx}(f) = 2E[X^*X] = \frac{2}{\Delta f} E[U^*U + W^*W + U^*W + W^*U]$$

mas, como o ruído é suposto estatisticamente independente, tem-se que,

$$E[U^*W] = E[W^*U] = 0 \quad (6.32)$$

donde

$$G_{xx}(f) = G_{uu}(f) + G_{ww}(f) \quad (6.33)$$

Note que a dependência de f e T foi omitida para simplificar a notação. Analogamente:

$$G_{yy}(f) = G_{vv}(f) + G_{zz}(f) \quad (6.34)$$

$$G_{xy}(f) = G_{uv}(f) \quad (6.35)$$

Note-se que o espectro cruzado não é afetado pelo ruído Gaussiano aditivo.

Observe-se, agora, a influência do ruído nos estimadores $\hat{H}_1$ e $\hat{H}_2$ dados pelas equações (6.19) e (6.20):

$$|\hat{H}_1(f)| = \frac{|G_{xy}(f)|}{G_{xx}(f)} = \frac{|G_{uv}|}{G_{uu} + G_{ww}} \leq |H(f)| \quad (6.36)$$

$$|\hat{H}_2(f)| = \frac{G_{yy}(f)}{|G_{yx}(f)|} = \frac{G_{vv} + G_{zz}}{|G_{vu}|} \geq |H(f)| \quad (6.37)$$

já que $G_{ww} \geq 0$ e $G_{zz} \geq 0$, tem-se que:

$$|\hat{H}_1(f)| \leq |H(f)| \leq |\hat{H}_2(f)| \quad (6.38)$$

donde os estimadores $\hat{H}_1$ e $\hat{H}_2$ são limites inferior e superior ao valor de $H(f)$ quanto ao ruído de medição. Cabe notar que a equação anterior não é geralmente verificada devido aos erros de *leakage*, janelamento triangular dos espectros, erro estatístico de estimação dos espectros e ruídos não independentes ou não Gaussianos.

Existem outros estimadores da FRF, porém $\hat{H}_1$ e $\hat{H}_2$ são os mais comumente utilizados. O estimador $\hat{H}_1$ deve ser utilizado quando o ruído contamina principalmente o sinal de resposta, enquanto $\hat{H}_2$ deve ser utilizado quando o ruído contamina o sinal de entrada. O ruído no sinal de entrada é típico de situações onde excitadores eletrodinâmicos são pilotados com sinais de banda larga sem realimentação para manter a amplitude da força constante. Como o sistema apresenta uma reação menor nas ressonâncias, a amplitude da força (entrada) tende a diminuir muito nas ressonâncias, tornando a relação sinal/ruído muito baixa.

6.2 Sistemas lineares com múltiplas entradas e saídas

O estimador $\hat{H}_1$ pode ser generalizado para um sistema linear de múltiplas entradas e saídas (MIMO, do inglês “multiple-input/multiple-output”). Considerando apenas a propriedade de linearidade do sistema tem-se:

$$Y_i(f) = \sum_j H_{ij}(f) X_j(f) \quad (6.39)$$

ou, em notação matricial:

$$\{Y(f)\} = [H(f)]\{X(f)\} \quad (6.40)$$

Multiplicando à direita por $\{X\}^H$ onde H denota transposto conjugado:

$$\{Y\}\{X\}^H = [H]\{X\}\{X\}^H \quad (6.41)$$

onde a dependência da frequência foi omitida para simplificar a notação. Aplicando a esperança matemática à equação (6.41) vem:

$$[G_{XY}] = [H(f)][G_{XX}] \quad (6.42)$$

ou

$$[G_{XY}]_{ij} = E[Y_i X_j^*] \quad [G_{XX}]_{ij} = E[X_i X_j^*] \quad (6.43)$$

A solução para a matriz de FRFs é dada por:

$$[\hat{H}_1] = [G_{XY}][G_{XX}]^{-1} \quad (6.44)$$

onde a inversa deve ser entendida como uma expressão formal da solução, que pode ser obtida de forma numérica mais eficiente pela solução do sistema linear dado por (6.42) por decomposição (geralmente método LU de Gauss).

Um estimador mais genérico, que permite minimizar os erros na entrada e na saída e que pode incorporar o conhecimento que se tenha *a priori* do ruído presente, é o estimador denominado $\hat{H}_v$. Será apresentada aqui uma formulação não rigorosa que permite implementar o estimador e investigar algumas de suas propriedades.

Definindo um erro na saída, no domínio da frequência, como sendo:

$$N = HX - Y \quad (6.45)$$

E fazendo a matriz dos espectros cruzados de N:

$$G_{NN} = E[NN^H] = E[YY^H - YX^H H^H - HXY^H + HXX^H H^H] \quad (6.46)$$

obtem-se:

$$G_{NN} = G_{YY} - G_{XY}H^H - HG_{YX} + HG_{XX}H^H$$

que pode ser re-arranjado:

$$G_{NN} = [-I : H] \begin{bmatrix} G_{YY} & G_{XY} \\ G_{YX} & G_{XX} \end{bmatrix} \begin{bmatrix} -I \\ H^H \end{bmatrix} = Q^H G_{AA} Q \quad (6.47)$$

onde $A^H = \{Y^H X^H\}$ e $G_{AA} = E[AA^H]$. A partir daqui existem pelo menos duas maneiras de chegar ao estimador $\hat{H}_v$.

A primeira consiste em considerar os ruídos nas entradas e saídas $\tilde{N}_i$ independentes e, portanto, a matriz $\tilde{G}_{NN}$ diagonal:

$$\tilde{G}_{NN} = \lambda[P] \quad (6.48)$$

Considerando $A = Z + \tilde{N}$, e $\tilde{N}$ independente de Z , tem-se

$$G_{AA} = G_{ZZ} + \tilde{G}_{NN} \quad (6.49)$$

onde Z seriam os sinais livres de ruído, $Z^H = \{V^H : U^H\}$. Então:

$$G_{AA}Q = G_{ZZ}Q + \tilde{G}_{NN}Q = \tilde{G}_{NN}Q$$

pois $G_{ZZ}Q = 0$.

Isto pode ser demonstrado da seguinte maneira:

Tem-se que:

$$Z = \begin{Bmatrix} V \\ U \end{Bmatrix}$$

$$\text{então} \quad G_{ZZ} = E[Z Z^H] = \begin{bmatrix} E[V V^H] & E[V U^H] \\ E[U V^H] & E[U U^H] \end{bmatrix} = \begin{bmatrix} G_{VV} & G_{UV} \\ G_{VU} & G_{UU} \end{bmatrix} \quad (6.50)$$

$$\text{com} \quad Q = \begin{bmatrix} -I \\ H^H \end{bmatrix}$$

$$\text{logo,} \quad G_{ZZ}Q = \begin{bmatrix} G_{VV} & G_{UV} \\ G_{VU} & G_{UU} \end{bmatrix} \begin{bmatrix} -I \\ H^H \end{bmatrix} = \begin{bmatrix} -G_{VV} + G_{UV}H^H \\ -G_{VU} + G_{UU}H^H \end{bmatrix} \quad (6.51)$$

mas se:

$$V = HU$$

transpondo e conjugando V :

$$\begin{aligned} VV^H &= VU^H H^H \\ E[VV^H] &= E[VU^H] H^H \Rightarrow G_{VV} = G_{UV} H^H \\ &\Rightarrow -G_{VV} + G_{UV} H^H = 0 \end{aligned} \quad (6.52)$$

Por outro lado, temos que:

$$VU^H = HUU^H$$

transpondo e conjugando:

$$UV^H = UU^H H^H$$

$$\begin{aligned} E[UV^H] &= E[UU^H]H^H \Rightarrow G_{VU} = G_{UU}H^H \\ -G_{VU} + G_{UU}H^H &= 0 \end{aligned} \quad (6.53)$$

donde, utilizando as equações (6.52) e (6.53), demonstramos que $G_{ZZ}Q = 0$.

E pode-se escrever:

$$G_{AA}Q = G_{NN}Q = \lambda[P]Q \quad (6.54)$$

ou

$$[P]^{-1}G_{AA}Q = \lambda Q$$

Como o objetivo é minimizar $\tilde{G}_{NN}$ com uma dada estrutura $[P]$, deve-se minimizar λ . Além disso, a equação acima é um problema de autovalor da matriz $[P]^{-1}G_{AA}$. A solução consiste, então, em obter os autovetores associados aos menores autovalores de $[P]^{-1}G_{AA}$ e normalizá-los de forma a ter uma matriz identidade negativa na parte superior da matriz Q .

Particularizando para sistemas com uma entrada e uma saída, pode-se ilustrar a utilização da matriz P . Seja a matriz

$$G_{AA} = \begin{bmatrix} G_{YY} & G_{XY} \\ G_{YX} & G_{XX} \end{bmatrix}$$

Para minimizar o erro na entrada, usa-se a estimador $\hat{H}_2$. Isto é,

$$[P] = \begin{bmatrix} 1 & 0 \\ 0 & \infty \end{bmatrix} \Rightarrow [P]^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

Assim, tem-se:

$$[P]^{-1}[G_{AA}] = \begin{bmatrix} G_{YY} & G_{XY} \\ 0 & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} G_{YY} & G_{XY} \\ 0 & 0 \end{bmatrix} \begin{Bmatrix} -1 \\ \hat{H}_2^* \end{Bmatrix} = \begin{Bmatrix} 0 \\ 0 \end{Bmatrix}$$

donde,

$$-G_{YY} + \hat{H}_2^* G_{XY} = 0 \Rightarrow \hat{H}_2 = \frac{G_{YY}}{G_{YX}}$$

Analogamente, para minimizar o erro na saída, usa-se o estimador $\hat{H}_1$

$$[P] = \begin{bmatrix} \infty & 0 \\ 0 & 1 \end{bmatrix} \Rightarrow [P]^{-1} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$$

Assim, tem-se:

$$[P]^{-1}[G_{AA}] = \begin{bmatrix} 0 & 0 \\ G_{YX} & G_{XX} \end{bmatrix} \Rightarrow \begin{bmatrix} 0 & 0 \\ G_{YX} & G_{XX} \end{bmatrix} \begin{Bmatrix} -1 \\ \hat{H}_1^* \end{Bmatrix} = \begin{Bmatrix} 0 \\ 0 \end{Bmatrix}$$

donde,

$$-G_{YX} + \hat{H}_1^* G_{XX} = 0 \Rightarrow \hat{H}_1 = \frac{G_{XY}}{G_{XX}}$$

Assim, variando os termos na diagonal de $[P]$ pode-se ponderar a minimização dos erros na entrada e na saída em função da informação *a priori* disponível.

Outra possibilidade é utilizar a propriedade do quociente de Rayleigh, isto é,

$$\min_q \frac{\{q\}^H G_{AA} \{q\}}{\{q\}^H \{q\}} = \lambda_{\min} \quad (6.55)$$

onde

$$G_{AA} \{q\} = \lambda \{q\}$$

ou seja, λ é um autovalor da matriz G_{AA} . Como o vetor $\{q\}$, que é uma coluna da matriz Q , está normalizado de forma que suas primeiras N_0 linhas são uma coluna da matriz identidade negativa, minimizar G_{NN} significa tomar como solução os autovalores associados aos menores autovalores [5]. Desta forma, a solução é a mesma que na formulação anterior quando $[P] = I$, ou seja, nenhuma informação *a priori* existe para a estrutura de erros. Isto equivale a dar o mesmo peso aos erros na entrada e na saída.

Nota: Quociente de Rayleigh.

Sabendo que $\frac{\partial}{\partial \{q\}} \{q\}^H [A] \{q\} = 2[A] \{q\}$, se $[A] = [A]^H$

$$\text{Então } \frac{\partial}{\partial \{q\}} \frac{\{q\}^H [A] \{q\}}{\{q\}^H \{q\}} = \frac{2(\{q\}^H \{q\})[A] \{q\} - 2(\{q\}^H [A] \{q\})\{q\}}{(\{q\}^H \{q\})^2} = 0$$

Implica em

$$[A] \{q\} = \left(\frac{\{q\}^H [A] \{q\}}{\{q\}^H \{q\}} \right) \{q\} \quad (6.56)$$

ou seja, o mínimo do quociente é o menor autovalor da matriz Hermitania $[A]$.

6.3 Exemplo

Nesta seção será simulada numericamente a resposta dinâmica de um sistema mecânico de um grau de liberdade sujeito a uma excitação aleatória. Os conceitos de

processamento de sinais aleatórios serão aplicados na determinação de estimadores da função de resposta em frequência (FRF) do sistema e a influência da variação dos diversos parâmetros envolvidos será analisada.

Uma característica interessante nos resultados é relativa ao valor da função de coerência. Para uma boa estimação do FRF, o valor de coerência deve ser próximo da unidade. Se ele for menor que a unidade isto pode ser devido a uma ou mais das quatro principais causas descritas a seguir:

1. Ruído externo presente nas medições (geralmente de origem eletromagnética);
2. Erro de polarização (em inglês, “*bias*”) devido a uma resolução em frequência insuficiente;
3. Não linearidades na relação entrada/saída;
4. A saída obtida é devida a outros fatores além da entrada considerada.

A seguir são analisados os estimadores $\hat{H}_1$ e $\hat{H}_2$ e a função de coerência para um sistema dinâmico de parâmetros concentrados consistindo de uma massa, uma mola e um amortecedor viscoso ($m = 1$, $k = 1000$, $c = 10$ em unidades do SI), de 1 grau de liberdade.

Inicialmente foi utilizado um total de $n = 1024$ amostras divididas em $nb = 4$ blocos de $N=256$ amostras cada. A frequência de amostragem f_a utilizada foi de 100 Hz, ou 100 amostras por segundo. Os resultados estimados para a Função de Resposta em Frequência (FRF) e da função de coerência ordinária são mostrados na

figura 6.2. Nesta figura, pode-se notar que o erro estatístico é elevado (oscilação em torno do valor médio) devido principalmente ao pequeno número de blocos (número de médias na estimação dos espectros).

(a)

(b)




figura 6.2. (a) Comparação de $H(f)$ teórico ('—') com estimadores $\hat{H}_1$ ('o-') e $\hat{H}_2$ ('x-') para $n = 1024$; $nb=4$; $N=256$. (b) Função coerência ordinária.

Aumentando o número de médias (Figura 6.3), o erro estatístico, ou seja, a oscilação em torno da média, cai. Entretanto pode ser notado que principalmente $\hat{H}_1$ não converge para o valor analítico na faixa de frequências em torno do pico de ressonância, ou seja, temos um erro de polarização devido ao pequeno número de pontos em cada bloco. Mostra-se, assim, que não basta aumentar o número de médias diminuindo o número de pontos por bloco, pois é este número que vai determinar o erro de polarização devido à resolução em frequência, que é de aproximadamente $0,39 \text{ Hz}$ (f_a/N).




Figura 6.3. (a) Comparação de $H(f)$ teórico ('—') com estimadores $\hat{H}_1$ ('o-') e $\hat{H}_2$ ('x-') para $n = 1024$; $nb=11$; $N=64$. (b) Função coerência ordinária.

A

Figura 6.4 mostra os resultados obtidos considerando $nb=16$ blocos de $N=256$ pontos por bloco, totalizando $n=4096$ pontos. Comparando estes resultados com os obtidos na figura 6.2, podemos concluir que houve uma diminuição no erro estatístico.




Figura 6.4. (a) Comparação de $H(f)$ teórico ('—') com estimadores $\hat{H}_1$ ('o-') e $\hat{H}_2$ ('x-') para $n = 4096$, $nb=16$; $N=256$. (b) Função coerência ordinária.

Visando explorar o erro na região da ressonância, considere-se o mesmo sistema adotando um coeficiente de amortecimento 5 vezes maior. Os resultados desta nova situação são mostradas na Figura 6.5. Nesta figura, pode-se observar a acentuada diminuição da amplitude (pelo arredondamento do pico) próximo à frequência natural do sistema. Com o alargamento do pico a resolução em frequência utilizada passa a ser suficiente e o erro de polarização é minimizado. Os valores de coerência na região de ressonância, que desciam a quase 0,7 na Figura 6.3b, agora são superiores a 0.988. Para

o mesmo fator de amortecimento anterior efeito semelhante teria sido obtido aumentando o número de pontos por bloco, N , de cinco vezes. Portanto, na obtenção de uma FRF com sinais aleatórios, para um mesmo número total de amostras medidas n , é preciso estabelecer um compromisso entre o número de blocos nb , que controla o erro estatístico, e o tamanho do bloco N , que controla o erro de polarização.




Figura 6.5. (a) Comparação de $H(f)$ teórico ('—') com estimadores $\hat{H}_1$ ('o-') e $\hat{H}_2$ ('x-') para $n = 4096$, $nb=16$; $N=256$ usando um amortecimento 5 vezes maior. (b) Função coerência.

Contaminando o sinal de entrada com ruído gaussiano não-correlacionado (aqui foi usado um nível de ruído de 20% com relação à amplitude do sinal), obtêm-se os resultados mostrados na Figura 6.6. Observa-se que a FRF não apresenta grandes diferenças com relação ao resultado obtido na

Figura 6.4a. Neste caso teoricamente é melhor utilizar o estimador $\hat{H}_2$ que é menos sensível ao ruído no sinal de entrada.

Adicionando ruído na saída do sistema, o efeito é percentualmente mais significativo nas altas frequências, onde o nível de sinal de resposta é menor (Figura 6.7). De fato, pode-se observar que o estimador $\hat{H}_2$ diverge completamente do valor de H teórico para esta faixa de frequências. Observa-se uma queda acentuada na função de coerência após a frequência natural do sistema, mas isto não afeta o estimador $\hat{H}_1$.

Quando há ruídos aditivos não correlacionados atuando simultaneamente na entrada e na saída (Figura 6.8), há uma superposição dos efeitos analisados anteriormente, e pode-se observar que $\hat{H}_1 \leq \hat{H}_2$ em todo intervalo analisado. Neste caso observa-se que, na região da ressonância, o estimador $\hat{H}_2$ está mais próximo do valor analítico enquanto que fora da ressonância o estimador $\hat{H}_1$ é nitidamente melhor.




Figura 6.6 (a) Comparação de $H(f)$ teórico ('—') com estimadores $\hat{H}_1$ ('o-') e $\hat{H}_2$ ('x-') para $n = 4096$, $nb=16$; $N=256$ adicionando ruído na entrada do sistema. (b) Função coerência ordinária.




Figura 6.7. (a) Comparação de $H(f)$ teórico ('—') com estimadores $\hat{H}_1$ ('o-') e $\hat{H}_2$ ('x-') para $n = 4096$, $nb=16$; $N=256$ adicionando ruído na saída do sistema. (b) Função coerência ordinária.




Figura 6.8. (a) Comparação de $H(f)$ teórico ('—') com estimadores $\hat{H}_1$ ('o-') e $\hat{H}_2$ ('x-') para $n = 4096$, $nb=16$; $N=256$ adicionando ruído na entrada e na saída do sistema. (b) Função coerência ordinária.

6.4 Multissenos

Já vimos que se o sinal de entrada, denotado aqui por $p_j(t)$, é periódico com período T , este pode ser expandido em uma série de Fourier com coeficientes complexos $P_j(f_k)$, onde $f_k = k/T$, k inteiro, tendo como resposta o sinal de saída $x_i(t)$, com coeficientes $X_i(f_k)$. A relação entrada/saída é dada por:

$$X_i(f_k) = H_{ij}(f_k)P_j(f_k) \quad (6.57)$$

Se $P_j(f_k)$ é diferente de zero para k no intervalo $[k_1, k_2]$, $H_{ij}(f_k)$ pode ser determinada em frequência no intervalo $[f_{k_1}, f_{k_2}]$ com uma resolução $1/T$. Um sinal periódico que contenha componentes harmônicas nas frequências desejadas pode ser denominado "sinal multissenso".

Como vimos, para um sinal periódico a série de Fourier pode ser calculada via TFD sem erros (a menos dos erros de quantização e de arredondamento numérico) desde que a frequência de amostragem seja suficiente para evitar o efeito de "aliasing" e o tempo de observação do sinal T contenha um número inteiro de períodos. O sinal multissenso pode ser facilmente sintetizado através de:

$$p(t) = \sum_{k=k_1}^{k_2} A_k \cos(2\pi kt/T + \phi_k) \quad (6.58)$$

Para o caso em que o espectro é $A_k = A = \text{constante}$, usando a equação 6.58 com $\phi_k = \phi = \text{constante}$, o sinal obtido é uma sequência de impactos periódicos. Este sinal tem a desvantagem de sinais transitórios de excitação, que são as grandes amplitudes necessárias para injetar energia suficiente no sistema. Schroeder ^[4] investigou este problema propôs algoritmos para a minimização do fator de crista (razão entre o valor máximo e o valor RMS) de sinais multissenso. A minimização é feita para uma dada distribuição de amplitudes através de uma escolha apropriada dos ângulos de fase ϕ_k .

Para uma dada distribuição de amplitudes do espectro A_k , Schroeder propõe usar as fases dadas pela equação (6.59).

$$\phi_k = 2\pi \sum_{l=k_1}^k \frac{A_l^2}{\sum_{i=k_1}^{k_2} A_i^2} \quad (6.59)$$

Para um espectro plano, $A_l = A = \text{constante}$, esta equação pode ser simplificada para a equação (6.60).

$$\phi_k = 2\pi \left(\frac{k^2 + k - k_1^2 + k_1}{2(k_2 - k_1 + 1)} \right) \quad (6.60)$$

Schroeder encontrou também os valores ótimos para o caso em que $k_1 = 1$, $k_2 = N$, quando a equação (6.60) transforma-se em,

$$\phi_k = \pi \frac{k^2}{N} \quad (6.61)$$

Se o ângulo de fase é restrito a assumir valores de 0 ou π , a equação (6.58) pode ser rescrita, para $k_1 = 1$, $k_2 = N$ como,

$$p_j(t) = \sum_{k=k_1}^{k_2} A_k \cos(2\pi k t / T) \quad (6.62)$$

onde, para um espectro plano,

$$A_k = A \left(1 - 2 \left[\frac{k^2}{2N} \right]_{\text{mod } 2} \right) \quad (6.63)$$

Na equação (6.63), A é a amplitude constante, e

$$\left[\frac{k^2}{2N} \right]_{\text{mod } 2} = \begin{cases} 1, & \text{se } \frac{k^2}{2N} \text{ ímpar} \\ 0, & \text{se } \frac{k^2}{2N} \text{ par} \end{cases} \quad (6.64)$$

Com a excitação multisseno, a FRF pode ser obtida a partir da equação (6.18) usando apenas um período dos sinais de entrada e saída. Embora não seja um requisito, o cálculo da média sobre alguns períodos pode reduzir o ruído aditivo existente na FRF estimada. O número de médias pode ser pequeno comparado com excitações aleatórias.

Como foi mostrado por Arruda ^[5], caso seja necessário fazer uma multi-excitação simultânea, ou seja, excitar simultaneamente com vários sinais de entrada, ainda assim pode-se usar sinais multisseno.

Considere a multi-excitação simultânea com n_e forças externas. Pode-se escrever, sem perda de generalidade, que a i -ésima resposta é dada pela equação:

$$X_i(f_k) = \sum_{j=1}^{n_e} H_{ij}(f_k) P_j(f_k) \quad (6.65)$$

A equação (6.65) pode ser representada em forma matricial para cada excitação de frequência f_k :

$$X_i(f_k) = \begin{bmatrix} P_1(f_k) & P_2(f_k) & \cdots & P_{n_e}(f_k) \end{bmatrix} \begin{bmatrix} H_{i1}(f_k) \\ H_{i2}(f_k) \\ \vdots \\ H_{in_e}(f_k) \end{bmatrix} \quad (6.66)$$

Um sistema de n_s equações como a equação (6.66), formado pela aplicação dos diferentes conjuntos simultâneos de sinais de excitação multisseno pode ser escrito como,

$$X_i(f_k) = P_k H_i(f_k) \quad (6.67)$$

Se $n_s \geq n_e$ e se a distribuição de amplitudes das entradas para diferentes conjuntos de entradas (linhas da matriz P_k não são linearmente dependentes, a equação (6.67) pode ser resolvida para $H_i(f_k)$. Para cada frequência diferente, um sistema de equações $n_s \times n_e$ é resolvido. A matriz P_k a ser invertida é a mesma para todas as respostas, mas é diferente para cada frequência. É possível escrever, portanto:

$$X_k = P_k H_k \quad (6.68)$$

onde

$$H_k = \begin{bmatrix} H_1(f_k) & H_2(f_k) & \cdots & H_{n_e}(f_k) \end{bmatrix}^T \quad (6.69)$$

$$X_k = \begin{bmatrix} X_1(f_k) & X_2(f_k) & \cdots & X_{n_s}(f_k) \end{bmatrix}^T \quad (6.70)$$

A solução, H_k pode ser calculada usando a solução de mínimos quadrados, de maneira que,

$$\hat{H}_k = P_k^+ X_k \quad (6.71)$$

onde P_k^+ é a pseudo-inversa (ou inversa generalizada) de P_k , dada por $P_k^+ = [P_k^T P_k]^{-1} P_k^T$.

Os n_s conjuntos linearmente independentes de n_e amplitudes de força podem ser obtidos multiplicando n_e fases de Schroeder de sinais multisseno por n_s vetores ortogonais, que podem ser facilmente gerados pelo método de ortogonalização de Gram-Schmidt. É interessante notar que o caso particular onde P_k é a matriz identidade corresponde ao caso de excitação em uma entrada por vez (estimação da FRF com uma entrada e várias saídas).

6.5 Exercícios

6.1. Demonstrar que, se $h(t)$ é a resposta ao impulso unitário do sistema linear

$$H(f) = Q_0(f)e^{-i\varphi(f)}, \text{ então } \int_{-\infty}^{\infty} t h(t) dt = -\frac{d\varphi(0)}{df}$$


6.2. Sejam $h_1(t)$, $h_2(t)$, $H_1(f)$ e $H_2(f)$ as funções de resposta em frequência dos dois sistemas mostrados na figura abaixo.

a) Demonstrar que a função de correlação cruzada é

$$R_{y_1 y_2}(\tau) = \int_{-\infty}^{\infty} h_1(\xi) \int_{-\infty}^{\infty} R_{x_1 x_2}(\tau + \eta - \xi) h_2(\eta) d\eta d\xi$$

b) Demonstrar que densidade espectral cruzada é dada como:

$$S_{y_1 y_2}(f) = H_1(f) H_2^*(f) S_{x_1 x_2}(f)$$




6.3. Na figura abaixo, sejam $S_{x_1 x_1}(f) = S_{x_2 x_2}(f) = Q_0$ e $S_{x_1 x_2}(f) = S_{x_2 x_1}^*(f) = Q_0 e^{-i2\pi f T}$

a) Demonstrar que a densidade espectral da resposta é dada por

$$S_{yy}(f) = Q_0 \frac{k_1^2 + k_2^2 + 4\pi^2 f^2 (c_1^2 + c_2^2) + 2(k_1 k_2 + 4\pi^2 f^2 c_1 c_2) \cos(2\pi f T) + 4\pi f (k_1 c_2 - c_1 k_2) \sin(2\pi f T)}{(k_1 + k_2)^2 + 4\pi^2 f^2 (c_1 + c_2)^2}$$

b) Se os valores dos coeficientes de rigidez e amortecimento são os mesmos, demonstrar

que a densidade espectral da resposta é dada por $S_{yy}(f) = \frac{Q_0}{2} (1 + \cos(2\pi f T))$



6.4. Num experimento de identificação de um sistema linear onde o nível de ruído no sensor que mede a resposta é muito maior que o nível de ruído no sensor que mede a excitação, pede-se indicar qual o melhor estimador de Função de Resposta em Frequência, se $\hat{H}_1$ ou $\hat{H}_2$. Explicar por quê.

7 - Densidade espectral de potência via modelo auto-regressivo

Ao invés de modelar o sinal como uma série de Fourier, podem-se adotar outros modelos de séries ortogonais ou ainda modelos ditos paramétricos, nos quais o sinal aleatório é obtido de um ruído branco. Neste últimos supõe-se que, extraindo de um sinal aleatório toda a informação nele contida, resta um ruído perfeitamente aleatório, ou seja, o ruído branco.

7.1 Modelo auto-regressivo

Assim, discretizando $x(t)$ com f_a constante, pode-se escrever para um destes modelos paramétricos:

$$x_n = -\sum_{s=1}^p a_s x_{n-s} + n_n, \quad n = 0, \dots, N-1 \quad (7.1)$$

onde n_n é o resíduo após caracterizar-se $x_n = x(t = n\Delta t)$ pelos seus p valores em instantes passados x_{n-s} ; $s = 1, p$. Este modelo é denominado autoregressivo de ordem p . Ele é caracterizado por p coeficientes a_s ; $s = 1, p$.

Procuram-se os valores de a_s e a ordem p que tornam n_n , com n variando, uma série aleatória branca, tal que:

$$R_r = \psi_n^2 \delta_r \quad (7.2)$$

onde δ_r é o delta de Dirac discreto, definido por:

$$\delta_r = \begin{cases} 1, & r = 0 \\ 0, & r \neq 0 \end{cases} \quad (7.3)$$

e R_r é a função de autocorrelação discreta do ruído em $\tau = r\Delta t$:

$$R_r = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{s=0}^{N-1} n_s n_{s+r} \quad (7.4)$$

7.2 Densidade de Espectral de Potência

Desta forma, a densidade espectral de potência do ruído $n(t)$ é dada por:

$$S_{nn}(f) = \psi_n^2 \Delta t = cte. \quad (7.5)$$

onde ψ_n^2 é o valor médio quadrático, pois,

$$\psi_n^2 = \int_{-f_a/2}^{f_a/2} S_{nn}(f) df = S_{nn} f_a \Rightarrow S_{nn} = \psi_n^2 \Delta t$$

Assim, considerando que $S_{nn} = 0$, para $f \geq f_a/2$, hipótese necessária para a discretização, tem-se:

$$\int_{-\infty}^{\infty} S_{nn}(f) df = \int_{-f_a/2}^{f_a/2} S_{nn}(f) df = \psi_n^2 \Delta t f_a = \psi_n^2 = R_{nn}(0) \quad (7.6)$$

Rearranjando (7.1) e fazendo $a_0 = 1$ (sem perda de generalidade), tem-se:

$$n_n = \sum_{s=0}^p a_s x_{n-s} \quad (7.7)$$

Aplicando a TFD dos dois lados da igualdade, tem-se:

$$N_k = \sum_{s=0}^p a_s \frac{1}{N} \sum_{n=0}^{N-1} x_{n-s} w_N^{-nk} \quad (7.8)$$

Levando em conta a periodicidade (N) da TFD e fazendo a substituição de variáveis $q = n - s$, tem-se:

$$N_k = \sum_{s=0}^p a_s w_N^{-ks} \frac{1}{N} \sum_{q=-s}^{N-1-s} x_q w_N^{-nq} \quad (7.9)$$

ou seja

$$N_k = X_k \sum_{s=0}^p a_s e^{-i2\pi ks/N} \quad (7.10)$$

de onde é possível fazer:

$$|X_k|^2 = \frac{|N_k|^2}{\left| \sum_{s=0}^p a_s e^{-i2\pi ks/N} \right|^2} \quad (7.11)$$

Notando que o denominador em (7.11) não é aleatório, e aplicando a esperança matemática dos dois lados da igualdade:

$$S_{xx}(k\Delta f) = \frac{S_{nn}(k\Delta f)}{\left| \sum_{s=0}^p a_s e^{-i2\pi ks/N} \right|^2} \quad (7.12)$$

A equação (7.12) mostra que a DEP obtida pela TFD é equivalente à obtida determinando um modelo AR e computando o lado direito da equação (7.12). Entretanto, por hipótese tem-se que:

$$S_{nn}(f) = \psi_n^2 \Delta t$$

que pode ser substituída em (7.12):

$$\tilde{S}_{xx}(f) = \frac{\psi_n^2 \Delta t}{\left| \sum_{s=0}^p a_s e^{-i2\pi ks/N} \right|^2} \quad (7.13)$$

onde, agora, f pode voltar a ser uma variável contínua, podendo-se interpretar (7.13) como uma interpolação entre os pontos de $S_{xx}(k\Delta f)$ computados.

O fato de substituir $E[|N_k|^2]/\Delta f$ por uma constante $\psi_n^2 \Delta t$ diminui, na prática, o erro estatístico em $\tilde{S}_{xx}(f)$, suavizando a curva de $\tilde{S}_{xx}(f)$. Por esta razão, o estimador da DEP obtido pela equação (7.13) é preferido quando não se dispõe de sinal suficiente para fazer um grande número de médias na aproximação da esperança matemática.

Resta saber como estimar os parâmetros a_s do modelo autoregressivo. Existem diversas maneiras de fazê-lo (vide ^[10]). Será visto aqui apenas o método de Yule-Walker.

7.3 Calculando os parâmetros do modelo AR

Retornando à equação (7.1) e fazendo $E[x_n x_{n+k}]$, tem-se:

$$E[x_n x_{n+k}] = R_{xx}(k) = -\sum_{s=1}^p a_s E[x_{n+k-s}, x_n] + E[n_{n+k}, x_n] \quad (7.14)$$

Com a hipótese de ruído independente, o termo $E[n_{n+k}, x_n]$ se anula, obtendo-se:

$$R_{xx}(k) = -\sum_{s=1}^p a_s R_{xx}(k-s) \quad (7.15)$$

Variando o valor de k de 1 a $p-1$ (pelo menos) tem-se:

$$\begin{bmatrix} R_{xx}(0) & R_{xx}(-1) & \cdots & R_{xx}(1-p) \\ R_{xx}(1) & R_{xx}(0) & \cdots & R_{xx}(2-p) \\ \vdots & \vdots & & \vdots \\ R_{xx}(p-1) & R_{xx}(p-2) & \cdots & R_{xx}(0) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} = - \begin{bmatrix} R_{xx}(1) \\ R_{xx}(2) \\ \vdots \\ R_{xx}(p) \end{bmatrix} \quad (7.16)$$

que são denominadas *Equações de Yule – Walker*. Este sistema linear de equações pode ser resolvido dada uma ordem p . Existem implementações recursivas, como Levinson-Durbin [10], que facilitam aumentar progressivamente a ordem do modelo AR.

Akaike ^[13] investigou exaustivamente critérios para estabelecer a ordem ótima do modelo AR. Os dois índices mais utilizados são: “*Final Predictor Error* (FPE)” e o “*Akaike Information Criterion* (AIC)”, dados por:

$$FPE = \sigma \left(\frac{N + p + 1}{N - p - 1} \right) \quad (7.17)$$

$$AIC = \ln(\sigma) + \frac{2(p+1)}{N} \quad (7.18)$$

onde N é o número total de amostras de x_n utilizadas, p a ordem do modelo e $\sigma = \sqrt{\psi^2}$ é o desvio padrão do ruído residual.

Cabe notar que a matriz da equação (7.16) é uma matriz de Toeplitz ^[11] pois todas as diagonais são compostas por elementos iguais. Além disso, ela é simétrica já que $R_{xx}(\tau) = R_{xx}(-\tau)$. Portanto, esta matriz pode ser formada a partir do vetor $\{R_{xx}(0), R_{xx}(1), \dots, R_{xx}(p-1)\}$.

7.4 Metodologia para calcular a DEP via modelo AR

A metodologia para computar a DEP via modelo AR é, portanto:

- Computar $R_{xx}(r)$
- Computar $\{a_r\}$ e ψ_n^2
- Aplicar a equação (7.13)

Para computar ψ_n^2 pode-se usar a equação (7.7) e, após calcular n_n , obter a média de n_n^2 ; $n = 0, N-1$.

Outro modo de chegar às equações de Yule-Walker (equação (7.15)) consiste em fazer uma minimização de ψ_n^2 . Esta é a forma usual, encontrada na maior parte da literatura. Faz-se $E[n_n n_{n+k}]$:

$$E[n_n n_{n+k}] = \sum_{i=0}^p \sum_{j=0}^p a_i a_j E[x_{n-i} x_{n+k-j}] \quad (7.19)$$

$$k = 0 \Rightarrow R_{nn}(0) = E[n_n n_n] = \psi_n^2$$

$$\psi_n^2 = \sum_{i=0}^p \sum_{j=0}^p a_i a_j R_{xx}(i-j) \quad (7.20)$$

Minimizando ψ_n^2 vem:

$$\frac{\partial \psi_n^2}{\partial a_i} = 0 \Rightarrow 2 \sum_{j=0}^p a_j R_{xx}(i-j) = 0 \quad (7.21)$$

A equação (7.21) pode ser rearranjada para o cálculo da solução a_j , $j = 0, p$ que minimiza ψ_n^2 :

$$\sum_{j=0}^p a_j R_{xx}(i-j) = -R_{xx}(i) \quad (7.22)$$

que é idêntica à equação (7.15).

A forma como chegamos à expressão da DEP via modelo AR não é usual. Ela tem a vantagem de deixar clara a diferença entre a DEP calculada via TFD chamado de (*periodograma*) e a DEP calculada via modelo AR as vezes chamado de (*máxima entropia*).

A maneira usual, utilizada por Akaike, pode ser exposta da seguinte forma:

$$n_n n_{n+l} = \sum_{s=0}^p a_s x_{n-s} \sum_{r=0}^p a_r x_{n+l-r} = \sum_{s=0}^p \sum_{r=0}^p a_s a_r x_{n-s} x_{n+l-r}$$

Aplicando a esperança matemática de ambos os lados da igualdade vem:

$$R_{nn}(l) = \sum_{s=0}^p \sum_{r=0}^p a_s a_r R_{xx}(l-r+s) \quad (7.23)$$

mas tem-se que:

$$R_{nn}(l) = \int_{-f_a/2}^{f_a/2} S_{nn}(f) e^{i2\pi f l \Delta t} df \quad (7.24)$$

e

$$R_{xx}(l) = \int_{-f_a/2}^{f_a/2} S_{xx}(f) e^{i2\pi fl\Delta t} df \quad (7.25)$$

Aplicando, então, a integral em f de ambos os lados da equação (7.23) vem:

$$\int_{-f_a/2}^{f_a/2} S_{nn}(f) e^{i2\pi fl\Delta t} df = \int_{-f_a/2}^{f_a/2} e^{i2\pi fl\Delta t} \left(\sum_{s=0}^p a_s e^{i2\pi fs\Delta t} \sum_{r=0}^p a_r e^{-i2\pi fr\Delta t} \right) S_{xx}(f) df$$

Note-se que o segundo somatório é nada mais que o complexo conjugado do primeiro, e, portando:

$$\int_{-f_a/2}^{f_a/2} S_{nn}(f) e^{i2\pi fl\Delta t} df = \int_{-f_a/2}^{f_a/2} e^{i2\pi fl\Delta t} \left| \sum_{s=0}^p a_s e^{-i2\pi fs\Delta t} \right|^2 S_{xx}(f) df \quad (7.26)$$

Pela unicidade da transformada de Fourier, tem-se que:

$$S_{nn}(f) = S_{xx}(f) \left| \sum_{s=0}^p a_s e^{-i2\pi fs\Delta t} \right|^2$$

ou, finalmente:

$$S_{xx}(f) = \frac{S_{nn}(f)}{\left| \sum_{s=0}^p a_s e^{-i2\pi fs\Delta t} \right|^2} \quad (7.27)$$

que é idêntica à equação (7.13).

8 - Tipos de sinal e a sua representação espectral

Já vimos nos capítulos anteriores os três principais tipos de sinal e suas representações espectrais. Neste capítulo faremos uma síntese da análise espectral com foco na representação espectral apropriada para cada tipo de sinal em termos de energia e potência.

Tanto matematicamente como fisicamente, sinais transitórios, periódicos e aleatórios são de natureza diferente. Utilizando a terminologia usual de processamento de sinais, podemos chamar de “energia do sinal” a integral no tempo de seu valor absoluto ao quadrado, com unidades UE^2s , onde UE representa qualquer unidade de engenharia como, por exemplo, Newtons, metros por segundo, etc. e s a unidade de tempo. Portanto, apenas sinais transitórios (quadrado integráveis ou, falando em termos práticos, com uma duração finita no tempo) podem ter uma representação na forma de energia espectral.

8.1 Sinal transitório

O espectro de um **sinal transitório** pode ser calculado utilizando a integral (ou transformada) de Fourier e é uma função contínua da frequência. Para se obter a energia do sinal numa determinada faixa de frequências é necessário integrar o espectro nesta faixa. Desta forma, a amplitude do espectro de um sinal transitório é expressa em termos de energia por frequência, usualmente expresso em UE^2s/Hz , e é chamado de **Densidade Espectral de Energia**, ESD (do inglês, "**Energy Spectral Density**"). A ESD pode ser calculada a partir da TDF elevando ao quadrado o valor absoluto dos coeficientes complexos da TDF e multiplicando o resultado por T^2 , onde T é a duração do bloco de dados adquirido, expressa em segundos. Temos que $T=N/f_s$, onde f_s é a frequência de amostragem e N o número de amostras do bloco adquirido. O princípio de conservação da energia em processamento de sinais (teorema de Parseval) estabelece que a integral do valor absoluto do sinal ao quadrado (sua energia) é igual à integral de sua ESD. O fator de correção para a ESD calculada via a TDF pode ser obtido a partir da fórmula de Poisson^[15], que relaciona a série à transformada de Fourier.

8.2 Sinal periódico

Se o **sinal é periódico**, sua potência (energia por unidade de tempo) em UE^2 para uma dada frequência múltipla (ou harmônica) da frequência fundamental é simplesmente o valor absoluto do coeficiente da série de Fourier (também chamado coeficiente de Euler-Fourier) elevado ao quadrado. A conservação da energia, neste caso, estabelece que a soma dos quadrados dos valores absolutos dos coeficientes da série de Fourier é igual ao valor médio quadrático do sinal. Os coeficientes da TDF são aproximadamente iguais aos coeficientes da série de Fourier se um número inteiro de períodos é amostrado e se o critério de Nyquist é respeitado, isto é, se a frequência de Nyquist (metade da frequência de amostragem) é maior que a maior frequência presente no espectro do sinal. Esta condição pode ser garantida colocando um filtro passa baixas (chamado filtro "*anti-aliasing*") no caminho do sinal analógico antes de fazer a conversão analógica/digital. O uso da TDF implica sempre em tratar o sinal adquirido como se fosse um período de um sinal periódico e calcular os coeficientes da série de Fourier que representa este sinal periódico. Se o bloco de sinal adquirido não corresponde a um número inteiro de períodos, haverá um erro de "circularidade", chamado de "leakage" porque causa um "vazamento" (em inglês, "leak") da potência do sinal de uma determinada linha de frequência para as linhas vizinhas, o que pode diminuir a amplitude do pico correspondente de quase a sua metade. Janelas no tempo podem ser utilizadas para diminuir o erro de "leakage" na amplitude ao custo de uma menor resolução em frequência [15]. O espectro resultante para um sinal periódico é chamado de **Espectro de Potência**, PS (do inglês, "**Power Spectrum**").

8.3 Sinal aleatório estacionário

Finalmente, se o **sinal é aleatório estacionário** (aquele cujas propriedades estatísticas não variam no tempo), pode ser caracterizado por seu valor médio quadrático, isto é, sua potência. A distribuição da potência na frequência é a **Densidade Espectral de Potência**, PSD (do inglês, "**Power Spectral Density**"), com unidades UE^2/Hz . A PSD pode ser obtida por filtragem do sinal aleatório com um filtro passa-banda e cálculo do seu valor médio quadrático, ou estimando sua função de auto-correlação e calculando a sua integral de Fourier. Pode-se mostrar [15] que usar a TDF é equivalente tanto a fazer o cálculo por filtragem como a transformar a função de auto-correlação. A TDF corresponde a um banco de filtros de largura constante. Como o sinal aleatório não tem um período, erros de "leakage" sempre estarão presentes. Eles podem, entretanto, ser minimizados utilizando

janelas temporais adequadas, sendo a de Hanning, que tem a forma de uma senóide elevada ao quadrado, a mais utilizada. Pode-se mostrar que a aplicação da janela de Hanning no domínio do tempo é equivalente a fazer um alisamento ("smoothing") da PSD estimada, substituindo a potência em cada linha de frequência pela média ponderada entre esta e as duas linhas vizinhas, estas últimas ponderadas com um fator de 1/4. A largura de banda da TDF é simplesmente a resolução em frequência ($\Delta f = f_s/N = 1/T$). A amplitude da PSD pode, portanto, ser calculada fazendo a média dos valores absolutos dos coeficientes da TDF ao quadrado e dividindo o resultado pela resolução em frequência.

Apesar de não ser necessário, em princípio, fazer médias para estimar o espectro de sinais determinísticos (transitórios e periódicos), usualmente fazem-se médias para verificar a repetibilidade do resultado e para filtrar o ruído de medição, que sempre está presente em sinais obtidos experimentalmente. No caso de sinais aleatórios, é imperativo fazer médias, e o número de médias determina a precisão do espectro estimado. O erro estatístico na amplitude da PSD é proporcional ao recíproco da raiz quadrada do número de médias ^[16]. No caso de sinais determinísticos, esta é a taxa de atenuação do ruído aleatório aditivo presente no sinal que se consegue fazendo médias. Portanto, o procedimento usado para estimar um espectro utilizando a TDF consiste em calcular a TDF dos blocos de dados adquiridos (com ou sem sobreposição) e fazer a média dos quadrados dos valores absolutos dos coeficientes da TDF. O resultado obtido já é o PS. A ESD pode ser estimada multiplicando o resultado por T e dividindo por Δf , o que é equivalente a dividir por Δf^2 , enquanto que a PSD é obtida dividindo o resultado por Δf . Portanto, fica evidente que os resultados obtidos para os três tipos de espectro serão numericamente diferentes para um mesmo sinal e que vão ser afetados de forma diferente quando a resolução em frequência Δf é alterada.

Se um tipo de sinal não for representado com o tipo apropriado de espectro, a alteração de Δf mudará o resultado numérico da amplitude do espectro, o que não deveria ocorrer se forem tomados os devidos cuidados para evitar erros de "aliasing" e "leakage". Por outro lado, se o tipo adequado de espectro for utilizado, isto não ocorrerá. Esta propriedade dos tipos de sinal e seus espectros pode ser utilizada até para determinar o tipo predominante do sinal que está sendo analisado (se periódico, transitório ou aleatório) quando isto não for conhecido *a priori* ^[17].

É de fundamental importância que engenheiros e técnicos que trabalham com processamento de sinais tenham plena consciência de que cada tipo de sinal tem sua representação espectral e que o fato dos analisadores de espectro permitirem mudar facilmente de um tipo de espectro para outro não quer dizer que a escolha seja arbitrária.

Comparar as amplitudes de espectros de sinais transitórios, periódicos e aleatórios é o mesmo que “comparar laranjas com bananas”.

Exemplo 1

Trata-se de um sinal de pressão sonora de voz dizendo "tá" medido com um microfone de placa de som de computador e adquirido com frequência de amostragem de 11025 Hz e 8 bits de quantização. A energia do sinal obtida integrando a amplitude do sinal ao quadrado é igual à integral da ESD e vale $2.2 \times 10^{-4} \text{ V}^2\text{s}$.




figura 8.1: Exemplo de sinal transitório e sua densidade espectral de energia (ESD)

%Programa em MATLAB (The Mathworks, Inc.) v. 4.2 para gerar a figura 8.22 (o arquivo ta.wav %pode ser gerado por qualquer programa de gravação de placa multimidia para PC):

```
[y,Fs]=wavread('ta.wav');
y=y-mean(y);
y=y/1000;
N=4096;
t=(0:4095)/Fs;
T=4096/Fs;
f=(0:(N/2-1))*Fs/N;
Y=y(351:N+350);
S=fft(Y)/N;
subplot(211),plot(t,Y)
```

```

xlabel('tempo [s]')
ylabel('[V]')
subplot(212),plot(f,2*abs(S(1:N/2)*T).^2)
xlabel('frequência [Hz]')
ylabel('[V^2*s/Hz]')
sum(Y.^2)/Fs
sum(2*abs(S(1:N/2+1)*T).^2)/T

```

Exemplo 2

Trata-se de um sinal de pressão sonora de voz cantando a nota musical "la" medido com um microfone de placa de som de computador e adquirido com frequência de amostragem de 11025 Hz e 8 bits de quantização. O valor médio quadrático do sinal é igual à soma dos valores das amplitudes do PS e vale 0.0036 V^2 .




figura 8.2: Exemplo de sinal periódico e seu espectro de potência (PS)

```

% Programa em MATLAB (The Mathworks, Inc.) v. 4.2 para gerar a figura 8.2 (o
% arquivo la.wav
% pode ser gerado por qualquer programa de gravação de placa multimidia para
% PC):
[y,Fs]=wavread('la.wav');
y=y-mean(y);
y=y/1000;

```

```

N=4096;
t=(0:4095)/Fs;
f=(0:(N/2-1))*Fs/N;
Y=(y(1:N));
S=fft(Y)/N;
subplot(211),plot(t((N/2+1):(N/2+N/4)),Y((N/2+1):(N/2+N/4)))
xlabel('tempo [s]')
ylabel('[V]')
subplot(212),plot(f,2*abs(S(1:N/2)).^2)
xlabel('frequência [Hz]')
ylabel('[V^2]')
mean(Y.^2)
sum(2*abs(S(1:N/2+1)).^2)

```

Exemplo 3

Trata-se de um sinal de pressão sonora de voz dizendo "shshshsh..." medido com um microfone de placa de som de computador e adquirido com frequência de amostragem de 11025 Hz e 8 bits de quantização. A potência média do sinal obtida calculando o valor médio quadrático do sinal no tempo é igual à integral da PSD e vale 0.001 V^2 .




figura 8.3. Sinal aleatório estacionário e sua densidade espectral de potência (PSD)

%Programa em MATLAB (The Mathworks, Inc.) v. 4.2 para gerar a figura 8.3 (o arquivo sh.wav %pode ser gerado por qualquer programa de gravação de placa multimídia para PC):

```

[y,Fs]=wavread('sh.wav');
y=y-mean(y);
y=y/1000;
N=2048;

```

```
t=(0:N-1)/Fs;
T=N/Fs;
f=(0:(N/2-1))*Fs/N;
S=zeros(N,1);
H=hanning(N);
ni=1;count=0;
while (ni+N-1) <= length(y),
    Y=y(ni:ni+N-1);
    Y=Y.*H;
    S=S+2*abs(fft(Y)/N).^2*T;
    count=count+1;
    ni=ni+N/2;
end
S=S/count*8/3;
subplot(211),plot(t,y(1:N))
xlabel('tempo [s]')
ylabel('[V]')
subplot(212),plot(f,S(1:N/2))
xlabel('frequência [Hz]'); ylabel('[V^2/Hz]')
mean(y.^2)
sum(S(1:N/2))/T
```

9 - Transformada de Hilbert

A transformada de Hilbert transforma um sinal sem mudá-lo de domínio (a transformada de um sinal no tempo é um outro sinal no tempo). Vamos mostrar que a transformada de Hilbert é a relação que liga as componentes real e imaginária da transformada de Fourier de um sinal real causal. Com ela pode-se construir o sinal analítico (sinal complexo) cujo módulo (valor absoluto) corresponde à envoltória do sinal.

9.1 Sinal causal

Um sinal causal (figura 9.1) é aquele que é nulo para o tempo negativo. Todo sinal causal pode ser expresso como a composição de um sinal par e um sinal ímpar.

$$x(t) = x_p(t) + x_i(t) \quad (9.1)$$

e, usando a função sinal denotada por $sgn(t)$, tem-se:

$$\begin{aligned} x_p(t) &= x_i(t) \operatorname{sgn}(t), \\ x_i(t) &= x_p(t) \operatorname{sgn}(t) \end{aligned} \quad (9.2)$$

onde, $\operatorname{sgn}(t) = 1, x > 0$ e $\operatorname{sgn}(t) = -1, x < 0$;




figura 9.1. Sinal causal como a soma de um sinal par e um ímpar

Para relacionar as componentes par e ímpar do sinal com as componentes real e imaginária da transformada de Fourier, precisamos utilizar algumas relações já vistas anteriormente. Então, lembrando a definição da transformada de Fourier, se estabelecem relações a partir da transformada direta e inversa, notando que a única diferença entre elas está no sinal da função exponencial. Desse modo, tem-se que, para um sinal real, a transformada de Fourier possui a propriedade dada pela equação:

$$X(f) = \int_{-\infty}^{\infty} x(t)e^{-i2\pi ft} dt = X^*(-f) \quad (9.3)$$

Por outro lado, a transformada de Fourier de um sinal par ($x(t) = x(-t)$), tem a propriedade dada pela equação,

$$X(f) = \int_{-\infty}^{\infty} x(-t)e^{-i2\pi ft} dt = \int_{-\infty}^{\infty} x(t)e^{i2\pi ft} dt = X^*(f) \quad (9.4)$$

de onde conclui-se que a transformada de Fourier de um sinal par é uma função real e par, isto é, a parte imaginária é nula.

$$\tilde{f}\{x_p(t)\} = X_{\text{Re}}(f) \quad (9.5)$$

Onde $\tilde{f}\{\cdot\}$ denota a integral de Fourier e $X(f) = X_{\text{Re}}(f) + iX_{\text{Im}}(f)$.

Analogamente, a transformada de Fourier de um sinal ímpar é dada pela equação

$$X(f) = \int_{-\infty}^{\infty} x(-t)e^{-i2\pi ft} dt = - \int_{-\infty}^{\infty} x(t)e^{i2\pi ft} dt = -X^*(f) \quad (9.6)$$

de onde conclui-se que a transformada de Fourier de um sinal ímpar é imaginária e é ímpar.

$$\tilde{f}\{x_i(t)\} = iX_{\text{Im}}(f) \quad (9.7)$$

Utilizando as equações (9.1), (9.4) e (9.6) pode-se estabelecer a transformada de Fourier de um sinal causal, composto pelas componentes par e ímpar.

$$X(f) = \tilde{f}\{x(t)\} = \tilde{f}\{x_p(t)\} + \tilde{f}\{x_i(t)\} \quad (9.8)$$

Então, utilizando as equações (9.5) e (9.7) na equação (9.8) tem-se,

$$X(f) = X_{\text{Re}}(f) + iX_{\text{Im}}(f) \quad (9.9)$$

As partes par e ímpar do sinal $x(t)$ podem ser reescritas uma em função da outra utilizando a equação (9.2), de maneira que as componentes real e imaginária da transformada de Fourier podem ser obtidas uma em função da outra.

A relação existente entre as componentes real e imaginária da transformada de Fourier de um sinal causal é conhecida como a transformada de Hilbert ^[18]. Utilizando as equações (9.2), (9.5) e (9.7), tem-se

$$X_{\text{Re}}(f) = \tilde{f}\{x_p(t)\} = \tilde{f}\{x_i(t)\text{sgn}(t)\} \quad (9.10)$$

Aplicando o teorema da convolução,

$$X_{\text{Re}}(f) = \tilde{f}\{x_p(t)\} = \tilde{f}\{x_i(t)\} * \tilde{f}\{\text{sgn}(t)\} \quad (9.11)$$

de onde,

$$X_{\text{Re}}(f) = iX_{\text{Im}}(f) * \frac{1}{i\pi f} = X_{\text{Im}}(f) * \frac{1}{\pi f} \quad (9.12)$$

já que $\tilde{f}\{\text{sgn}(t)\} = \frac{1}{i\pi f}$.

Formalmente, a transformada de Hilbert do sinal $x(t)$ é definida como a convolução do sinal $x(t)$ e $\frac{1}{\pi t}$.

$$H\{x(t)\} = \frac{1}{\pi} \int_{-\infty}^{\infty} x(\tau) \frac{1}{t - \tau} d\tau = x(t) * \left(\frac{1}{\pi t} \right) \quad (9.13)$$

Aplicando a transformada de Fourier e o teorema da convolução na equação (9.13),

$$\tilde{f}\{H\{x(t)\}\} = X(f)(-i\text{sgn}(f)) = e^{-i\frac{\pi}{2}} X(f)\text{sgn}(f) \quad (9.14)$$

pois, a transformada de Fourier de $\frac{1}{\pi t}$ é $-i\text{sgn}(f)$, de onde pode-se obter a transformada de Hilbert utilizando a transformada de Fourier inversa.

$$H\{x(t)\} = \tilde{f}^{-1}\left\{e^{-i\frac{\pi}{2}} \tilde{f}\{x_p(t)\}\text{sgn}(f)\right\} \quad (9.15)$$

Na equação (9.15), pode-se observar que houve uma mudança de fase em 90° da transformada de Fourier, deslocando a fase das frequências positivas em -90° e das frequências negativas em 90° .

9.2 Algoritmo para o cálculo da transformada de Hilbert

Resumindo, para calcular a transformada de Hilbert de um sinal é preciso:

1. Calcular o espectro do sinal via transformada de Fourier.

2. Girar a fase em 90° multiplicando o espectro por $\{-i \operatorname{sgn}(f)\}$ (equação (9.14)).
3. Retornar ao domínio do tempo através da transformada inversa de Fourier (equação (9.15)).

Este procedimento para o cálculo da transformada de Hilbert é bastante simples, se comparado com o cálculo através da equação (9.13).

9.3 Sinal analítico

Definição: A partir do sinal original e do sinal calculado utilizando a transformada de Hilbert, é possível obter o sinal analítico, que é um sinal complexo cuja parte real é o sinal original e cuja parte imaginária é a transformada de Hilbert do sinal original, isto é,

$$x_a(t) = x(t) + i(H\{x(t)\}) \quad (9.16)$$

9.4 Detecção do envelope de um sinal

O envelope de um sinal pode ser obtido fazendo uso da transformada de Hilbert. A figura 9.2 mostra um diagrama de blocos para a obtenção do envelope de um sinal. Ao sinal original aplica-se a transformada de Hilbert e os dois sinais são somados. A seguir, é realizado o cálculo do valor absoluto que constitui o envelope aproximado do sinal original.




figura 9.2. Diagrama de blocos para a obtenção do envelope de um sinal

Exemplo 1

Um exemplo de aplicação consiste em obter o sinal modulador de um sinal composto. Considere-se um sinal cuja frequência é de 1 kHz modulado por um sinal de 70 Hz como mostrado na figura 9.3.

Para demodulá-lo, isto é, para obter a envoltória do sinal modulado, encontra-se o sinal analítico (sinal complexo), cuja parte real é o sinal original (sinal modulado) e cuja parte imaginária é a sua transformada de Hilbert. O módulo do sinal analítico é a envoltória do sinal original como mostra a figura 9.4.




figura 9.3. Sinal de 1 kHz modulado por um outro sinal de 70 Hz




figura 9.4. Sinal modulado e envoltória

Exemplo 2

Considere-se um sinal com decaimento exponencial dado pela equação (9.17)

$$x(t) = e^{-\zeta t} \sin(\omega_0 t) \quad (9.17)$$

onde $\omega_0 = 31$ rad/s e $\zeta = 0.5$.

A resposta livre do sistema amortecido é mostrada na figura 9.5 (a) e o envelope na figura 9.5 (b).




figura 9.5 (a) Resposta de um sistema livre amortecido e (b) envelope do sinal

O envelope foi obtido através da função analítica. Pode-se calcular o coeficiente de amortecimento calculando a inclinação do logaritmo da envoltória, como se mostra na figura 9.6 (a). Através desta curva é possível calcular o coeficiente de amortecimento ou fator de amortecimento do modelo tratado. Observa-se, na figura 9.6 (b), que a inclinação da reta é de aproximadamente 0.5, consequentemente $\zeta = 0.5$.




figura 9.6 (a) Logaritmo do envelope (b) e logaritmo do envelope entre 2 e 6 segundos.

Nota-se na figura 9.6 (a) que há efeitos de distorção nas extremidades do valor absoluto do sinal analítico.

10 - Outros métodos

Neste capítulo, duas ferramentas de processamento de sinais baseadas na TFD são apresentadas. Menos conhecidas, estas ferramentas permitem alisar e derivar curvas e superfícies, obter espectros de sinais com amostragem não igualmente espaçada e obter espectros com largura de banda proporcional à frequência. São ferramentas relativamente novas e cujo potencial ainda não foi totalmente explorado.

10.1 Série de Fourier discreta regressiva (RDFS)

A série de Fourier discreta regressiva (RDFS) é uma ferramenta utilizada para minimizar o problema do “*leakage*” e pode ser usada mesmo para sinais com amostragem de espaçamento arbitrário (frequência de amostragem variável). Originalmente a RDFS foi proposta por Arruda ^{[19] [20]}.

RDFS unidimensional

Já vimos que a transformada de Fourier discreta de um sinal $x(t = n\Delta t) = x_n$ é definida como

$$X_k = \frac{1}{N} \sum_{n=0}^{N-1} x_n W_N^{-kn}, \quad k = 0, \dots, N-1 \quad (10.1)$$

e, a transformada inversa de Fourier como

$$x_n = \sum_{k=0}^{N-1} X_k W_N^{kn}, \quad n = 0, \dots, N-1 \quad (10.2)$$

onde, $W_N = \exp(-i2\pi kn/N)$ é a N -ésima raiz da unidade (vide caps. 1 e 2). Os elementos da transformada de Fourier discreta X_k , são os coeficientes da série de Fourier discreta. A série de Fourier discreta tem período $N\Delta t$ com N par, tem-se com $N/2$ linhas de frequências positivas (sendo um deles o termo de Nyquist que é real), o nível de “corrente contínua” (DC) e $N/2-1$ linhas de frequências negativas. A equação (10.2) pode ser rescrita na forma matricial como

$$W X = x \quad (10.3)$$

$$\text{onde } x = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{N-1} \end{bmatrix}, W = \begin{bmatrix} W^0 & W^0 & \dots & W^0 \\ W^0 & W^1 & \dots & W^{N-1} \\ \vdots & \vdots & \ddots & \vdots \\ W^0 & W^{(N-1)} & \dots & W^{(N-1)(N-1)} \end{bmatrix}, X = \begin{bmatrix} X_0 \\ X_1 \\ \vdots \\ X_{N-1} \end{bmatrix}$$

A solução da equação (10.3) pode ser obtida usando mínimos quadrados, isto é:

$$X = (W^H W)^{-1} W^H x \quad (10.4)$$

onde o índice H denota a transposta da matriz complexa conjugada. Devido às propriedades de ortogonalidade da exponencial complexa, é possível demonstrar que

$$W^H W = NI \quad (10.5)$$

onde I é a matriz identidade, de maneira que a equação (10.4) pode ser escrita como

$$X = \left(\frac{1}{N} \right) W^H x \quad (10.6)$$

A equação (10.6) é exatamente a expressão da transformada de Fourier inversa discreta. Como a matriz W é quadrada tem-se, na verdade, uma interpolação, e não uma aproximação por mínimos quadrados.

A RDFS consiste no uso do modelo da série de Fourier discreta generalizada para aproximar os dados que não necessariamente tenham espaçamento fixo.

Seja a série de Fourier discreta expressada como

$$x(t_n) = \sum_{k=-P}^P X_k e^{\left(\frac{-i2\pi t_n}{T} \right)} + \varepsilon_n, \quad n = 0, \dots, N \quad (10.7)$$

A expressão (10.7) contém P componentes de frequências positivas, o nível DC, P componentes de frequências negativas, além da existência do ruído ε_n . O período T da série de Fourier discreta é arbitrário. A equação (10.7) pode ser rescrita na forma matricial como

$$W X = x + \varepsilon \quad (10.8)$$

$$\text{com } W_{nk} = e^{\left(\frac{-i2\pi k t_n}{T} \right)}, \quad n = 1, \dots, N, \quad k = -P, \dots, P$$

$$X = [X_{-P} \quad \dots \quad X_{-1} \quad X_0 \quad X_1 \quad \dots \quad X_P]^T, \quad x = [x_0 \quad \dots \quad x_{N-1}]^T, \quad \varepsilon = [\varepsilon_0 \quad \dots \quad \varepsilon_{N-1}]^T$$

Na equação (10.8) ε representa o ruído no modelo da série de Fourier discreta. A solução via mínimos quadrados, que será chamada de RDFS, para a equação (10.8) é dada por

$$\hat{X} = (W^H W)^{-1} W^H x \quad (10.9)$$

Se o número de linhas de frequência P é pequeno, então a RDFS terá o efeito de um filtro passa baixas. Os dados filtrados serão obtidos a partir da equação

$$\hat{x} = W\hat{X} \quad (10.10)$$

O período T é arbitrário e pode ser otimizado visando minimizar o erro ε .

Exemplo

Como exemplo seja o sinal definido como $x = \cos(2t) + \sin(4t)$ discretizado a espaçamentos variando entre 0.000149 e 0.0665 com ruído de: 0%, 10%, 20% e 35%. Utilizando a RDFS com $P = 5$ teremos, no total, 11 elementos na equação (10.9). Utilizando a equação (10.10), o sinal aproximado pela RDFS é reconstruído. O resultado é mostrado na figura 10.1.

Na figura 10.1, pode-se observar que, apesar do espaçamento desigual, é possível reconstruir o sinal através da RDFS mesmo na presença de ruído. Esta ferramenta também pode ser utilizada em sinais truncados, reduzindo o “leakage” que aparece quando se usa a TDF.

RDFS bidimensional

A suavização de funções escalares que dependem de duas variáveis são amplamente utilizados em muitas áreas de aplicação. De maneira similar ao tratamento de sinais unidimensionais via RDFS, o objetivo é estimar os coeficientes da série de Fourier discreta bidimensional com período arbitrário e resolução em frequência também arbitrária via mínimos quadrados. A formulação aqui apresentada foi originalmente proposta por Arruda [19].




figura 10.1. Exemplo de utilização da RDFS para sinais com espaçamento não igual e contaminado por ruído aditivo (— sinal e *** reconstruído pela RDFS): (a) 0% , (b) 10%, (c) 20% e (d) 35%.

Para funções bidimensionais $x(\xi, \eta)$ discretizadas a passos iguais com resoluções $\Delta\xi$ e $\Delta\eta$, a transformada de Fourier discreta bidimensional pode ser aplicada

$$X_{kl} = \frac{1}{M} \frac{1}{N} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} x_{mn} W_M^{-km} W_N^{-ln}, \quad k = 0, 1, \dots, M-1, \quad l = 0, 1, \dots, N-1 \quad (10.11)$$

onde x_{mn} é o sinal digitalizado a uma taxa constante, $W_N = \exp(i2\pi/N)$ e $W_M = \exp(i2\pi/M)$ são as raízes N e M da unidade, respectivamente; e X_{kl} são os coeficientes de Euler-Fourier bidimensionais. De igual maneira podem ser obtidos os dados originais através da transformada de Fourier inversa discreta dada pela equação (10.12).

$$x_{mn} = \sum_{k=0}^{M-1} \sum_{l=0}^{N-1} X_{kl} W_M^{km} W_N^{ln}, \quad m = 0, 1, \dots, M-1, \quad n = 0, 1, \dots, N-1 \quad (10.12)$$

A equação (10.12) mostra que a série de Fourier discreta bidimensional com período M em m e período N em n é o modelo utilizado para interpolar x_{mn} . O efeito da periodização introduz componentes de alta frequência que representa extremos com mudanças abruptas. Estas mudanças abruptas introduzem no espectro o que é conhecido como o efeito de “leakage”. O processo de janelamento utilizado para evitar o “leakage” produz distorção nas bordas dos dados.

A TDF bidimensional é usualmente calculada em dois passos. No primeiro passo, é calculada a TDF unidimensional sobre as colunas da matriz $[x_{mn}]$, e no segundo passo, é calculada a TDF unidimensional sobre as linhas da matriz $[x_{mn}]$. Na equação (10.11), aplicando a TDF unidimensional sobre as colunas da matriz x_{mn} , tem-se:

$$Y_{kn} = \frac{1}{M} \sum_{m=0}^{M-1} x_{mn} W_M^{-km}, \quad k = 0, 1, \dots, M-1, \quad n = 0, 1, \dots, N-1 \quad (10.13)$$

e a seguir é calculada a TDF unidimensional sobre as linhas de Y_{kn}

$$X_{kl} = \frac{1}{N} \sum_{n=0}^{N-1} Y_{kn} W_N^{-ln}, \quad k = 0, 1, \dots, M-1, \quad l = 0, 1, \dots, N-1 \quad (10.14)$$

O “alisamento” é efetuado através da aplicação de um filtro passa-baixas antes de aplicar a TDF inversa, o qual é também realizado em duas etapas. Primeiro, a filtragem é realizada na direção η , e q linhas de frequência são reservadas.

$$X_{kl} = 0, \quad l = q+1, \dots, N-q \quad (10.15)$$

Segundo, a TDF inversa das linhas de X_{kl} é calculada.

$$Y_{kn} = \sum_{l=0}^{N-1} X_{kl} W_M^{ln}, \quad k = 0, 1, \dots, M-1, \quad n = 0, 1, \dots, N-1 \quad (10.16)$$

Os valores intermediários Y_{kn} da equação (10.16) são filtrados, restando as primeiras p linhas de frequências:

$$Y_{kn} = 0, \quad k = p+1, \dots, M-p \quad (10.17)$$

Notar que as linhas $M-p+1, \dots, M-1$ e $N-q+1, \dots, N-1$ correspondem às primeiras p e q frequências negativas em ξ e η , respectivamente, e não deveriam ser desperdiçadas. Finalmente, os dados suavizados nas duas direções (equação (10.18)) são obtidos ao aplicar pela segunda vez a TDF inversa às colunas de Y_{kn}

$$x^{(s)}_{mn} = \sum_{k=0}^{M-1} Y_{kn} W_N^{km}, \quad m = 0, 1, \dots, M-1, \quad n = 0, 1, \dots, N-1 \quad (10.18)$$

As derivadas parciais espaciais podem ser obtidas através da diferenciação da equação (10.12) com relação a $\xi = m\Delta\xi$ e $\eta = n\Delta\eta$, que são equivalentes a multiplicar Y_{kn} por $i2\pi k/M\Delta\xi$ e X_{kl} por $i2\pi k/M\Delta\eta$, respectivamente, antes da obtenção da TDF inversa.

Diferentes métodos podem ser utilizados para minimizar o “leakage” na TDF unidimensional. Uma das maneiras é a utilização das funções de interpolação tipo “spline” de ordem três que permitem levar suavemente os sinais a zero nos extremos [21].

Na RDFS bidimensional, ao contrário da TDF, os períodos dos dados não são assumidos como sendo iguais à sua extensão, e o número de linhas de frequência não é igual ao tamanho da matriz de dados. Para dados igualmente espaçados pode-se escrever:

$$x_{mn} = \sum_{k=-p}^p \sum_{l=-q}^q X_{kl} W_{MM}^{km} W_{NN}^{ln} + \varepsilon_{mn}, \quad m = 0, \dots, M-1, \quad n = 0, \dots, N-1 \quad (10.19)$$

O comprimento dos dados em ξ é M , porém o período da serie de Fourier é $MM > M$. O número de linhas de frequência é $p \ll M$. De maneira análoga, na direção η , $NN > N$ e $q \ll N$. A RDFS é uma função de aproximação ao invés de uma função de interpolação de x_{mn} , e os coeficientes da serie de Euler-Fourier não podem ser calculados através da TDF. Rescrevendo a equação (10.19) na forma matricial,

$$x = W_{MM} X W_{NN} + \varepsilon \quad (10.20)$$

Aplicando mínimos quadrados na equação (10.20), tem-se

$$X = (W_{MM}^H W_{MM})^{-1} W_{MM}^H x W_{NN}^H (W_{NN} W_{NN}^H)^{-1} \quad (10.21)$$

onde H denota a transposta conjugada de uma matriz. É importante notar que as matrizes a serem invertidas têm tamanho $(2p + 1, 2p + 1)$ e $(2q + 1, 2q + 1)$. A função suavizada é obtida a partir de,

$$x^{(s)} = W_{MM} X W_{NN} \quad (10.22)$$

Se diferentes medidas são realizadas sobre a mesma superfície, então são aplicadas conceitos estatísticos, e elas podem ser viabilizadas utilizando o estimador de máximo verossimilhança [22]. Neste caso, a equação (10.21) é modificado através da utilização de matrizes de ponderação.

$$\hat{X} = (W_{MM}^H V_r^{-1} W_{MM})^{-1} W_{MM}^H V_r^{-1} x V_c^{-1} W_{NN}^H (W_{NN} V_c^{-1} W_{NN}^H)^{-1}$$

Estas matrizes de ponderação V_r^{-1} e V_c^{-1} são as matrizes inversa das matrizes de covariância de erro nas linhas e nas colunas, respectivamente.

Superfícies com diferentes espaçamentos

Seja uma superfície (sinal bidimensional) amostrada nos pontos (ξ_m, η_n) . Pode-se escrever uma aproximação por série de Fourier bidimensional na forma

$$x_{mn} = \sum_{k=-p}^p \sum_{l=-q}^q X_{kl} e^{\left(\frac{i2\pi k \xi_m}{T_\xi}\right)} e^{\left(\frac{i2\pi l \eta_n}{T_\eta}\right)} + \varepsilon_{mn}, \quad m = 0, \dots, M-1, \quad n = 0, \dots, N-1 \quad (10.23)$$

A equação (10.23) pode ser escrita na forma matricial como

$$x = W_\xi X W_\eta + \varepsilon \quad (10.24)$$

onde $(W_\xi)_{km} = e^{\left(\frac{i2\pi k \xi_m}{T_\xi}\right)}$ e $(W_\eta)_{ln} = e^{\left(\frac{i2\pi l \eta_n}{T_\eta}\right)}$

A solução da equação (10.24) por mínimos quadrados é,

$$X = (W_\xi^H W_\xi)^{-1} W_\xi^H x W_\eta^H (W_\eta^H W_\eta)^{-1} \quad (10.25)$$

A superfície suavizada será dada por

$$x^{(s)} = W_\xi X W_\eta \quad (10.26)$$

As derivadas parciais espaciais podem ser calculadas como as mencionadas na seção anterior. Isto é, multiplicando por $i2\pi k/M\Delta\xi$ nas linhas e $i2\pi l/M\Delta\eta$ nas colunas, respectivamente, antes de calcular a TDF inversa.

Dados em “grid” não retangular

Quando os dados não estão mapeados num “grid” retangular, então eles não podem ser representados na forma matricial. Entretanto, eles podem ser representados em forma de vetores com relação às coordenadas, de maneira que o modelo bi-dimensional da série de Fourier discreta pode ser escrito como:

$$\chi_n = \sum_{k=-p}^p \sum_{l=-q}^q X_{kl} e^{\left(\frac{i2\pi k \xi_n}{T_\xi}\right)} e^{\left(\frac{i2\pi l \eta_n}{T_\eta}\right)} + \varepsilon_n, \quad n = 0, \dots, N-1 \quad (10.27)$$

onde N é, agora, o número total de pontos amostrados $\chi(\xi_n, \eta_n)$.

Para reescrever a equação (10.27) na forma matricial, é necessário organizar os elementos X_{kl} no vetor χ de elementos $\chi_s = X_{kl}$, com $s = (k-1)(2q+1) + l$,

onde $k = -p, \dots, p$; $l = -q, \dots, q$; $s = 1, \dots, (2p+1)(2q+1)$.

A matriz de funções exponenciais terá uma dimensão $N \times (2p+1)(2q+1)$. Se A é a matriz de funções exponenciais, então:

$$A_{ns} = e^{\left(\frac{i2\pi k \xi_n}{T_\xi} + \frac{i2\pi l \eta_n}{T_\eta} \right)}, \quad n = 0, \dots, N-1$$

$$s = (k-1)(2q+1) + l = 1, \dots, (2p+1)(2q+1)$$
(10.28)

Então, a equação (10.27) pode ser rescrita na forma matricial como,

$$\chi = A X + \varepsilon$$
(10.29)

A solução da equação (10.29) por mínimos quadrados é,

$$X = (A^H A)^{-1} A^H \chi$$
(10.30)

e a forma suavizada é obtida a partir de,

$$\chi^{(s)} = A X$$
(10.31)

e as derivadas parciais podem ser calculadas da mesma maneira que nas seções anteriores.

O processamento estatístico dos dados pode ser obtido através do uso de matrizes de ponderação V^{-1} na equação (10.29), de maneira que a solução será dada por:

$$\hat{X} = (A^H V^{-1} A)^{-1} A^H V^{-1} \chi$$
(10.32)

onde $V = [\varepsilon \varepsilon^T]$ é a estimativa da matriz de covariância do ruído.

Exemplo

Como exemplo, seja a superfície definida como

$$x_{m,n} = \sin\left(\frac{2\pi m}{M - \frac{1}{4}M}\right) \cos\left(\frac{2\pi n}{N - \frac{1}{4}N}\right); \quad \text{com } m = 1, \dots, M, n = 1, \dots, N,$$

com $\Delta\xi = \Delta\eta = 1$, e número de amostras $M = 16$ e $N = 32$.

À superfície original é adicionado ruído em níveis de 25%. A figura 10.2a ilustra a superfície sem ruído e a figura 10.2b é a superfície com ruído. A figura 10.3 mostra a superfície suavizada usando a RDFS com número de linhas nos espectros das equações (10.21) e (10.22) $p=3$ e $q=3$.

. A superfície suavizada é obtida usando RDFS através das equações (10.21) e (10.22) cujo resultado é ilustrado na figura 10.3.




figura 10.2. Superfície original




figura 10.3. Superfície suavizada usando RDFS

10.2 Transformada Q constante

A transformada Q constante é uma ferramenta que permite realizar a representação espectral cuja razão entre a frequência central e a largura de banda seja constante. Este tipo de análise é comumente utilizado em acústica. A transformada discreta de Fourier utiliza uma resolução em frequência, isto é, um espaçamento em frequência, constante. De maneira geral, a resolução, ou largura de banda, da k -ésima linha é dada por

$$\Delta f_k = \frac{f_s}{N_k} \quad (10.33)$$

onde f_s é a frequência de amostragem e N_k é o número total de amostras. Por outro lado, a razão entre a frequência central (f_k) e a largura de banda (Δf_k) da análise é dada por

$$Q_k = \frac{f_k}{\Delta f_k} \quad (10.34)$$

Observa-se na equação (10.33) que, para diminuir o espaçamento do espectro, deve-se diminuir a frequência de amostragem (o que geralmente não é desejável) ou aumentar o número de linhas.

Sendo o objetivo manter Q constante ($Q_k = Q, \forall k$), combinando as equações (10.33) e (10.34), isola-se N_k ,

$$N_k = Q \frac{f_s}{f_k} \quad (10.35)$$

Na equação (10.35), mantendo a frequência de amostragem constante, se há um aumento da frequência central da banda k , haverá uma diminuição do número de linhas correspondente a esta banda.

A componente espectral k da transformada Q constante é obtida a partir da transformada de Fourier discreta (ou de curta duração “*short time Fourier transform –STFT*”) [23] definida como

$$X_k = \frac{1}{N} \sum_{n=0}^{N-1} w_n x_n e^{-i2\pi kn/N} \quad (10.36)$$

onde, x_n e w_n são as amostras do sinal e da janela, respectivamente, N é o número total de amostras, e $2\pi k/N$ é a frequência angular da componente k . Para a transformada Q constante, a frequência da componente k é $2\pi Q/N_k$ [24]. Onde N_k é o número de amostras para a componente k (equação 11.35). Isto é, a relação $f_k/\Delta f_k$ é k para a STFT e Q na transformada Q constante. A função janela w tem a mesma forma que a utilizada na STFT, porém o comprimento e a amplitude dependem do número de amostras N_k , de forma que, a equação (10.36) sofre uma reformulação

$$X_k = \sum_{n=0}^{N_k-1} \frac{w_{n,k}}{N_k} x_n e^{-i2\pi Qn/N_k} \quad (10.37)$$

A transformada Q constante definida pela equação (10.37) se parece muito com a transformada de Fourier discreta. Entretanto, não pode ser aplicada diretamente, pois o comprimento da janela para cada componente k é diferente.

Brown ^[25] propôs um algoritmo eficiente para o cálculo da transformada Q constante utilizando a transformada de Fourier, obtido através do uso do teorema de Parseval. Segundo o teorema de Parseval, sabe-se que para dois sinais x e y

$$\sum_{n=0}^{N-1} x_n y_n^* = N \sum_{k=0}^{N-1} X_k Y_k^* \quad (10.38)$$

onde X e Y são as TDFs de x e y respectivamente. Isto é

$$X_k = \frac{1}{N} \sum_{n=0}^{N-1} x_n e^{-i2\pi kn/N}$$

$$Y_k = \frac{1}{N} \sum_{n=0}^{N-1} y_n e^{-i2\pi kn/N}$$

Na equação (10.6), y^* é o conjugado de y e Y^* é o conjugado de Y , respectivamente.

Na equação (10.37), fazendo

$$X_{k_0} = \sum_{n=0}^{N_{k_0}-1} \frac{w_{n,k_0}}{N_{k_0}} x_n e^{-i2\pi Qn/N_{k_0}} = \sum_{n=0}^{N_{k_0}-1} x_n K_{temp}^*{}_{n,k_0} \quad (10.39)$$

onde

$$K_{temp}{}_{n,k_0} = \frac{w_{n,k_0}}{N_{k_0}} e^{i2\pi Qn/N_{k_0}} \quad (10.40)$$

de forma que sua conjugada é $K_{temp}^*{}_{n,k_0} = \frac{w_{n,k_0}}{N_{k_0}} e^{-i2\pi Qn/N_{k_0}}$. A expressão dada pela

equação (10.40) é conhecida como função núcleo (em inglês, “*kernel*”) no tempo, cujo comportamento pode ser observada na figura 10.4a.

Utilizando o teorema de Parseval dado pela equação (10.38), tem-se

$$\sum_{n=0}^{N_{k_0}-1} x_n K_{temp}^*{}_{n,k_0} = N_{k_0} \sum_{k=0}^{N_{k_0}-1} X_k K_{spec}^*{}_{k,k_0} \quad (10.41)$$

sendo X e K_{spec} (figura 10.4b), as transformadas de Fourier discreta do sinal x e do núcleo temporal K_{temp} (figura 10.4a), respectivamente. Desta maneira, utilizando-se o lado direito da equação (10.41), calcula-se a transformada Q constante do sinal x a partir de sua transformada de Fourier discreta. Observa-se na equação (10.41) que os núcleos, tanto no

domínio do tempo como no domínio da frequência, podem ser gerados uma única vez , pois eles são independentes do sinal e de sua transformada de Fourier.




figura 10.4. Núcleo no domínio do tempo (a) e no domínio da frequência (b)

Para um sinal x estacionário, é possível calcular a densidade espectral de energia ^[26] do sinal x em bandas de Q constante usando a relação:

$$X_{q_{k_0}} = N_{k_0} \sum_{k=0}^{N_{k_0}-1} X_k K_{espec}^*_{k,k_0} \quad (10.42)$$

Aplicações da transformada Q constante

Uma das aplicações da transformada de Q constante é a análise de sinais sonoros. Em acústica, a característica do espaçamento geométrico das frequências centrais está diretamente ligada à sensibilidade do ouvido humano. Assim, a transformada Q constante é utilizada, entre outras, no cálculo de espectros de violinos ^[27], no reconhecimento de padrões de qualidade de violinos ^[28] e em filtros acústicos ^[29].

Filtros acústicos usando a transformada Q

De maneira geral, a transformada Q constante permite construir filtros acústicos com espaçamentos geométricos entre frequências centrais dos filtros vizinhos. Definindo como

$$f_k = 2^{1/b} f_{k-1} \quad (10.43)$$

onde a constante b é o número de componentes ou número de filtros por oitava. Por exemplo, para se obterem filtros de 1/3 oitava, a variável b tomará o valor 3, já para filtros de oitava, a variável b tomará o valor 1.

A frequência central do filtro k pode ser obtida em função da frequência central do primeiro filtro; isto é

$$\begin{aligned}
 f_k &= 2^{1/b} f_{k-1} \\
 &= (2^{1/b})^2 f_{k-2} \\
 &= (2^{1/b})^3 f_{k-3} \\
 &\vdots \\
 &= (2^{1/b})^{k-1} f_1
 \end{aligned} \tag{10.44}$$

Se considerarmos que f_1 representa a menor frequência central ($f_{\min}$), então a frequência f_k poderá ser representada como

$$f_k = (2^{1/b})^{k-1} f_{\min} \tag{10.45}$$

Se a frequência $f_{\max}$ corresponde à maior frequência central, então o número total de filtros é dado por

$$k_{\max} = b \ln 2 \left(\frac{f_{\max}}{f_{\min}} \right) + 1 \tag{10.46}$$

O número de amostras para cada banda é obtido utilizando a equação (10.35) e as frequências fundamentais de cada banda são calculadas utilizando a equação (10.45). A figura 10.5 mostra o banco de filtros de 1/3 de oitava padrão utilizados na análise de sinais acústicos.




figura 10.5. Filtros de 1/3 oitava usando a transformada Q

Tratamento de sinais sonoros utilizando a transformada Q constante

No processamento de sinais sonoros, a transformada Q constante é uma ferramenta poderosa. A percepção do ouvido humano com relação ao espectro em frequência é logarítmica. Isto é, para componentes de baixa frequência é necessário uma janela cuja largura seja estreita, porém para altas frequências é necessário uma janela de largura maior. Na figura 10.4, são representados os núcleos no domínio do tempo (a) e no domínio da frequência (b). Observa-se que o núcleo no domínio do tempo requer de uma janela de comprimento considerável em baixas frequências.

Considera-se um sinal sonoro com frequências entre 196 Hz e 4186 Hz, cujo comprimento é de 1024 amostras, digitalizadas a uma frequência de amostragem de 32000 amostras/s (32000 Hz). A resolução em frequência é de 31.25 Hz, que corresponde a 16% da frequência inferior (196 Hz) e 0.7% da frequência superior (4186 Hz). Para sinais sonoros musicais é necessário que a separação espectral entre duas notas adjacentes seja ao redor de 6% [24], conseqüentemente, o limite inferior (196 Hz) não está corretamente representado e o limite superior (4186 Hz) tem maior número de amostras (em frequência) do que o necessário. Desta maneira, demonstra-se que a o espaçamento regular feito na transformada de Fourier discreta não é adequada para o tratamento de sinais musicais.

Então, o espectro estimado [29]^[30], pode ser obtido usando

$$S_{k_0} = coef X_{q_{k_0}} X_{q_{k_0}}^* \quad (10.47)$$

onde *coef* é o coeficiente que depende do tipo de janela utilizada, i.e. para a janela de Hanning, o valor do coeficiente é 8/3.


Exemplo

Os sinais produzidos por violinos podem ser representados e analisados usando a transformada Q constante. Na figura 10.6 é mostrado um conjunto de violinos de diferentes fabricantes. O objetivo é realizar uma análise da qualidade dos violinos usando a transformada Q constante. Os sinais foram adquiridos em um ambiente padronizado (sala semi-anecóica). Estes dados (a), foram transportados para o ambiente MATLAB, onde foi utilizado o método da transformada Q constante que permite a representação do espectro em tempo e frequência como mostra a


figura 10.7b. Nesta figura, podem ser observadas, que as variações do espectro são do tipo logarítmico semelhante à percepção qualitativa do nosso ouvido.



figura 10.6. Sinal de um violino produzindo um “glisando”



(a)



(b)

figura 10.7. a) Sinal no tempo, b) espectro tempo - frequência usando a transformada Q constante

11 - Modelos paramétricos

Neste capítulo, inicialmente o método de Prony é apresentado. Este método não usa o modelo de série de Fourier, mas também utiliza uma somatória de exponenciais complexas para representar um sinal. Entretanto, aqui as frequências das exponenciais não são mais múltiplas de uma frequência fundamental, sendo estimadas no processo de estimação dos coeficientes. Com isso o problema torna-se não-linear e o método de Prony representa uma forma astuciosa de resolver este problema de equações não lineares, quebrando-o em duas etapas.

O método de Prony também é utilizado para identificar sistemas lineares, cujas funções de resposta ao impulso unitário são somatórias de exponenciais complexas, cujos expoentes são os auto-valores e cuja transformada, que é a função de resposta em frequência (FRF) pode ser colocada na forma de pólos e resíduos:

$$h(t) = \sum_{r=1}^{2N} A_r e^{s_r t} \Leftrightarrow H(\omega) = \sum_{r=1}^{2N} \frac{A_r}{i\omega - s_r},$$

onde $i = \sqrt{-1}$. Quando mais de uma função resposta ao impulso de um mesmo sistema deve ser tratada, particularmente quando o sistema tem mais de uma entrada, o método precisa ser generalizado, o que é feito no chamado método “polireferência”. Neste caso, as FRFs são expressas como:

$$H_{ij}(\omega) = \sum_{r=1}^{2N} \frac{A_{ijr}}{(i\omega - s_r)} \quad \text{onde} \quad A_{ijr} = \frac{\Phi_{ir} \Phi_{jr}}{a_r}$$

onde s_r é o r -ésimo autovalor e Φ_r o r -ésimo autovetor, i indica o grau de liberdade onde a resposta é medida e j o grau de liberdade onde é feita a excitação. Nos métodos “polireferência”, FRFs com mais de uma entrada j são tratadas simultaneamente na extração dos autovalores e autovetores.

Além do método de Prony e do método polireferência derivado dele, outros métodos de identificação de sistemas lineares são apresentados de forma sucinta neste capítulo. As formulações apresentadas aqui foram adaptadas de textos de referência no assunto como o livro de Ewins^[31] e o relatório de Allemang et al.^[32]. Os métodos polinomiais foram adaptados dos artigos de Vold^[33] e^[34] e Richardson e Formenti^[35]. A formulação do método de Ibrahim foi adaptada de Ibrahim e Mukulick^[36].

11.1 Método de Prony

O método de Prony consiste em encontrar um conjunto de p funções exponenciais arbitrárias (magnitude e fase) que mais aproximem os dados medidos (amostras do sinal). Este método é apropriado quando o sinal é uma soma de funções exponenciais e quando a ordem do modelo (número de funções exponenciais) pode ser estimado. Para ter sucesso, é necessário que o número de pontos dos dados seja no mínimo duas vezes a ordem do modelo.

Seja a função $h(t)$ dada por

$$h(t) = \sum_{r=1}^{2N} A_r e^{s_r t} \quad (11.1)$$

Discretizando a função $h(t)$ em amostras espaçadas de Δt e tomando-se $e^{s_r \Delta t} = V^r$ reescrevemos a expressão anterior como

$$h(t_n) = \sum_{r=1}^{2N} A_r V_r^n, \quad n = 0, 1, \dots, q \quad (11.2)$$

Expandindo a equação (11.2) para cada amostra considerada e multiplicando por coeficientes arbitrários β_i , tem-se

$$\begin{aligned} \beta_0 h_0 &= \beta_0 \sum_{r=1}^{2N} A_r V_r^0 \\ \beta_1 h_1 &= \beta_1 \sum_{r=1}^{2N} A_r V_r^1 \\ &\vdots \\ \beta_q h_q &= \beta_q \sum_{r=1}^{2N} A_r V_r^q \end{aligned}$$

Somando as q equações anteriores obtemos,

$$\sum_{i=0}^q \beta_i h_i = \sum_{j=1}^{2N} A_j \sum_{i=0}^q \beta_i V_j^i \quad (11.3)$$

Analogamente

$$\sum_{i=0}^q \beta_i h_{i+1} = \sum_{j=1}^{2N} A_j \sum_{i=0}^q \beta_i V_j^{i+1} \quad (11.4)$$

Fazendo a equação (11.3) igual a zero e $q = 2N$ tem-se:

$$\sum_{i=0}^q \beta_i V_j^{i+1} = V_j \sum_{i=0}^q \beta_i V_j^i \quad (11.5)$$

sem perda de generalidade, fazendo $\beta_{2N} = 1$, vem:

$$\begin{aligned} \sum_{i=0}^{2N} \beta_i h_i &= 0 \\ \sum_{i=0}^{2N-1} \beta_i h_i &= -h_{2N} \end{aligned} \quad (11.6)$$

A equação (11.6) implica em:

$$\begin{aligned} \sum_{i=0}^{2N-1} \beta_i h_{i+1} &= 0 \\ \sum_{i=0}^q \beta_i V_j^{i+1} &= V_j \sum_{i=0}^q \beta_i V_j^i = 0 \end{aligned} \quad (11.7)$$

o que vale para qualquer deslocamento s no tempo:

$$\sum_{i=0}^q \beta_i V_j^{i+s} = V_j^s \sum_{i=0}^q \beta_i V_j^i = 0$$

Desta forma, fazendo $N-1$ deslocamentos no tempo e montando as equações resultantes na forma matricial:

$$\begin{aligned} \sum_{i=0}^{2N-1} \beta_i h_{i+s} &= -h_{2N+s} \\ \left(\begin{array}{cccc} h_0 & h_1 & \cdots & h_{2N-1} \\ h_1 & h_2 & \cdots & h_{2N} \\ \vdots & \vdots & \vdots & \vdots \\ h_{M-1} & h_M & \cdots & h_{M+2N-2} \end{array} \right) \left(\begin{array}{c} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{2N-1} \end{array} \right) &= \left(\begin{array}{c} -h_{2N} \\ -h_{2N+1} \\ \vdots \\ -h_{M+2N-1} \end{array} \right) \end{aligned} \quad (11.8)$$

onde $s = M-1$.

Resolvendo o sistema linear de equações com $M \geq 2N$ determina-se os β_i . Substituindo (11.8) em (11.3), tem-se que uma solução possível é:

$$\sum_{i=0}^{2N} \beta_i V_j^i = 0 \quad (11.9)$$

onde $j = 1, 2, \dots, 2N$. Isto significa que os V_j procurados são raízes de um polinômio de coeficientes β_i , já calculado pela solução (11.8). As raízes do polinômio podem ser obtidas por um problema de autovalor associado.

Pode-se relacionar os β_i e V pela construção de uma matriz companheira, considerando as variáveis auxiliares $\beta_i = V^0$, $X_1 = VX^0$, ..., $X_k = VX^{k-1}$.

$$\begin{pmatrix} -\beta_{2N-1} & -\beta_{2N-2} & \cdots & \beta_1 & \beta_0 \\ 1 & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{pmatrix} \begin{pmatrix} X_{2N-1} \\ X_{2N-2} \\ \vdots \\ X_0 \end{pmatrix} = V \begin{pmatrix} X_{2N-1} \\ X_{2N-2} \\ \vdots \\ X_0 \end{pmatrix} \quad (11.10)$$

Desta última equação obtém-se $2N$ raízes V_j , de onde são obtidos os autovalores ou frequências naturais do sistema usando a relação $s_r = (1/\Delta t)\ln(V_r)$, e cujos autovetores podem ser obtidos usando a equação (11.3).

$$\begin{pmatrix} 1 & 1 & \cdots & 1 \\ V_1^1 & V_2^1 & \cdots & V_{2N}^1 \\ \vdots & \vdots & \vdots & \vdots \\ V_1^q & V_2^q & \cdots & V_{2N}^q \end{pmatrix} \begin{pmatrix} A_1 \\ A_2 \\ \vdots \\ A_{2N} \end{pmatrix} = \begin{pmatrix} h_0 \\ h_1 \\ \vdots \\ h_q \end{pmatrix} \quad (11.11)$$

onde $q \geq 2N$. A solução da equação anterior são os $2N$ resíduos A_j . Esta formulação pode ser estendida para cada entrada ou referência q e N saídas substituindo h_i na equação (11.8) por $\{h_q\}_i$ onde :

$$\{h_q\} = \begin{pmatrix} h_{1q} \\ h_{2q} \\ \vdots \\ h_{Nq} \end{pmatrix}$$

Nas equações (11.11) os h_i são substituídos por $\{h_q\}_i^T$ sendo que os A_i obtidos tornam-se $\{A_i\}^T$ que são os i -ésimos autovetores.

11.2 Método polireferência no domínio do tempo

Para cada grau de liberdade, $p = 1, \dots, N_0$, tem-se:

$$\{h_p(t_n)\} = \sum_{r=1}^{2N} \{A_{pr}\} e^{s_r t_n} \quad (11.12)$$

onde $\{h_p\} = \{h_{p1} \ h_{p2} \ \dots \ h_{pNi}\}^T = \{A_{p1r} \ A_{p2r} \ \dots \ h_{pNir}\}^T$. A equação (11.12) pode ser rescrita como:

$$\{h_p(t_n)\} = \sum_{r=1}^{2N} \{A_{pr}\} V_r^n \quad (11.13)$$

A expressão que relaciona os resíduos aos fatores de participação modal é:

$$A_{pir} = \frac{\Phi_{ir}}{\Phi_{qr}} A_{pqr} = L_{iqr} A_{pqr}$$

Escolhida a referência l , pode-se escrever o vetor A_{pr} em função do resíduo correspondente à referência escolhida A_{prl} :

$$\{A_{pr}\} = \{L\}_r A_{prl}$$

Montando uma matriz L a partir dos vetores $\{L\}_r$ tem-se,

$$L = \begin{pmatrix} L_{1,l,1} & L_{1,l,2} & \cdots & L_{1,l,2N} \\ L_{2,l,1} & L_{2,l,2} & \cdots & L_{2,l,2N} \\ \vdots & \vdots & \vdots & \vdots \\ L_{N_l,l,1} & L_{N_l,l,2} & \cdots & L_{N_l,l,2N} \end{pmatrix}$$

Construindo uma matriz V diagonal com os elementos V_r da equação (11.13):

$$L = \begin{pmatrix} V_1 & 0 & \cdots & 0 \\ 0 & V_2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & V_{2N} \end{pmatrix}$$

pode-se rescrever a equação (11.13) em forma matricial:

$$\{h_{pn}\} = [L][V]^n \{A_p\} \quad (11.14)$$

Analogamente ao método utilizado para SISO, multiplicando a equação (11.14) por β_i tem-se:

$$\begin{aligned} [\beta_0] \{h_{p0}\} &= [\beta_0] [L][V]^0 \{A_p\} \\ [\beta_1] \{h_{p1}\} &= [\beta_1] [L][V]^1 \{A_p\} \\ \vdots &\quad \quad \quad \vdots \\ [\beta_q] \{h_{pq}\} &= [\beta_q] [L][V]^q \{A_p\} \end{aligned}$$

Somando todas as equações:

$$\sum_{i=0}^q [\beta_i] \{h_{pi}\} = \sum_{i=0}^q [\beta_i] [L][V]^i \{A_p\} \quad (11.15)$$

Analogamente

$$\sum_{i=0}^q [\beta_i] \{h_{pi+1}\} = \sum_{i=0}^q [\beta_i] [L][V]^{i+1} \{A_p\} \quad (11.16)$$

Fazendo a equação (11.15) nula, e tomando $q = 2N$, tem-se:

$$\sum_{i=0}^{2N} [\beta_i] \{h_{pi}\} = \{0\} \quad (11.17)$$

É fácil mostrar que:

$$\sum_{i=0}^N [\beta_i] \{h_{p(i+s)}\} = \{0\} \quad (11.18)$$

para qualquer deslocamento no tempo s desde que $\sum_{i=0}^q [\beta_i] [L][V]^i = [0]$, o que é uma solução

de

$$\sum_{i=0}^q [\beta_i] [L][V]^i \{A_p\} = \{0\}$$

Sem perda de generalidade, assumindo $[\beta_i] = [I]$, e passando o último termo para o lado direito da equação (11.18) vem:

$$\sum_{i=0}^{2N-1} [\beta_i] \{h_{pi}\} = -\{h_{p2N}\} \quad (11.19)$$

Para cada ponto de resposta p (ou grau de liberdade), $p = 1, 2, \dots, N_0$, pode-se escrever um conjunto de equações variando o deslocamento no tempo s de 0 até $X-1$, onde X é um número arbitrário, que pode ser grande. Escrevendo todos esses conjuntos de equações em uma só equação em notação matricial, tem-se:

$$[\beta_0] \quad [\beta_1] \quad \dots \quad [\beta_{2N-1}] \begin{pmatrix} \{h_{1,0}\} & \{h_{1,1}\} & \dots & \{h_{1,2N-1}\} \\ \vdots & \vdots & \dots & \vdots \\ \{h_{1,X-1}\} & \{h_{1,X}\} & \dots & \{h_{1,2N+X-2}\} \\ \vdots & \vdots & \vdots & \vdots \\ \{h_{N_0,0}\} & \{h_{N_0,1}\} & \dots & \{h_{N_0,2N-1}\} \\ \{h_{N_0,1}\} & \{h_{N_0,2}\} & \dots & \{h_{N_0,2N}\} \\ \vdots & \vdots & \dots & \vdots \\ \{h_{N_0,X-1}\} & \{h_{N_0,X}\} & \dots & \{h_{N_0,2N+X-2}\} \end{pmatrix}^T =$$

$$[-\{h_{1,2N}\} \quad \dots \quad \{h_{1,2N+X-1}\} \quad \dots \quad \{h_{N_0,2N}\} \quad \dots \quad \{h_{N_0,2N+X-1}\} \quad \dots]$$

A notação mais concisa da equação anterior é

$$[B][h] = [r] \quad (11.20)$$

De (11.20) obtêm-se os $[\beta_i]$, $i = 0, 1, \dots, 2N-1$.

Assume-se que:

$$\left[\sum_{i=0}^q [\beta_i][L][V]^i \right] = [0]$$

abrindo esta equação para cada coluna $\{L_i\}$ de $[L]$ tem-se:

$$\sum_{i=0}^q [\beta_i] V_j^i \{L_j\} = \{0\} \quad (11.21)$$

Para que o sistema de equações tenha solução para os vários $\{L_j\}$ é preciso que:

$$\det \left[\sum_{i=0}^q [\beta_i] V^i \right] = 0 \quad (11.22)$$

o que resulta em um polinômio matricial de cujas raízes V_j , $j = 1, 2, \dots, 2N$ podem ser calculados os autovalores. Estas raízes, podem ser obtidas construindo-se a matriz companheira do polinômio matricial da equação (11.22).

$$\begin{pmatrix} -[\beta_{2N-1}] & -[\beta_{2N-2}] & \cdots & [\beta_1] & [\beta_0] \\ [I] & [0] & \cdots & [0] & [0] \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ [0] & [0] & \cdots & [I] & [0] \end{pmatrix} \begin{Bmatrix} \{X_{2N-1}\} \\ \{X_{2N-2}\} \\ \vdots \\ \{X_0\} \end{Bmatrix} = V \begin{Bmatrix} \{X_{2N-1}\} \\ \{X_{2N-2}\} \\ \vdots \\ \{X_0\} \end{Bmatrix} \quad (11.23)$$

onde cada coluna $\{L_j\}$ de $[L]$ associada a V_j é $\{X_0\}$. Finalmente, os resíduos são determinados por:

$$\begin{Bmatrix} [L][V]^0 \\ [L][V]^1 \\ \vdots \\ [L][V]^X \end{Bmatrix} \{A_p\} = \begin{Bmatrix} \{h_{p0}\} \\ \{h_{p1}\} \\ \vdots \\ \{h_{pX}\} \end{Bmatrix} \quad (11.24)$$

que pode ser modificada a partir da equação 11 fazendo variar n de 0 a X , sendo X um inteiro arbitrário.

11.3 Método polinomial (SISO)

Primeiramente o método polinomial será apresentado para o caso de uma única entrada e única saída (“single input-single output”, SISO). Pela equivalência entre as representações em frações racionais e parciais, tem-se:

$$H(s) = \sum_{k=1}^n \frac{R_k}{s - s_k} + \frac{R_k^*}{s - s_k^*} = \frac{\sum_{k=1}^m a_k (s)^k}{\sum_{k=1}^{2n} b_k (s)^k} \quad (11.25)$$

onde, R_k, R_k^* são os resíduos e s_k, s_k^* são os pólos.

Sem perda de generalidade $b_m = 1$. Desta forma tem-se:

$$\sum_{k=0}^{2n-1} b_k (i\omega)^k H(\omega) - \sum_{k=0}^m (i\omega)^k a_k = -H(\omega)(i\omega)^{2n} \quad (11.26)$$

Rescrevendo em forma matricial,

$$\begin{pmatrix} (i\omega)^0 H(\omega) & \cdots & (i\omega)^{2n-1} H(\omega) & -(i\omega)^0 & \cdots & -(i\omega)^m \end{pmatrix} \begin{Bmatrix} b_0 \\ \vdots \\ b_{2n-1} \\ a_0 \\ \vdots \\ a_m \end{Bmatrix} = \left\{ -(i\omega)^{2n} H(\omega) \right\} \quad (11.27)$$

Esta equação é do tipo $A\Phi = b$ e pode ser resolvida por mínimos quadrados e por métodos conhecidos de decomposição. Os pólos são raízes de $\sum_{k=0}^{2n} b_k s^k$. Esta equação pode ser formulada

como um problema de autovalores e autovetores através da matriz companheira.

$$\begin{pmatrix} 0 & 1 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 1 & \cdots & 0 & 0 \\ 0 & 0 & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 1 & 0 \\ 0 & 0 & 0 & \cdots & 0 & 1 \\ -b_0 & -b_1 & -b_2 & \cdots & -b_{2n-2} & -b_{2n-1} \end{pmatrix} \begin{Bmatrix} X_0 \\ X_1 \\ \vdots \\ X_{2n-1} \end{Bmatrix} = s \begin{Bmatrix} X_0 \\ X_1 \\ \vdots \\ X_{2n-1} \end{Bmatrix} \quad (11.28)$$

O último passo do método consiste em determinar os resíduos.

$$\begin{aligned}
R_k &= \lim_{s \rightarrow s_k} H(s)(s - s_k) \\
&= \lim_{s \rightarrow s_k} \frac{(s - s_k) \sum_{k=0}^m a_k s^k}{\sum_{k=0}^{2n-1} b_k s^k} \\
&= \lim_{s \rightarrow s_k} \frac{\sum_{i=0}^m a_i s^{i+1} - s_k \sum_{i=0}^m a_i s^{i+1}}{\sum_{j=0}^{2n-1} b_j s^j}
\end{aligned}$$

e por L'Hôpital obtém-se:

$$= \lim_{s \rightarrow s_k} \frac{\sum_{i=0}^m a_i s_k^i (i+1) - s_k \sum_{i=0}^m i a_i s_k^{i-1}}{\sum_{j=0}^{2n-1} j b_j s_k^{j-1}}$$

e, portanto,

$$R_k = \frac{\sum_{i=0}^m a_i s_k^i}{\sum_{j=0}^{2n-1} j b_j s_k^{j-1}} \quad (11.29)$$

O problema com esta formulação é que a matriz A torna-se mal condicionada para m e n grandes.

Utilizando polinômios ortogonais, por exemplo polinômios de Chebycheff, pode-se evitar problemas de mal-condicionamento. A função $H(\omega)$ pode ser escrita como:

$$H(\omega) = \frac{\sum_{k=1}^m \alpha_k \Phi_k}{\sum_{k=1}^{2n} \beta_k \Phi_k} \quad (11.30)$$

$$\sum_{k=0}^{2n-1} \beta_k \Phi_k(\omega) H(\omega) - \sum_{k=0}^m \alpha_k \Phi_k(\omega) = -H(\omega) \Phi_m(\omega) \quad (11.31)$$

Os polinômios podem ser gerados a partir de fórmulas recursivas de Forsythe, Chebycheff, etc. No caso de polinômios Chebycheff, tem-se:

$$\begin{aligned}
\Phi_0(x) &= 1 \\
\Phi_1(x) &= x \\
&\vdots \\
\Phi_k(x) &= 2x\Phi_{k-1}(x) - \Phi_{k-2}(x)
\end{aligned} \tag{11.32}$$

que são ortogonais na faixa: $-1 \leq x \leq 1$ i.e.

$$\int_{-1}^1 w(x) \Phi_k(x) \Phi_e(x) dx = 0 \tag{11.33}$$

onde $w(x)$ é uma função de ponderação $w(x) = (1 - x^2)^{-1/2}$. Para determinar α_k e β_k basta fazer:

$$\begin{bmatrix} \Phi_0 H(\omega) & \cdots & \Phi_{2n-1} H(\omega) & -\Phi_0 & \cdots & -\Phi_m \end{bmatrix} \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_{2n-1} \\ \alpha_0 \\ \vdots \\ \alpha_m \end{bmatrix} = \begin{bmatrix} -\Phi_{2n} H(\omega) \end{bmatrix} \tag{11.34}$$

o resto do procedimento é análogo.

A conversão de α_k e β_k em a_k e b_k é trivial, já que os polinômios ortogonais são formados a partir de polinômios em séries de potências.

11.4 Método de Ibrahim no domínio do tempo

No método de Ibrahim tenta-se organizar a formulação de Prony de forma a conseguir um problema de autovalores e autovetores.

$$[x(t)] = [\Psi][\Lambda][L] \tag{11.35}$$

onde,

$[\Psi]$ é a matriz de autovetores

$[\Lambda]$ é a matriz de autovalores complexos

$[L]$ é a matriz diagonal dos fatores de participação modal

Isto pode ser alcançado tomando-se um segundo conjunto de respostas medidas, em um instante de tempo Δt imediatamente posterior ao primeiro conjunto medido. Isto pode ser expresso por:

$$x_i(t_i + \Delta t) = \sum_{r=1}^{2m} L_r \Psi_{ir} e^{s_r(t_i + \Delta t)} \quad (11.36)$$

Alterando a notação:

$$\hat{x}_i(t_i) = \sum_{r=1}^{2m} L_r \hat{\Psi}_{ir} e^{s_r(t_i)} \quad (11.37)$$

A equação anterior leva a um segundo conjunto de equações expresso por:

$$[\hat{x}(t)] = [\hat{\Psi}][\Lambda][L] \quad (11.38)$$

A partir de um mesmo conjunto de dados pode-se encontrar uma matriz que correlacione:

$$[A][\Psi] = [\hat{\Psi}] \quad (11.39)$$

Considerando as equações (11.34) e (11.37),

$$[A][x] = [\hat{x}] \quad (11.40)$$

A matriz A pode ser obtida diretamente da equação anterior pelo processo de determinação da pseudo-inversa, o que para um sistema com $q > 2m$ equivale à solução por mínimos quadrados. A partir da relação expressa pela equação (11.39) e considerando as expressões de $[x]$ e $[\hat{x}]$ dadas pelas equações (11.34) e (11.37), chega-se a um problema de autovalores e autovetores.

$$[A]\{\Psi\}_r = e^{s_r \Delta t} \{\Psi\}_r \quad (11.41)$$

Com a resolução deste problema determinam-se os parâmetros modais λ_r e Ψ_r . Uma observação deve ser feita quanto à determinação dos modos, pois eles devem ser normalizados após a resolução de problema de autovalores e autovetores, para que permitam posteriormente sintetizar as respostas em frequência (FRFs). Na montagem das matrizes $[x]$, devem-se criar graus de liberdade fictícios defasando a resposta ao impulso no tempo. Com isso, pode-se controlar a ordem do modelo, que é dada pelo número de colunas de $[x]$, e, ainda assim, usar todas as amostras no tempo que se desejar. Desta forma o problema fica sobre-determinado, pois $q > 2m$. Além disso, estes graus de liberdade permitem calcular, depois, o fator de confiança modal (do inglês “modal confidence factor”, MCF), essencial para separar modos computacionais dos modos físicos. O MCF consiste simplesmente em usar o fato de que o modo estimado para graus de liberdade fictícios obtidos defasando a resposta ao impulso de um intervalo de tempo τ pode ser obtido do mesmo modo identificado para os graus de liberdade correspondentes sem defasagem,

$$\{\hat{\Psi}\}_r = e^{s_r \tau} \{\Psi\}_r \quad (11.42)$$

O coeficiente de correlação entre $\{\Psi\}_r$, calculado diretamente e o calculado pela equação (11.42) a partir dos graus de liberdade fictícios constitui o MCF.

11.5 Método polinomial polireferência (MIMO)

É possível estender o método de ajuste polinomial para o caso de múltiplas entradas e múltiplas saídas (“multiple input-multiple output”, MIMO).

Escrevendo a parcela da matriz de resposta em frequência medida ($N_0 \times N_i$) transposta:

$$[H(\omega)] = \frac{\sum_{k=0}^m [a_k] s^k (N_i \times N_0)}{\sum_{k=0}^{2n} [b_k] s^k (N_i \times N_i)} \quad (11.43)$$

onde $s = i\omega$, $[a_k]$ e $[b_k]$ são coeficientes de polinômios matriciais.

Inicialmente, cabe notar que, neste caso, o denominador não se anula para as raízes do polinômio s_r , $r=1,2, \dots, 2nN_i$ mas, ao invés disso, perde posto (“rank”), ou seja:

$$\det \left[\sum_{k=0}^{2n} [b_k] s^k \right] = 0 \quad (11.44)$$

Sabendo dos problemas de mal condicionamento da matriz A no caso dos polinômios em séries de potências, utiliza-se a formulação por polinômios ortogonais:

$$[H(\omega)] = \frac{\sum_{k=0}^m [\alpha_k] \Phi_k(\omega)}{\sum_{k=0}^{2n} [\beta_k] \Phi_k(\omega)} \quad (11.45)$$

Fazendo $[\beta_{2n}] = I_i (N_i \times N_i)$ sem perda de generalidade, pode-se escrever:

$$\sum_{k=0}^{2n-1} [H(\omega)]^H \Phi_k^* [\beta_k]^H - \sum_{k=0}^m \Phi_k^* I_0 [\alpha_k]^H = -\Phi_{2n}^* [H(\omega)]^H \quad (11.46)$$

onde H denota o conjugado transposto de uma matriz e $*$ denota o conjugado de um escalar complexo.

Da equação (11.46) pode-se formar o problema de mínimos quadrados para a determinação de $[\alpha_k]$ e $[\beta_k]$:

$$\begin{bmatrix} H^H \Phi_0^* & \cdots & H^H \Phi_{2n-1}^* & -\Phi_0^* I_0 & \cdots & -\Phi_m^* I_0 \end{bmatrix} \begin{Bmatrix} [\beta_0]^H \\ \vdots \\ [\beta_{2n-1}]^H \\ [\alpha_0]^H \\ \vdots \\ [\alpha_m]^H \end{Bmatrix} = \{-\Phi_m^* H^H\} \quad (11.47)$$

Vold propôs que, ao invés de converter $[\alpha_k]$ e $[\beta_k]$ em $[a_k]$ e $[b_k]$ para então calcular os autovalores e autovetores, estes fossem calculados por uma matriz companheira na própria base polinomial ortogonal. De fato, se $\left[\sum_{k=0}^{2n} [\beta_k] \Phi_k \right] = 0$ perde “rank”, pode-se escrever:

$$\left[\sum_{k=0}^{2n} [\beta_k] \Phi_k(\omega) \right] V = 0 \quad (11.48)$$

Rearranjando e fazendo $[\beta_k] = I_i$ tem-se:

$$\left[-\sum_{k=0}^{2n-1} [\beta_k] \Phi_k(\omega) \right] V = \Phi_m(\omega) V \quad (11.49)$$

Mas, os $\Phi_k(\omega)$ são polinômios de Chevycheff:

$$\Phi_k(s)V = 2s\Phi_{m-1}(s)V - \Phi_{m-2}(s)V \quad (11.50)$$

o que permite escrever:

$$\begin{bmatrix} -[\beta_0] & \cdots & -[\beta_{2n-1}] \end{bmatrix} \begin{Bmatrix} \Phi_0(\omega)V \\ \vdots \\ \Phi_{2n-1}(\omega)V \end{Bmatrix} + \Phi_{n-2}(\omega)V = 2s\{-\Phi_{2n-1}(\omega)V\} \quad (11.51)$$

Arranjando várias equações com m variando de 1 a n-1 e a equação (11.49), pode-se escrever:

$$\begin{aligned}
& \begin{bmatrix} [0] & [I_i] & [0] & \cdots & & [0] \\ [I_i] & [0] & [I_i] & \cdots & & [0] \\ [0] & [I_i] & [0] & \cdots & & [0] \\ \vdots & \vdots & \vdots & & & \vdots \\ [0] & [0] & [0] & \cdots & [I_i] & [0] & [I_i] \\ -[\beta_0] & -[\beta_1] & -[\beta_2] & \cdots & -[\beta_{2n-3}] & -[I_i\beta_{2n-2}] & -[\beta_{2n-1}] \end{bmatrix} \begin{Bmatrix} \Phi_0(\omega)V \\ \vdots \\ \Phi_{2n-1}(\omega)V \end{Bmatrix} = \\
& s \begin{bmatrix} [I_i] & [0] & \cdots & [0] \\ [0] & [2I_i] & \cdots & [0] \\ \vdots & \vdots & & \vdots \\ [0] & [0] & \cdots & [2I_i] \end{bmatrix} \begin{Bmatrix} \Phi_0 V \\ \vdots \\ \Phi_{2n-1} V \end{Bmatrix} \quad (11.52)
\end{aligned}$$

Este é um problema de autovalor generalizado cujos autovalores são as raízes s_r , $r = 1, 2, \dots, 2nN_i$ procuradas.

O método pode ser generalizado para outros tipos de polinômios ortogonais gerados por fórmulas recursivas.

A obtenção dos resíduos pode ser feita por uma generalização do método SISO ou por uma formulação alternativa, que usa a fase de obtenção de resíduos do método polireferência.

Para isto, basta observar que os vetores V_r ($N_i \times 1$), sub-vetores dos autovalores do problema anterior (lembrando que $\Phi_0(\omega) = 1$, donde os primeiros N_i elementos do autovetor dão diretamente V_r), são nada menos que os vetores de participação modal (ou autovetores à esquerda) L_r da formulação do método polireferência. (Isto não foi provado, apenas constatado.) Tem-se, portanto, as raízes s_r , $r = 1, 2, \dots, 2nN_i$ da formulação em frações parciais.

$$[H(\omega)] = \sum_{r=1}^N \{\Psi_r\} \frac{L_r^T}{i\omega - s_k} + \{\Psi_r^*\} \frac{L_r^H}{i\omega - s_r^*} \quad (11.53)$$

onde $N = nN_i$, $\{\Psi_r\}$ são os modos ($N_i \times 1$) e V_r ($N_i \times 1$). Para cada resposta Θ , $\Theta = 1, \dots, N_0$, pode ser escrito como:

$$\{H(\omega)\}_\Theta = \sum_{r=1}^{2N} \Psi_{r\Theta} \frac{\{L_r\}^T}{i\omega - s_k} \quad (11.54)$$

$$\Psi_\Theta = [\Phi_{\Theta 1} \quad \Phi_{\Theta 2} \quad \cdots \quad \Phi_{\Theta 2N}] \quad (11.55)$$

$$\{H(\omega)\}_\Theta = \Psi_\Theta W(\omega) L^T = \Psi_\Theta B^T W(\omega) \quad (11.56)$$

$$W(\omega) = \begin{bmatrix} (i\omega - s_1)^{-1} & 0 & \cdots & 0 \\ 0 & (i\omega - s_1)^{-1} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & (i\omega - s_1)^{-1} \end{bmatrix} \quad (11.57)$$

$$L^T = \begin{Bmatrix} L_1^T \\ L_2^T \\ \vdots \\ L_{2N}^T \end{Bmatrix} \quad (11.58)$$

$$B(w) = LW \quad (11.59)$$

Mas a equação (11.55) vale para qualquer frequência ω .

$$H_{\Theta} = \Psi_{\Theta} B^T(\omega) \rightarrow B(\omega) \Psi_{\Theta}^T = H_{\Theta}^T(\omega) \quad (11.60)$$

Arranjando para M frequências, tem-se:

$$B(\omega) \Psi_{\Theta}^T = H_{\Theta}^T \quad (11.61)$$

onde

$$B = \begin{Bmatrix} LW_0 \\ LW_1 \\ \vdots \\ LW_M \end{Bmatrix}, H_{\Theta}^T = \begin{Bmatrix} \{H_{\Theta}(\omega_0)\}^T \\ \{H_{\Theta}(\omega_1)\}^T \\ \vdots \\ \{H_{\Theta}(\omega_m)\}^T \end{Bmatrix} \quad (11.62)$$

$$W_k = W(\omega_k) \quad (11.63)$$

de onde obtém-se Ψ_{or} ; $r = 1, \dots, 2N$ e repete-se o procedimento para $\Theta = 1, \dots, N_o$, gerando a matriz modal Ψ .

Índice

—A—

Akaike, 118
 “*aliasing*”, 44
 alisamento, 141
 amostragem, teorema da, 44
 amplitude, 4
 amplitude pico a pico, 4
 “*anti-aliasing*”, filtros, 44
 autocorrelação, função de, 118
 autovalor, 159
 autovalores, 159
 autovetor, 159
 autovetores, 159

—C—

causal, sistema, 4

—Ch—

Chebysheff, polinômios de, 159

—C—

circularidade, efeito de, 60
 conversor analógico-digital (CAD), 44
 convolução, 4, 132
 Cooley e Tukey, 44

—D—

decibel(dB), 4
 decimação em frequência, 44
 decimação no tempo, 44
 delta de Dirac, 4, 118
 delta distribuição, 4
 densidade espectral de energia, 125
 densidade espectral de potência, 60, 118, 125
 deslocamento (“shift”), 4
 DFT, 125, 141
 DFT bidimensional, 141
 Dirac, 4
 discretização, 44
 Duhamel, integral de, 4

—E—

envelope do sinal, 132
 ESD, 125
 espectro, 4
 espectro de amplitudes, 4
 espectro de fase, 4
 espectro de potência, 125
 espectro discreto, 4
 Euler-Fourier, 4, 44
excitação, 4

—F—

fase, 4
 fator de participação modal, 159
 FFT, 44
 filtros, 4
 Filtros acústicos, 141
 filtros de 1/3 oitava, 141
 “Final Predictor Error” (FPE), 118
 Fourier, 4
 Fourier, algoritmos da transformada, 44
 Fourier, analisadores, 44
 Fourier, série de, 4
 Fourier, série de, bidimensional, 141
 Fourier, série de, discreta regressiva, 141
 Fourier, transformada de, 4
 Fourier, transformada de, 118
 Fourier, transformada discreta, 44
 FRF, 4, 159
 função de transferência, 4
 função delta de Dirac, 4
 função pente, 4
 função porta, 4

—H—

Hamming, 4
 Hanning, 4, 60
 Hertz, 4
 Hilbert, transformada de, 132
 Hilbert, transformada de, 132

—I—

Ibrahim, método de, 159
 interpolação de Shannon, 44

—J—

janela de observação, 60
 janela retangular, 4
 janelas de observação, 4

—K—

Kirchoff, 4

—L—

L'Hôpital, 159
 Laplace, transformada de, 4
 “leakage”(vazamento), 44, 60, 125, 141
 Levinson-Durbin, 118
 linear, sistema, 4
 lóbulos laterais, 4

—M—

matriz companheira, 159
 máxima entropia, 118
 método polinomial, 159
 MIMO, 159
 mínimos quadrados, 141, 159
 modelo autoregressivo, 118
 modelos paramétricos, 118, 159
 modulação em amplitude, 4

—O—

ortogonais, polinômios, 159

—P—

Parseval, 4, 141
 período, 4
 periodograma, 118
 Poisson, fórmula de, 44
 Poisson, fórmula de, 4
 polireferência, 159
 potência do sinal, 4

Prony, método de, 159
 PS, 125
 PSD, 125
 pseudo-transformada, 4

—R—

RDFS, 141
 RDFS bidimensional, 141
 RDFS unidimensional, 141
 reamostragem, 44
 relações entrada/saída, 4
 resolução em frequência, 44
 resposta, 4
 RLC, sistema elétrico, 4
 RMS, raiz do valor médio quadrático, 4

—S—

senóide, 4
 série de impulsos, 4
 sinai discreto, 44
 sinal, 4
 sinal aleatório, 4, 125
 sinal analítico, 132
 sinal causal, 132
 sinal periódico, 44
 sinal senoidal, 4
 sinal transitório, 4, 44, 125
 SISO, 159
 STFT, 141
 superposição, princípio da, 4

—T—

teorema da convolução, 4
 teorema de energia, 4
 Toeplitz, 118
 transformação, 4
 transformada Q constante, 141
 truncamento, 4

—Y—

Yule-Walker, 118

Referências

[1] Papoulis, A, Probability, Random Variables and Stochastic Processes, Auckland, McGraw-Hill, 1981.

[2] Davenport, W.B., Probability and Random Processes, Tokyo: McGraw-Hill Kogakusha, 1970.

[3] Bendat, J.S. and Piersol,AG., Engineering Applications of Correlation and Spectral Analysis, New York: John Wiley & Sons, 1980.

[4] Schroeder, M.R. "Synthesis of low peak factor signals and binary sequences with low autocorrelation." IEEE Trans. Inform. Theory, vol. IT-16, pp. 85-89, 1970.

[5] Arruda, J.R.F., Multisine Multiexcitation in Frequency Response Function Estimation, AIAA Journal, 31(1), 1993, pp. 215-216.

[6] Papoulis, A, Probability, Random Variables and Stochastic Processes, Auckland, McGraw-Hill, 1981.

[7] Davenport, W.B., Probability and Random Processes, Tokyo: McGraw-Hill Kogakusha, 1970.

[8] Bendat, J.S. and Piersol,AG., Engineering Applications of Correlation and Spectral Analysis, New York: John Wiley & Sons, 1980.

[9] Bendat, J.S. and Piersol,AG., Random Data: Analysis and Measurement Procedures, New York: Wiley Interscience, 1971.

-
- [10] Marple, S.L., Digital Spectral Analysis with Applications, Eglewood Cliffs: Prentice-Hall, 1987.
- [13] Akaike, H., Parzen, E. (Editor), Tanake, K. (Editor), Selected papers of Hirotuyu Akaike, Springer Verlag, 1998.
- [11] Strang, G., Introduction to Applied Mathematics, Wellesley: Wellesley-Cambridge Press, 1986.
- [12] Newland, D.E., An Introduction to Random Vibrations, Spectral and Wavelet Analysis, 3rd. Edition, Singapure: Longman, 1993.
- [14] Gade, S. and Herlufsen, H., "Signals and Units," B&K Technical Review, No. 3, 1987, pp. 29-38.
- [15] Papoulis, A., Signal Analysis, McGraw-Hill, 1977.
- [16] Bendat, J.S. and Piersol, A.G., Engineering Applications of Correlation and Spectral Analysis, J. Wiley & Sons, 1980.
- [17] Arruda, J.R.F. and Godoy, E., "A Peak Classification Technique in Digital Spectral Analysis," Proceedings of IMAC 7, Las Vegas, NV, 1989, pp. 1582-1586.
- [18] Randall, B. Tech., B.A "Frequency Analysis," Bruel & Kjaer, 1987, pp. 177-184.
- [19] Arruda, J.R.F, Surface smoothing and partial spatial derivatives computation using a regressive discrete Fourier series, Mechanical Systems and Signal Processing, 1992, 6(1), pp. 41-50.

[20] Arruda, J.R.F, Analysis of non-equally spaced data using a regressive discrete Fourier series, *Journal of Sound and Vibration*, 1992, 156(3), pp. 571-574.

[21] Boor, C., “A practical guide to splines”, Berlin, Springer-Verlag, 1978.

[22] Eykhoff, P., “System identification – Parameter and State Estimation”, London: John Wiley, 1974.

[23] Oppenheim, AV., Shafer, R.W., “Discrete Time Signal Processing”, *Prentice Hall*, NJ, USA, 1989.

[24] Brown, J.C., Calculation of a constant-Q spectral transform, *Journal of Acoustical Society of America*, 89(1), pp.425-434, 1991.

[25] Brown J.C., An efficient algorithm for the calculation of a constant-Q transform, *Journal of Acoustical Society of America*, 92(5), pp.2698-2701, 1992.

[26] Bendat, J.S. and Piersol, A G., *Random data: Analysis and measurement procedures*, Wiley, New York, USA, 1986.

[27] Miller J.E., Spectral measurements of violins, *Catgut Acoust. Soc. J.*, vol 2, no. 4, p. 1-4, Nov. 1993.

[28] Sando R., Huallpa, B.N., Arruda F. J. R. , Violin quality assessment with an objective criterion using the constant-Q transform, *International Conference on Noise and Vibration Engineering (ISMA 26)*, Sept. 10 –14, Perugia_Italy, p. 127-132, 2001.

[29] Huallpa, B.N., Arruda F. J. R., F.J. Von Zuben, The Constant Q-Transform Used as a Practical Sound Filter, *Proceedings of the IX DINAME, 5-9 March 2001, Florianópolis - SC - Brazil*, p. 89-93, 2001.

[30] Huallpa, B.N., Arruda F. J. R. , Ferramentas de análise espectral: série de Fourier discreta regressiva e transformada Q constante, 1ª. Escola Temática de Dinâmica e Controle (Dincon 2002) da SBMAC, Julho 29-Agosto 2, São José do Rio Preto – São Paulo - Brasil, 2002

[31] Ewins, D.E., Modal Testing, Wiley Research Studies Press, 1984.

[32] Allemang et al., Experimental Modal Analysis and Dynamic Component Synthesis, Vol. III, Modal Parameter Estimation, Report AFWAL, TR 87-3069, *Flight Dynamics Laboratory, Air Force Wright Aeronautical Laboratories, Wright – Patterson Air Force Base, Ohio, USA* 1987.

[33] Vold, H., Kundrat, J. Rocklin, G.T., Russel, R., A Multi-Input Modal Estimation Algorithm for Mini – Computers, *SAE paper No. 820194, SAE Transactions*, Vol. 91, No. 1, pp.815-821, 1982.

[34] Vold, H., Numerically Robust Frequency Domain Modal Parameter Estimation, *Sound and Vibration*, January, pp.38-40, 1990.

[35] Richardson, M.H., Formenti, D.L., Parameter Estimation from Frequency Response Measurements Using Rational Fraction Polynomials, *Proc. of the 1st. Int. Modal Analysis Conference, Orlando, Fl., USA*, pp.167-181, 1982.

[36] Ibrahim, S. and Mukulick, E., A method for the direct identification of vibration parameters from free response, *The Shock and Vibration Bulletin*, Vol. 47, No. 4, pp.183-198, 1977.